# UE BIO 504 - L3 Biologie
# Modélisation en Biologie : Partie Bioinformatique

Thierry Gautier

Session 1 – Mercredi 20 décembre 2023
9 h30 – 11 h30 (+ ⅓ temps)

L'examen comporte 4 pages présentant un petit problème réparti sur 12 questions et 3 parties. (Le total étant sur 20 points). **Prenez le temps de lire l'intégralité du sujet avant de commencer**. **ATTENTION : Vous devez impérativement répondre dans les espaces prévus à cet effet sur le sujet, et mentionner votre numéro d'anonymat en haut de chaque page. L'orthographe, la concision et le soin apporté aux réponses font partie des critères d'évaluation. Seuls les documents physiques sont autorisés.**

## Partie 1: Préparation du clonage

À votre arrivée en stage, le projet qui vous est confié consiste à cloner le gène *H2AFZ* humain codant pour l'histone H2A.Z dans un vecteur d'expression. Avant de vous lancer dans les expériences, vous vous renseignez sur ce gène, en faisant une recherche sur le site du NCBI. Grâce aux extraits de la description du gène de NCBI (figure 1), répondez aux questions suivantes :

*Q.1.1.* [1 point] *a*- De quel type de molécule est extraite cette séquence ?
*b*- Quel est le numéro *RefSeq* de la séquence proposée et son numéro de version. Vouz rapellerez les caractéristiques de la nomenclature *RefSeq*.

**Réponse :**
Le numéro *RefSeq* est NC_000004, le numéro de version est 12. information donnée par LOCUS, ACCESSION et VERSION
La nomenclature RefSeq impose un code du type XX_NNNNNN où XX décrit le type de séquence et N est un chiffre
Il s'agit d'une molécule d'ADN génomique du chromosome 4 humain.
Information données par les codes suivants /organism, /mol_type, /chromosome

*Q.1.2.* [1 point] *a*- Combien le gène *H2AFZ* contient d'exons et d'introns ?
*b*- Quelle est la taille de ce gène (**Justifiez vos réponses**) ?

**Réponse :**
La séquence fait 2269 nucléotides (visible dans LOCUS), le gène est indiqué comme utilisant toute la séquence 1..2269. Il mesure donc 2269-1+1=2269 nucléotides.
La description de l'ARNm indique qu'il faut joindre 5 sections de la séquence
mRNA join(1..188,616..693,907..1083,1416..1545,1833..2269). Il contient donc 5 exons et 4 introns.

*Q.1.3.* [2 points] Comment feriez-vous pour *a)*- calculer la taille de l'ARNm ?
*b)*- calculer la taille du 5'UTR ? (**Justifiez vos réponses**)

**Réponse :**
Pour calculer la taille de l'ARNm, il faut additionner les tailles des 5 exons en faisant la soustraction des positions finales et des positions initiales et ajouter 1 pour chaque soustraction.
Le 5'UTR est situé en amont de la CDS et est inclus dans l'ARNm. Il s'agit donc de la région comprise entre le début de l'ARNm et le début de la CDS.

*Q.1.4.* [2 points] **Vous pouvez gardez cette question pour la fin** : calculez les tailles de l'ARNm et du 5'UTR.

**Réponse :**
Calcul de la taille de l'ARNm : Exon1 : 188-1+1=188,
Exon2 : 693-616+1=78,
Exon3 : 1083-970+1=114,
Exon4 : 1545-1416+1=130,
Exon5 : 2269-1833+1=437, soit 947 ntdes
L'ARNm débute en position 1, la CDS débute en position 186, ce qui implique que le 5'UTR termine en positon 185. Il mesure donc 185 ntdes

```
LOCUS       NC_000004               2269 bp    DNA     linear   CON 06-JUN-2016
DEFINITION  Homo sapiens chromosome 4, GRCh38.p7 Primary Assembly.
ACCESSION   NC_000004 REGION: complement(99948087..99950355) GPC_000001296
VERSION     NC_000004.12

[Information supprimée]

FEATURES             Location/Qualifiers
     source          1..2269
                     /organism="Homo sapiens"
                     /mol_type="genomic DNA"
                     /db_xref="taxon:9606"
                     /chromosome="4"
     gene            1..2269
                     /gene="H2AFZ"
                     /gene_synonym="H2A.z; H2A.Z-1; H2A/z; H2AZ"
                     /note="H2A histone family member Z; Derived by automated
                     computational analysis using gene prediction method:
                     BestRefSeq."
                     /db_xref="GeneID:3015"
                     /db_xref="HGNC:HGNC:4741"
                     /db_xref="HPRD:00823"
                     /db_xref="MIM:142763"
     mRNA            join(1..188,616..693,970..1083,1416..1545,1833..2269)
                     /gene="H2AFZ"
                     /gene_synonym="H2A.z; H2A.Z-1; H2A/z; H2AZ"
                     /product="H2A histone family member Z"
                     /note="Derived by automated computational analysis using
                     gene prediction method: BestRefSeq."
                     /transcript_id="NM_002106.3"
                     /db_xref="GeneID:3015"
                     /db_xref="HGNC:HGNC:4741"
                     /db_xref="HPRD:00823"
                     /db_xref="MIM:142763"
     CDS             join(186..188,616..693,970..1083,1416..1545,1833..1894)
                     /gene="H2AFZ"
```

FIGURE 1 – Extraits de la réponse du NCBI concernant le gène humain *H2AFZ*.

## Partie 2:
## Analyse de la protéine H2A.Z après expression du gène cloné

Votre clonage terminé, vous allez maintenant faire exprimer la protéine dans des cellules en culture. Vous voulez repérer la protéine produite en Western-Blot, mais le seul anticorps disponible est dirigé contre la région amino-terminale de la protéine H2A.Z de souris. Vous décidez de réaliser un dotplot entre les séquences humaine et murine.

(a) Dotplot (b) Alignement

FIGURE 2 – Dotplot réalisé entre les séquences des protéines humaine et murine de H2A.Z.

*Q.2.5.* [1 point] Quel est le but de cette analyse ? Quelles sont les avantages du dotplot ?

**Réponse :**
Le but est de visualiser graphiquement les similarités existant entre les séquences humaine et murine. Les avantages du dotplot sont sa simplicité, sa rapidité, le mode graphique, la possibilité de comparer rapidement des génomes proches phylogénétiquement.

*Q.2.6.* [1 point] Vous réalisez le dotplot avec une taille de fenêtre de 20. Que contrôle ce paramètre ?

**Réponse :**
Il s'agit de la taille de la fenêtre de filtrage. Elle permet de contrôler le bruit de fond généré par la méthode de création du dotplot. Plus la valeur de la fenêtre est grande, plus le filtrage est important.

*Q.2.7.* [3 points] Le dotplot que vous obtenez est représenté sur la figure 2. Que pouvez-vous prédire sur l'action de l'anticorps ? **Justifiez votre réponse**.

**Réponse :**
La diagonale montre une grande similarité entre les 2 séquences protéiques. Cette similarité est en fait une identité dans la région amino-terminale des protéines des positions 1 à 73 (indiquées sur l'alignement des séquences). Il y a donc de fortes chances que l'anticorps anti-H2A.Z de souris reconnaisse la protéine humaine.

## Partie 3: Recherche sur les séquences

Curieux d'en savoir plus sur ces séquences à l'issu du dotplot, vous décidez de les aligner en utilisant un logiciel en ligne. Vous hésitez entre un alignement global et un alignement local.

*Q.3.8.* [2 points] Expliquez la différence entre les deux types d'alignements ?

**Réponse :**
L'alignement global, basé sur l'algorithme de Needleman et Wunsch consiste à proposer l'alignement optimal entre la totalité des 2 séquences. L'alignement local, basé sur l'algorithme de Smith-Waterman permet de n'aligner que des portions de séquences entre elles.

Vous réalisez un alignement '*needle*' entre les séquences. Le résultat est reproduit en figure 3.

```
#=================================
#
# Aligned_sequences: 2
# 1: H2A.Z_Homo_sapiens
# 2: H2A.Z_Mus_musculus
# Matrix: EBLOSUM62
# Gap_penalty: 10.0                H2A.Z_Homo_sa      1 MAGGKAGKDSGKAKTKAVSRSQRAGLQFPVGRIHRHLKSRTTSHGRVGAT     50
# Extend_penalty: 0.5                                    ||||||||||||||||||||||||||||||||||||||||||||||||||
#                                  H2A.Z_Mus_mus      1 MAGGKAGKDSGKAKTKAVSRSQRAGLQFPVGRIHRHLKSRTTSHGRVGAT     50
# Length: 128
# Identity:     128/128 (100.0%)   H2A.Z_Homo_sa     51 AAVYSAAILEYLTAEVLELAGNASKDLKVKRITPRHLQLAIRGDEELDSL    100
# Similarity:   128/128 (100.0%)                         ||||||||||||||||||||||||||||||||||||||||||||||||||
# Gaps:           0/128 ( 0.0%)    H2A.Z_Mus_mus     51 AAVYSAAILEYLTAEVLELAGNASKDLKVKRITPRHLQLAIRGDEELDSL    100
# Score: 635.0
#                                  H2A.Z_Homo_sa    101 IKATIAGGGVIPHIHKSLIGKKGQQKTV    128
#                                                       ||||||||||||||||||||||||||||
#                                  H2A.Z_Mus_mus    101 IKATIAGGGVIPHIHKSLIGKKGQQKTV    128
#=================================
```

FIGURE 3 – Alignement des séquences H2A.Z humaine et murine calculé avec le logiciel *needle*.

*Q.3.9.* [3 points] Commenter le résultat et l'alignement produit. Que pouvez-vous dire sur les séquences ?

**Réponse :**
L'alignement est global (needle) avec un taux d'identité de 100% entre les deux séquences. Le score est maximal puisqu'aucune différence n'existe entre les 2 séquences. Les séquences humaine et murine sont 100% identiques.

*Q.3.10.* [1½ points] Pourrez-vous utiliser l'anticorps anti-H2A.Z de souris, disponible dans le laboratoire, pour révéler la protéine H2A.Z humaine ?

**Réponse :**
Les deux séquences étant totalement identiques, l'anticorps de souris reconnaitra la séquence humaine qui partage les mêmes caractéristiques structurales que la séquence de souris ayant servi à fabriquer l'anticorps.

Vous souhaitez connaître les homologies entre toutes les protéines H2A.Z des eucaryotes en utilisant ces deux séquences. Vous créez un fichier FASTA les incluants.

*Q.3.11.* [1 point] Listez le contenu du fichier FASTA. (Vous n'écrirez que les 5 premiers et derniers acides aminés des deux séquences exemple : ABCDE...VWXYZ).

**Réponse :**
Fichier "sequences.fasta" contenant le texte suivant (fichier au format .txt)
>hH2A.Z sequence humaine
MAGGK...QQTKV
>mH2A.Z sequence murine
MAGGK...QQTKV

*Q.3.12.* [1½ points] Que feriez-vous pour déterminer l'homologie de toutes les protéines H2A.Z des eucaryotes ? **Justifiez vos réponses**

**Réponse :**
Pour déterminer l'homologie entre toutes les protéines H2A.Z des eucaryotes, on peut faire une recherche des différentes séquences H2A.Z dans une base de données protéiques avec le logiciel BLAST. Cette recherche permettra d'identifier toutes les séquences connues de H2A.Z, de les comparer et de créer un arbre phylogénétique de ces séquences. Avec la sequence protéique de H2A.Z, On utilisera *blastp* (aussi appelé **Protein BLAST**) et la base de donnée **UniProt**.