CM1 – Oct. 2025

BIO 504

Bioinformatique

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Bioinformatique ?

De quoi parle-t-on ?

Paulien Hogeweg et Ben Hesper popularisent le terme en 1970

C’était…

“Étude des processus d’information dans les systèmes biotiques”

Bioinformatique ?

C’est… devenu un terme générique

Pour toutes études biologiques qui utilisent la programmation comme partie de leur méthodologie

Pour toutes analyses spécifiques répétitives principalement utilisés en génomique

C’est…

Un champ de recherche interdisciplinaire combinant l’informatique, les statistiques, les mathématiques dans le but d’analyser et d’interpréter des données biologiques

Un outil de recherche

Bioinformatique ?

Aujourd'hui

- Bioinformatics is the application of computer technology to the understanding and effective use of biological data

- It is the discipline that stores, analyses and interprets the Big Data generated by life-science experiments, or collected in a clinical context

- This multidisciplinary field is driven by experts from a variety of backgrounds: biologists, computer scientists, mathematicians, statisticians and physicists

Que veut dire : faire de la BI ?

Séquences

```
TAGAACAAT
TCGAACAGT
CAGAATGTA
CCGAACGAT
TCGAACGTT
TAGAACGTG
GCGAGTAAT
CAGAATTAC
TGAAATATA
CAGAATAAT
```

Matrice de fréquences

M(9,10)

$$M = \begin{array}{c} A \\ C \\ G \\ T \end{array} \begin{bmatrix} 0 & 5 & 1 & 10 & 9 & 0 & 5 & 5 & 2 \\ 4 & 4 & 0 & 0 & 0 & 5 & 0 & 0 & 1 \\ 1 & 1 & 9 & 0 & 1 & 0 & 4 & 1 & 1 \\ 5 & 0 & 0 & 0 & 0 & 5 & 1 & 4 & 6 \end{bmatrix}.$$

Matrice poids position (PSSM)

$$M = \begin{array}{c} A \\ C \\ G \\ T \end{array} \begin{bmatrix} 0.0 & 0.5 & 0.1 & 1.0 & 0.9 & 0.0 & 0.5 & 0.5 & 0.2 \\ 0.4 & 0.4 & 0.0 & 0.0 & 0.0 & 0.5 & 0.0 & 0.0 & 0.1 \\ 0.1 & 0.1 & 0.9 & 0.0 & 0.1 & 0.0 & 0.4 & 0.1 & 0.1 \\ 0.5 & 0.0 & 0.0 & 0.0 & 0.0 & 0.5 & 0.1 & 0.4 & 0.6 \end{bmatrix}$$

Sont-elles différentes ?
Y a-t-il un domaine commun?

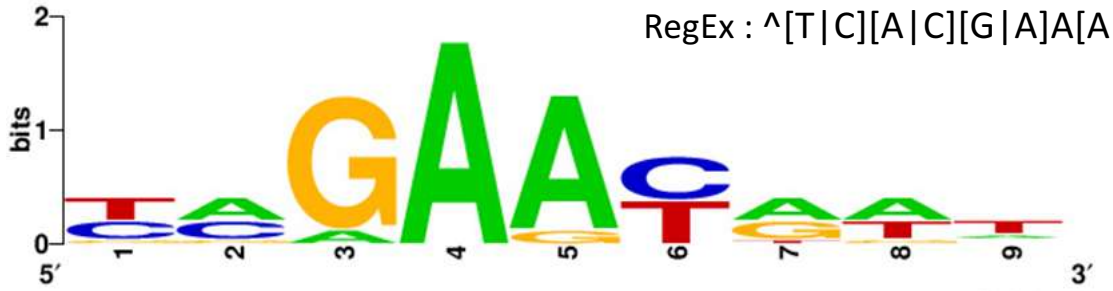

RegEx : ^[T|C][A|C][G|A]A[A|G][C|T][A|G][A|T]T

TAGAACAAT
CCAAGTGTT
TAGAGTGAT
CAAAATGAT

Transformer des « data » en savoir

D’où viennent les « data » ?

Le plus souvent de comparaisons

De l’intérêt de comparer

De quoi s’agit-il ? À quoi ça sert ?

Un téléviseur

Fonction : Présenter les programmes TV
Permet aussi de surfer sur le Net

Un ordinateur

Traiter de l’information
Permet aussi de regarder la TV

Comment le savez-vous ?

Comparer pour comprendre
Bases de données
et de connaissances
(en biologie)

Historique

- 1954: **Première séquence de protéine** (insuline, Sanger)
- 1958: Première structure 3D de protéine
  (myoglobine, Kendrew)
- 1965: Première compilation de protéines
  Margaret Dayhoff: *Atlas of Protein Sequences* (50 entrées)
  Imprimé jusqu'en 1978, puis format électronique
- 1970: **Premier séquençage d'ADN** (Ray Wu, Cornell U.)
- 1971: PDB - Protein Data Bank (struct. 3D macromolécules)
- 1977: Premier séquençage complet (phage ΦX174)

Historique

- Début des années 80:
  premières grandes banques de séquences généralistes
- 1984: Séquençage complet du virus Epstein-Barr (172 kpb)
- 1992: Séquence du Chromosome III de la levure ($3*10^5$ bp)
- 1995: Premier génome bactérien entièrement séquencé
  Haemophilus influenzae ($<2*10^6$ bp)
- 1999: Premier organisme multicellulaire
  Caenorhabditis elegans (10^8 bp)
- Juin 2001: Ébauche de séquence du génome humain ($3*10^9$ bp)

Historique

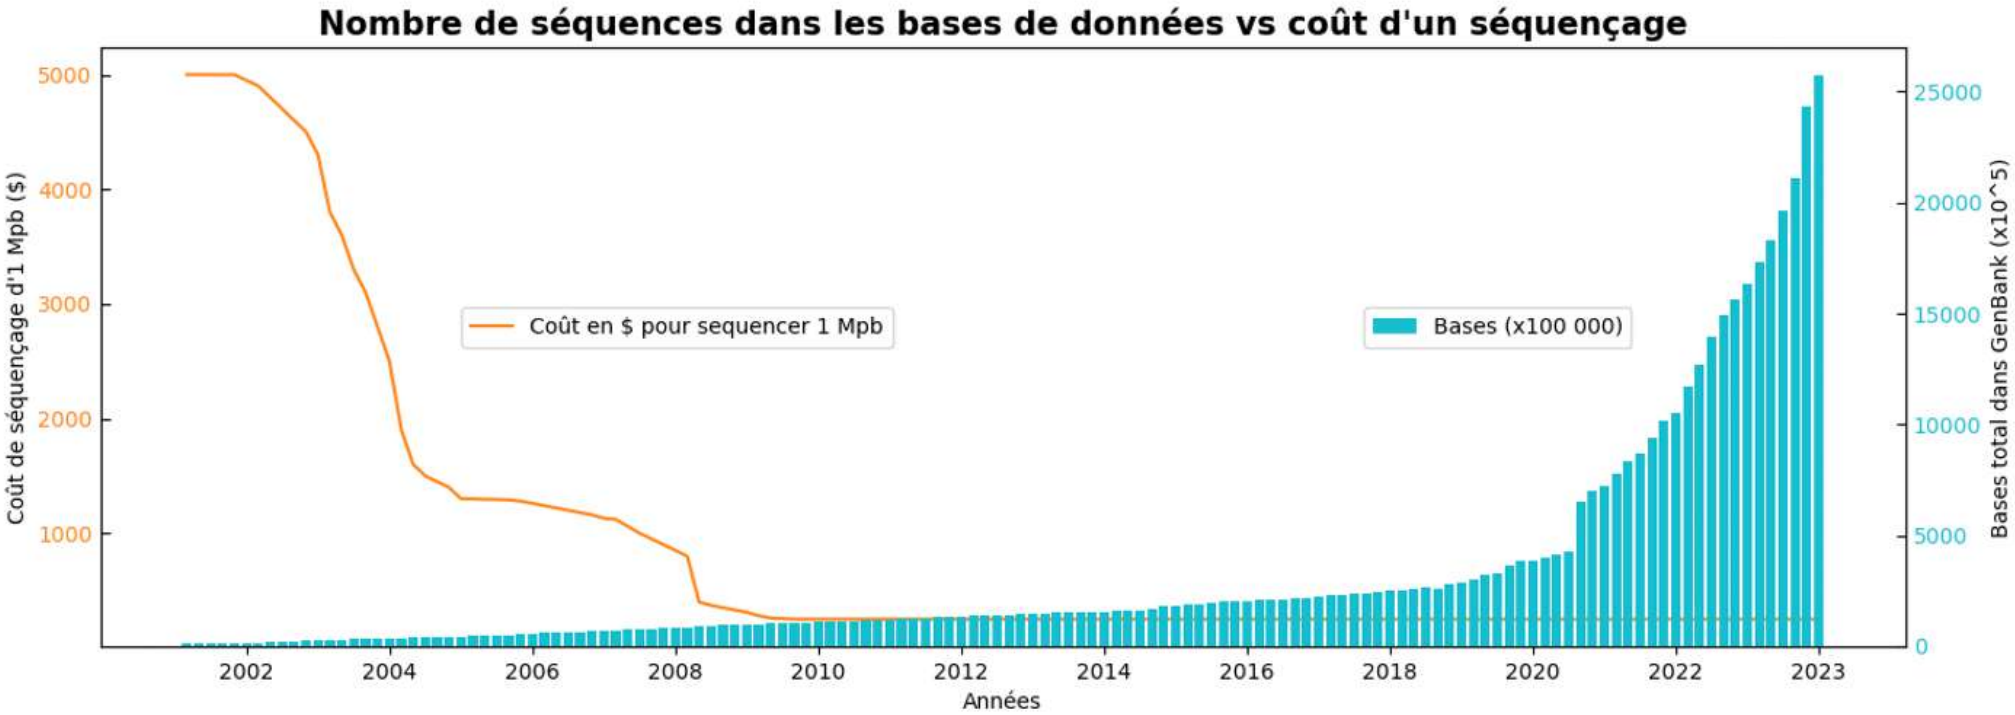
Nombre de séquences dans les bases de données vs coût d'un séquençage
Coût de séquençage d'1 Mpb ($)
5000
4000
3000
2000
1000
Coût en $ pour sequencer 1 Mpb
Bases (x100 000)
25000
20000
15000
10000
5000
0
Bases total dans GenBank (x10^5)
2002
2004
2006
2008
2010
2012
2014
2016
2018
2020
2022
2023
Années

Évolution du coût du séquençage

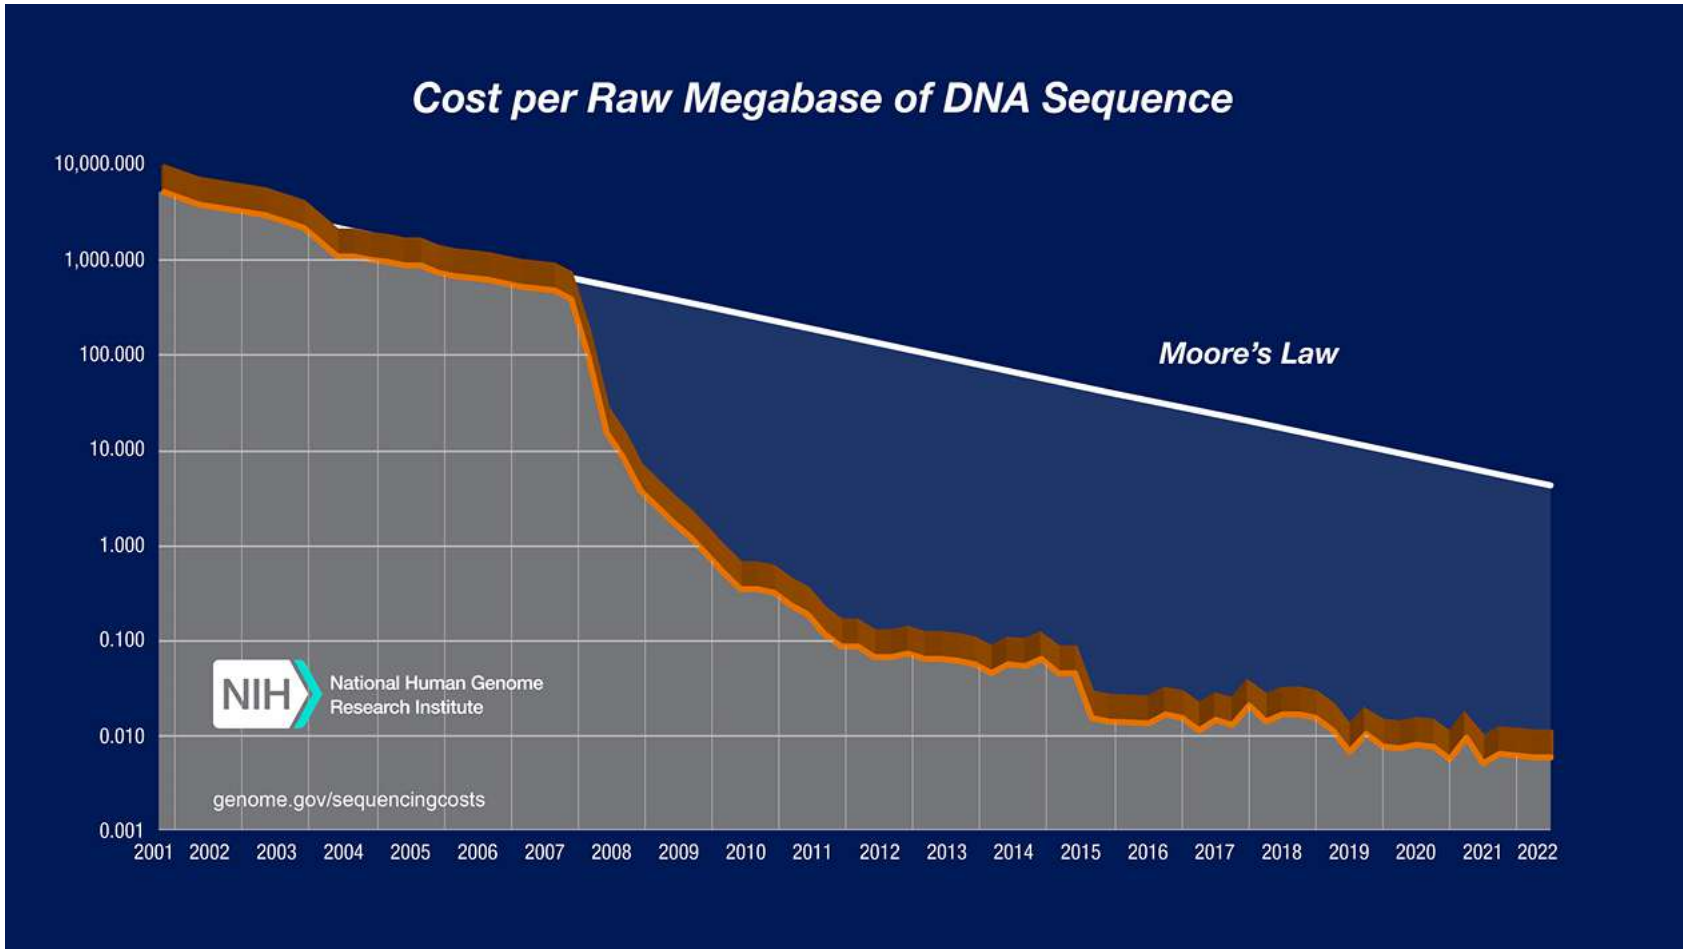

Évolution du coût du séquençage

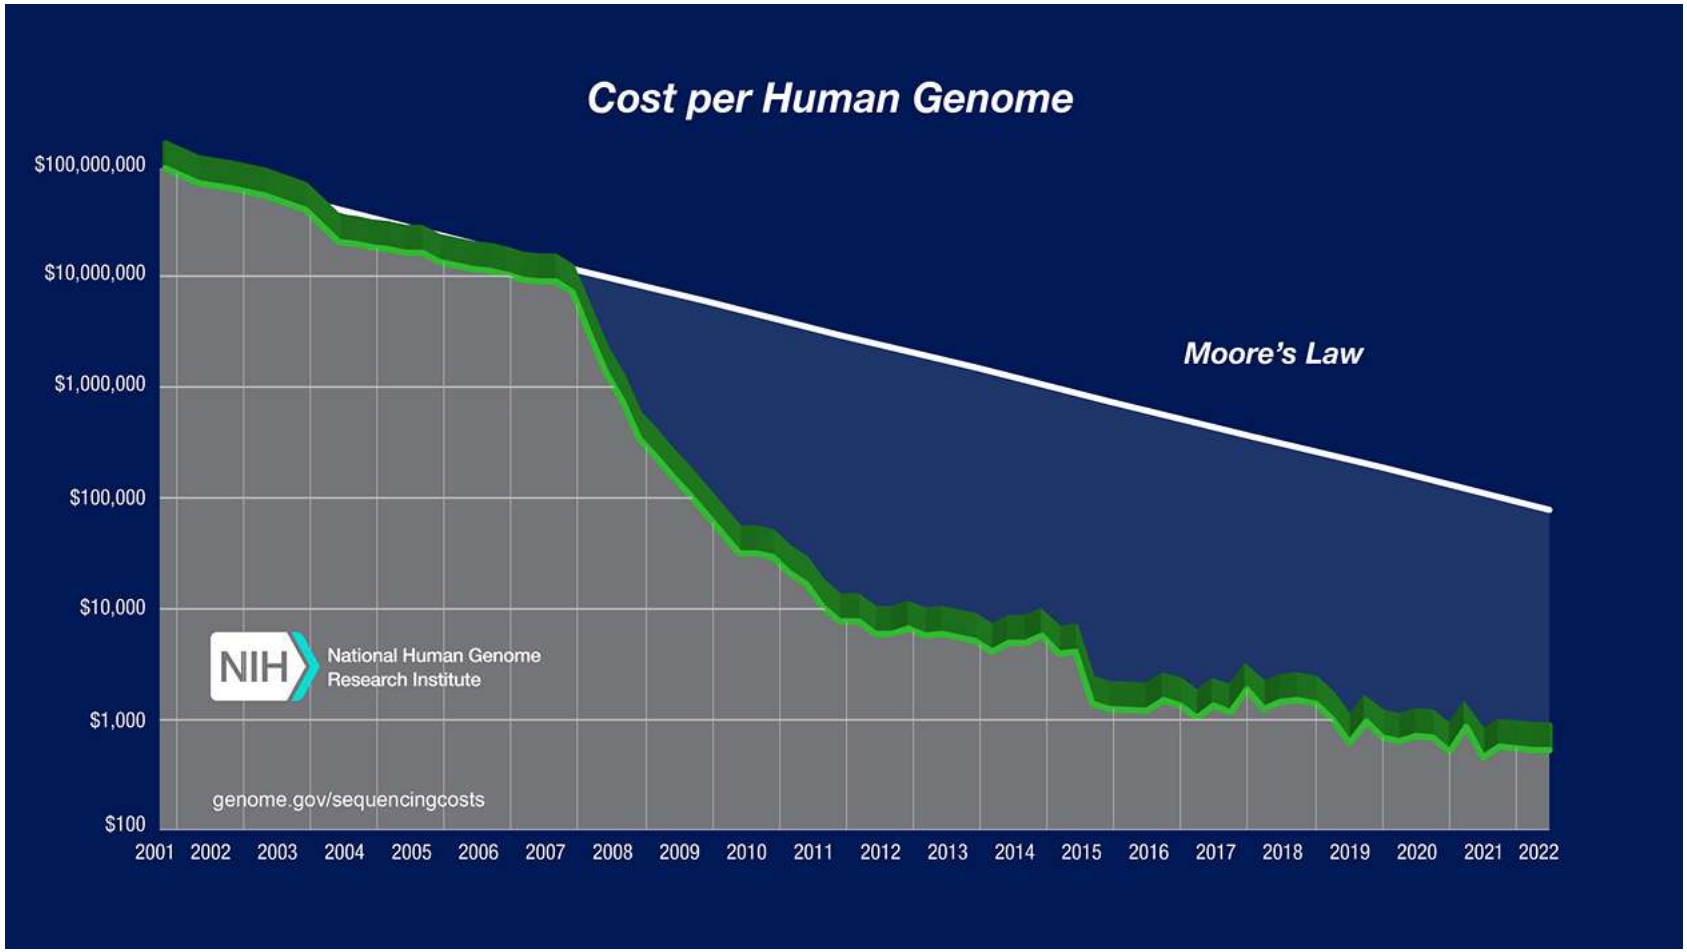

Évolution du savoir informatique

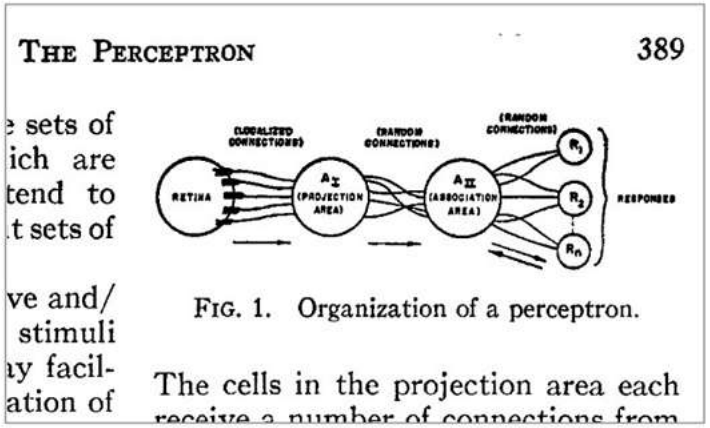

THE PERCEPTRON 389

sets of
ich are
tend to
t sets of

ve and/
stimuli
ay facil-
ation of

FIG. 1. Organization of a perceptron.

The cells in the projection area each

- 1958: Perceptron (F. Rosenblatt)

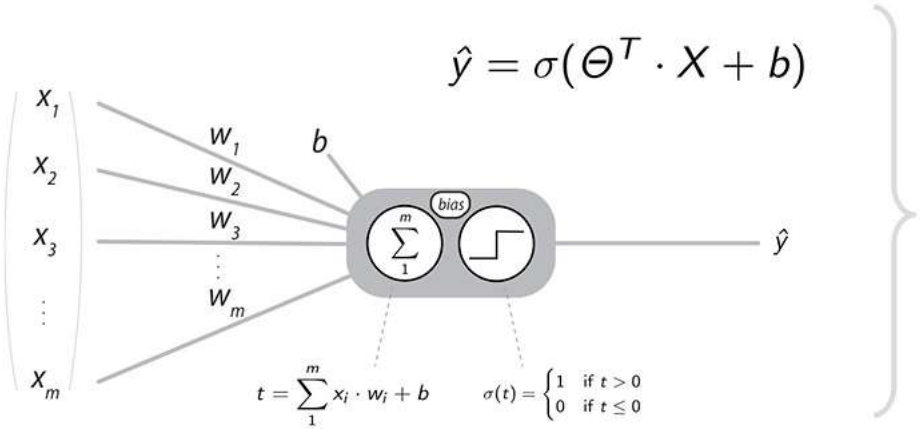

Perceptron
Frank Rosenblatt
1958

Évolution du savoir informatique

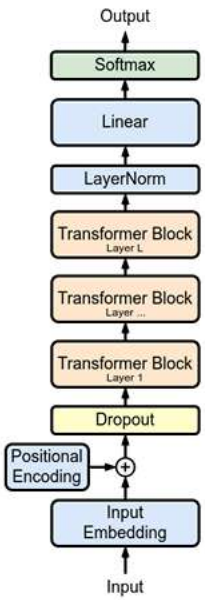

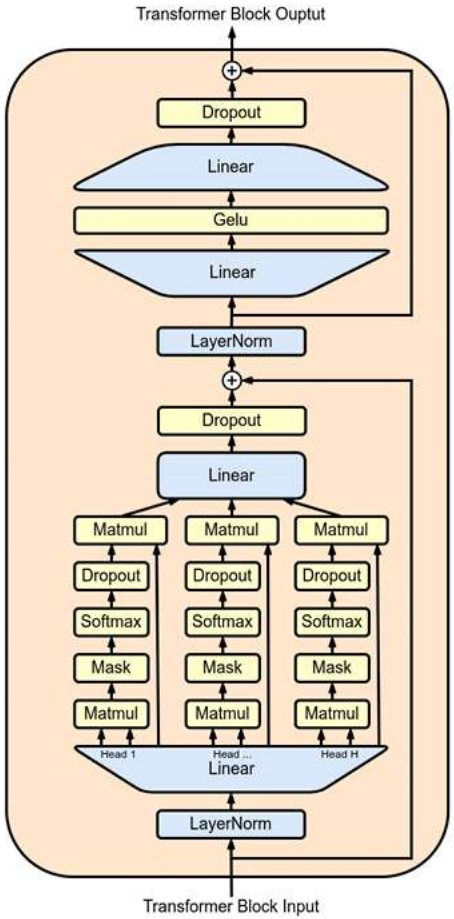

- 1958: Perceptron (F. Rosenblatt)
- 2010: Réseaux de neurones récurrents (Machine Learning)
- 2016: Début de AlphaFold (Deep Learning)
- 2020: Présentation de GPT-3
- 2021: Présentation de AlphaFold2, RoseTTAFold,
- 2022: Présentation de GPT-3.5, ColabFold
- 2023: Présentation de GPT-4, LLaMA, Whisper, etc
- 2024: Présentation de GPT-4o, LLaMA 3, Claude, etc

GPT : **G**enerative **P**re-trained **T**ransformers

KUNGL. VETENSKAPS-AKADEMIEN
THE ROYAL SWEDISH ACADEMY OF SCIENCES

THE NOBEL PRIZE IN CHEMISTRY 2024

POPULAR SCIENCE BACKGROUND

They have revealed proteins' secrets through computing and artificial intelligence

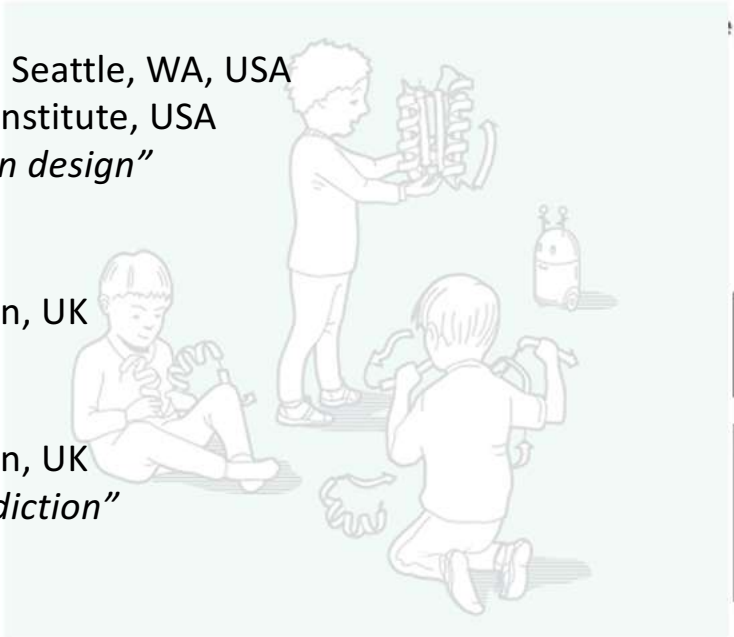

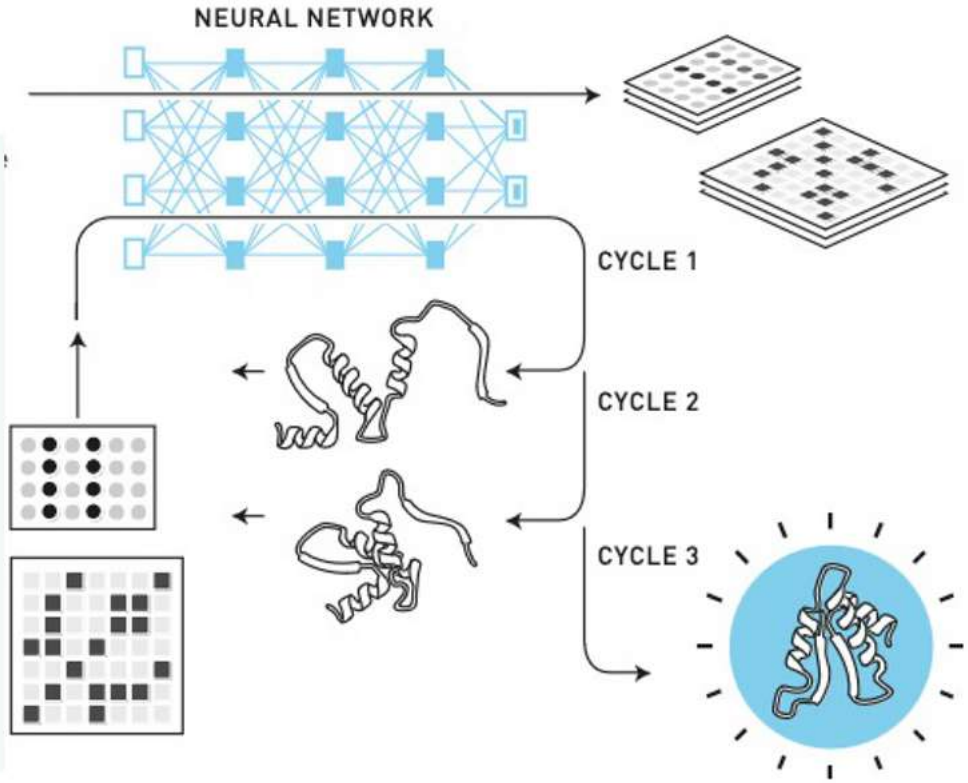

David Baker
University of Washington, Seattle, WA, USA
Howard Hughes Medical Institute, USA
"for computational protein design"

Demis Hassabis
Google DeepMind, London, UK

John M. Jumper
Google DeepMind, London, UK
"for protein structure prediction"

Bioinformatique :

Organiser l’information

Stocker dans les bases de données biologiques

Bases de données en biologie

Les bases de données généralistes

USA : Genbank

créé en 1979 au Los Alamos National Laboratory (GSDB:Gene Sequence DataBase) maintenu par le NCBI (National Center for Biotechnology Information) qui dépend du NIH (National Institute of Health) à Bethesda

Europe : EMBL data library

créé en 1980 à Heidelberg (Allemagne)
financée par l'EMBO (European Molecular Biology Organisation)
maintenue à l'EBI (European Bioinformatics Institute) Cambridge
l'EBI dépend de l'EMBL (European Molecular Biology Laboratory)

Japon

créé en 1984-1987
maintenu par le centre d'information biologique
dépend du NIG (National Institute of Genetics) à Mishima

Formation des bases de données

1 Nomenclature des objets décrits :

Éviter les sources de confusion

2 Annotations :

Donner des informations associées à l'objet,

Créer des liens pertinents avec la source de ces informations,

Attacher à chaque lien un numéro d'identification,

Limiter les risques de propagation des erreurs

3 Formats :

Formats et styles différents

Logiciels propriétaires ou ouverts

NIH National Library of Medicine

PRODUCTS AND SERVICES ▾ RESOURCES FOR YOU ▾ EXPLORE NLM ▾ GRANTS AND RESEARCH ▾

Accelerating Biomedical Discovery and Data-Powered Health

Search NLM

PubMed
Citations for biomedical literature

MedlinePlus
Reliable, up-to-date health information for you

Open-i
An experimental multimedia search engine

MeSH
Medical Subject Headings

ClinicalTrials.gov
A database of clinical studies, worldwide

BLAST
Basic Local Alignment Search Tool

Download

https://www.ncbi.nlm.nih.gov/home/download/

The majority of NCBI data are available for downloading, either directly from the NCBI FTP site or by using software tools to download custom datasets.

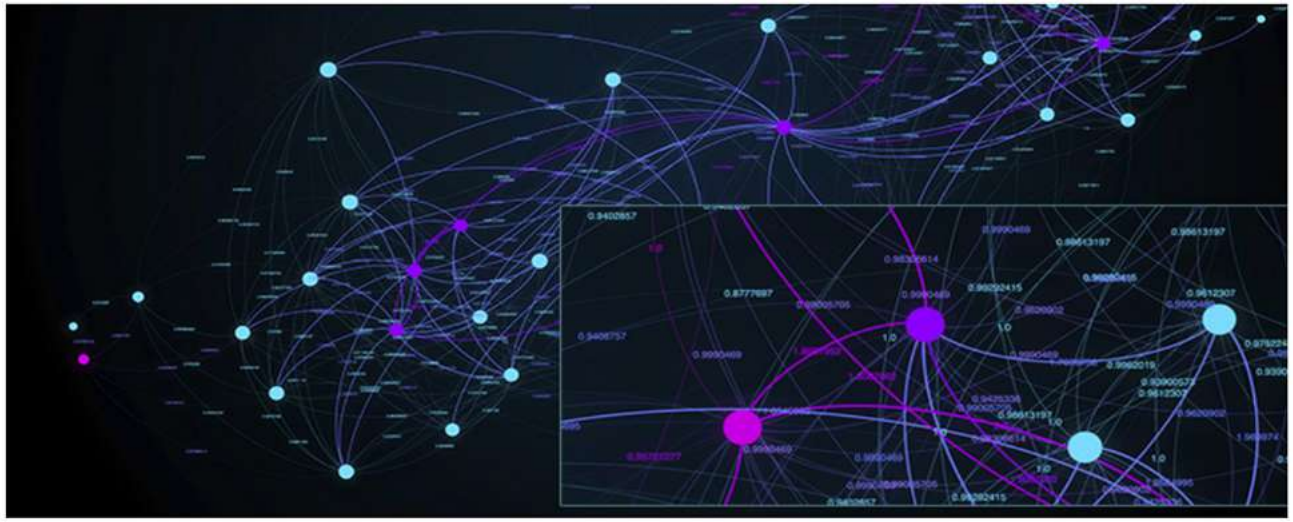

ADDITIONAL LINKS

How to download custom data sets

Large Data Download Best Practices

SRA Download Reference

FTP

Download data from the NCBI FTP site

Aspera

High-speed downloads provided by Aspera software

Download Tools

Tools and APIs for downloading customized datasets

Name	Total size	Content		Last update
	9.97 Pb	34 dirs		
1000genomes	649.11 Tb	1 dir	3 files	2013-02-26 09:43
bigwig	600.94 Gb	10 dirs	1721 files	2014-11-22 13:56
bioproject	1.25 Gb	3 dirs	5 files	2017-11-13 11:10
biosample	533.26 Mb		1 file	2017-11-13 04:32
blast	41.50 Tb	8 dirs	1 file	2016-05-23 17:44
cgap	4.56 Mb	1 dir		2004-09-13 11:14
cn3d	271.23 Mb	1 dir	9 files	2014-10-03 10:22
dbgap	141.74 Gb	11 dirs	2 files	2017-08-20 16:07
entrez	5.30 Gb	10 dirs	6 files	2013-07-18 18:49
epigenomics	223.79 Gb	5 dirs	3 files	2011-10-13 14:22
eqtl	377.45 Gb	2 dirs	2 files	2017-09-19 15:34
fa2htgs	238.93 Mb	3 dirs	1 file	2006-08-04 17:02
genbank	2.33 Tb	11 dirs	2967 files	2017-10-17 18:49
gene	26.10 Gb	3 dirs	1 file	2016-02-12 17:11
genomes	9.24 Tb	437 dirs	4 files	2017-11-07 14:17
geo	82.24 Tb	4 dirs	1 file	2016-07-22 12:39
giab	8.49 Tb	1 dir	3 files	2014-02-05 19:36
hapmap	349.59 Gb	23 dirs	36 files	2011-09-20 10:18
mmdb	19.46 Gb	11 dirs	5 files	2017-10-08 10:49
ncbi-asn1	790.47 Gb	5 dirs	2358 files	2017-10-17 18:53
pathogen	4.47 Tb	6 dirs	2 files	2017-11-12 22:51
pub	96.61 Tb	157 dirs	1 file	2017-09-12 14:53
pubchem	6.39 Tb	10 dirs	1 file	2017-11-12 22:51
pubmed	58.60 Gb	2 dirs	24 files	2017-06-21 11:22

EMBL's European Bioinformatics Institute

EMBL-EBI

Unleashing the potential of big data in biology

Find a gene, protein or chemical | All | Search

Example searches: blast keratin bfl1 | About EBI Search

Find data resources | Submit data | Explore our research | Train with us

Explore all our data resources and tools

Our full range of data resources and data analysis tools are essential for supporting life science research.

Featured data resources

AlphaFold DB

Database for protein structure predictions for numerous species

CC-BY

BioModels

A repository of peer-reviewed, published, computational models.

Web API | CC0

ChEMBL

An open data resource of binding, functional and ADMET bioactivity data.

Web API | CC-BY

Featured tools

Clustal Omega

Multiple sequence alignment of DNA or protein sequences. Clustal Omega replaces the older ClustalW alignment tools.

Web API

HMMER

Fast sensitive protein homology searches using profile hidden Markov models (HMMs) for querying against both sequence and HMM target databases.

Web API

Annotation Platform

Consolidating text-mined and curated annotations

Web API

Le stockage

À chaque séquence correspond une entrée (*entry*)

entrée

- **Informations permettant l'identification**
- **+**
- **Annotations (caractéristiques et propriétés biologiques)**
- **+**
- **Séquence**

INSDC

About Policy Advisors Submitting Standards News & Announcements Documents

```
The DDBJ/ENA/GenBank
Feature Table
Definition
Version 11.2 February 2024


DNA Data Bank of Japan, Mishima, Japan.
EMBL-EBI, European Nucleotide Archive, Cambridge, UK.
GenBank, NCBI, Bethesda, MD, USA.
```

NCBI

ENA European Nucleotide Archive

DDBJ

http://www.insdc.org/documents/feature_table.html

Nomenclature et conventions

ADN

ARN

Protéines

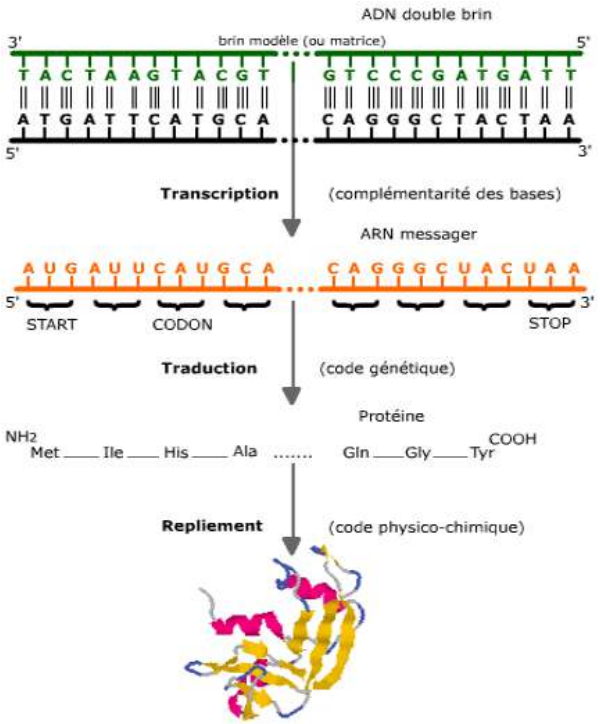

alphabet

ATGC

AUGC

ACDEFGHIKL MNPQRSTVWY [Ala->A]

Nomenclature et conventions

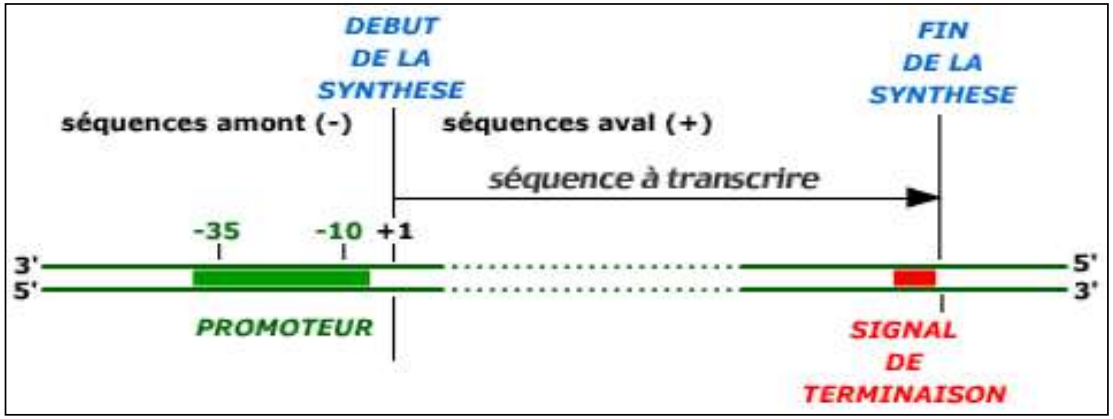

Promoteur	<1..9
ARNpm	10 .. 1320
Exon (1)	10 .. 567
Intron (1)	568 .. 788
Exon (2)	789 .. 1320
polyA	1310 .. 1317
CDS	join(54 .. 567, 789 .. 1254)

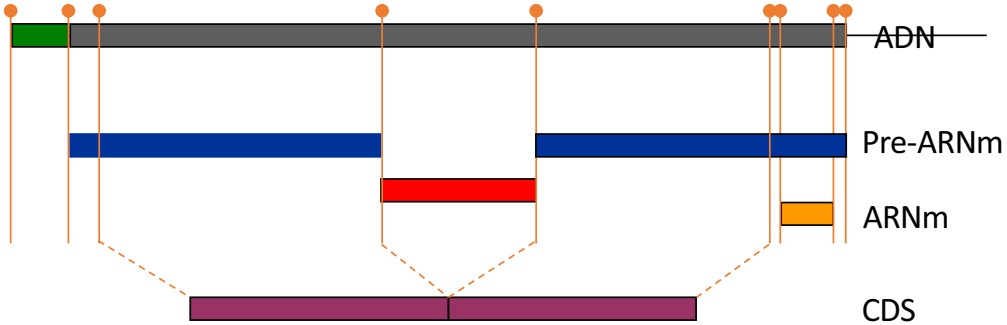

Nomenclature et conventions

a a: adenine
c c: cytosine
g g: guanine
t t: thymine in DNA; uracil in RNA

Nomenclature Committee of the International Union of Biochemistry

https://iubmb.org/about/committees/biochemical-nomenclature-committees/

Cornish-Bowden,
A. Nucl Acid Res 13, 3021-3030 (1985)

Nomenclature et conventions

a	a: adenine
c	c: cytosine
g	g: guanine
t	t: thymine in DNA; uracil in RNA
m	a or c
r	a or g -> purines
w	a or t
s	c or g
y	c or t -> pyrimidines
k	g or t
v	a or c or g not t
h	a or c or t not g
d	a or g or t not c
b	c or g or t not a
n	a or c or g or t

INTERNATIONAL UNION OF BIOCHEMISTRY AND MOLECULAR BIOLOGY

HOME ABOUT ACTIVITIES PUBLICATIONS RESOURCES

Nomenclature Committee of the International Union of Biochemistry

https://iubmb.org/about/committees/biochemical-nomenclature-committees/

Cornish-Bowden,
A. Nucl Acid Res 13, 3021-3030 (1985)

Nomenclature et conventions

L'ARN polymérase :
Sens de synthèse 5'→ 3'

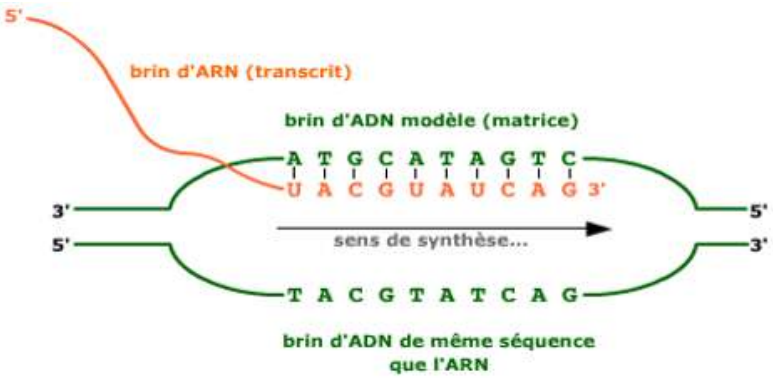

Convention :
Séquence représentée dans les bases

5' -> 3'	3' -> 5'
brin codant	brin matrice
brin sens	brin anti-sens
brin « Watson »	brin « Crick »
+ D direct	- C complémentaire

Nomenclature et conventions

Ala	A	Alanine
Arg	R	Arginine
Asn	N	Asparagine
Asp	D	Aspartic acid (Aspartate)
Cys	C	Cysteine
Gln	Q	Glutamine
Glu	E	Glutamic acid (Glutamate)
Gly	G	Glycine
His	H	Histidine
Ile	I	Isoleucine
Leu	L	Leucine
Lys	K	Lysine
Met	M	Methionine
Phe	F	Phenylalanine
Pro	P	Proline
Ser	S	Serine
Thr	T	Threonine
Trp	W	Tryptophan
Tyr	Y	Tyrosine
Val	V	Valine
Xaa	X	Unknown amino acid
Sec	U	Selenocysteine
Pyl	O	Pyrrolysine
Asx	B	Aspartic acid or Asparagine
Glx	Z	Glutamine or Glutamic acid
Xle	J	Leucine or Isoleucine

Non codés

Nva	Norvaline
Nle	Norleucin
Orn	Ornithine

Les annotations (format NCBI)

Intitulés

Champs

```
LOCUS       NG_000007              81706 bp    DNA     linear   PRI 26-NOV-2015
DEFINITION  Homo sapiens beta globin region (HBB@); and hemoglobin subunit beta
            (HBB); and hemoglobin subunit delta (HBD); and hemoglobin subunit
            epsilon 1 (HBE1); and hemoglobin subunit gamma 1 (HBG1); and
            hemoglobin subunit gamma 2 (HBG2), RefSeqGene on chromosome 11.
ACCESSION   NG_000007
VERSION     NG_000007.3  GI:28380636
KEYWORDS    RefSeq; RefSeqGene.
SOURCE      Homo sapiens (human)
  ORGANISM  Homo sapiens
            Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi;
            Mammalia; Eutheria; Euarchontoglires; Primates; Haplorrhini;
            Catarrhini; Hominidae; Homo.
REFERENCE   1  (bases 1 to 81706)
  AUTHORS   Efstratiadis,A., Posakony,J.W., Maniatis,T., Lawn,R.M.,
            O'Connell,C., Spritz,R.A., DeRiel,J.K., Forget,B.G., Weissman,S.M.,
            Slightom,J.L., Blechl,A.E., Smithies,O., Baralle,F.E.,
            Shoulders,C.C. and Proudfoot,N.J.
  TITLE     The structure and evolution of the human beta-globin gene family
  JOURNAL   Cell 21 (3), 653-668 (1980)
   PUBMED   6985477
COMMENT     REVIEWED REFSEQ: This record has been curated by NCBI staff. The
            reference sequence was derived from AC104389.8.
            This sequence is a reference standard in the RefSeqGene project.
            On Feb 14, 2003 this sequence version replaced gi:18266749.
```

Les annotations

code d'identification

taxonomie

références

commentaires

éléments génomiques: localisation

```
LOCUS       NG_000007              81706 bp    DNA     linear   PRI 26-NOV-2015
DEFINITION  Homo sapiens beta globin region (HBB@); and hemoglobin subunit beta
            (HBB); and hemoglobin subunit delta (HBD); and hemoglobin subunit
            epsilon 1 (HBE1); and hemoglobin subunit gamma 1 (HBG1); and
            hemoglobin subunit gamma 2 (HBG2), RefSeqGene on chromosome 11.
ACCESSION   NG_000007
VERSION     NG_000007.3  GI:28380636
KEYWORDS    RefSeq; RefSeqGene.
SOURCE      Homo sapiens (human)
  ORGANISM  Homo sapiens
            Eukaryota; Metazoa; Chordata; Craniata; Vertebrata; Euteleostomi;
            Mammalia; Eutheria; Euarchontoglires; Primates; Haplorrhini;
            Catarrhini; Hominidae; Homo.
REFERENCE   1  (bases 1 to 81706)
  AUTHORS   Efstratiadis,A., Posakony,J.W., Maniatis,T., Lawn,R.M.,
            O'Connell,C., Spritz,R.A., DeRiel,J.K., Forget,B.G., Weissman,S.M.,
            Slightom,J.L., Blechl,A.E., Smithies,O., Baralle,F.E.,
            Shoulders,C.C. and Proudfoot,N.J.
  TITLE     The structure and evolution of the human beta-globin gene family
  JOURNAL   Cell 21 (3), 653-668 (1980)
   PUBMED   6985477
COMMENT     REVIEWED REFSEQ: This record has been curated by NCBI staff. The
            reference sequence was derived from AC104389.8.
            This sequence is a reference standard in the RefSeqGene project.
            On Feb 14, 2003 this sequence version replaced gi:18266749.
FEATURES             Location/Qualifiers
     source          1..81706
                     /organism="Homo sapiens"
                     /mol_type="genomic DNA"
                     /db_xref="taxon:9606"
                     /chromosome="11"
                     /map="11p15.5"
```

Les annotations

promoteur

gène :

- mRNA

- CDS

protéine

Références croisées

séquence

```
STS             27360..27601
                /standard_name="REN97531"
                /db_xref="UniSTS:422329"
gene            27473..29266
                /gene="HBE1"
                /gene_synonym="HBE"
                /note="hemoglobin subunit epsilon 1"
                /db_xref="GeneID:3046"
                /db_xref="HGNC:HGNC:4830"
                /db_xref="MIM:142100"
mRNA            join(27473..27817,27940..28162,29019..29266)
                /gene="HBE1"
CDS             join(27726..27817,27940..28162,29019..29147)
                /gene="HBE1"
                /gene_synonym="HBE"
                /note="epsilon globin; hemoglobin epsilon chain;
                epsilon-globin; hemoglobin, epsilon 1"
                /codon_start=1
                /product="hemoglobin subunit epsilon"
                /protein_id="NP_005321.1"
                /db_xref="GI:4885393"
                /db_xref="CCDS:CCDS7756.1"
                /db_xref="GeneID:3046"
                /db_xref="HGNC:HGNC:4830"
ORIGIN
        1 ggatcctcac atgagttcag tatataattg taacagaata aaaaatcaat tatgtattca
       61 agttgctagt gtcttaagag gttcacattt ttatctaact gattatcaca aaaatacttc

    81601 aaaaaaaagt tatcctatta aaactgatct cacacatccg tagagccatt atcaagtctt
    81661 tctctttgaa atagacagaa atttagtgtt ttctcagtca gttaac
//
```

Les annotations (EBI | NCBI)

EBI	NCBI	Champs
ID	LOCUS	Nom de la fiche, taille de la séquence, Type de molécule, Division GenBank, Date de modification
DE	DEFINITION	Brève description de la séquence (Nom du gène, de la protéines, de l'organisme
AC	ACCESSION	Identifiant unique, ne change pas même si la séquence change mais peut être remplacé
SV	VERSION	Accession dot version
KW	KEYWORDS	Mots ou phrase décrivant la séquence ou « . » si le champ est vide
OS	SOURCE	
OC	ORGANISM	Préformatage de l'information Classification de l'organisme
		Informations sur les auteurs de la séquence
RA	REFERENCE	
RA	AUTHORS	
RA		
RA		
RA		
RL	TITLE	
RL	JOURNAL	
RL	PUBMED	
CC	COMMENT	

L'identification

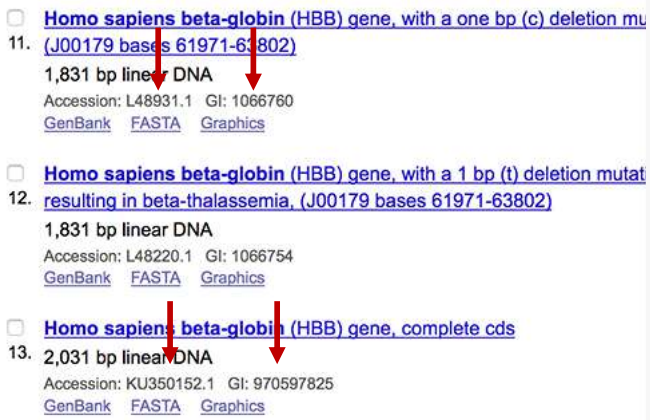

Codes d'identification :

« accession number »

=> Accès à l'information complète

Enregistrement type

Genbank / EMBL / DDBJ :

N12345 ou

NN123456

Exemples :

L48931

KU350152

RefSeq

Principales caractéristiques de la collection RefSeq collection:

- non-redondante
- lien clair entre les séquences nucléotidiques et protéiques
- Mises à jour pour tenir compte des nouveaux savoirs entre séquences et biologie
- validation des données et cohérence du format
- accessions caractérisées par un underscore '_'
- curation continuelle par les membres et collaborateurs du NCBI

L'identification (RefSeq)

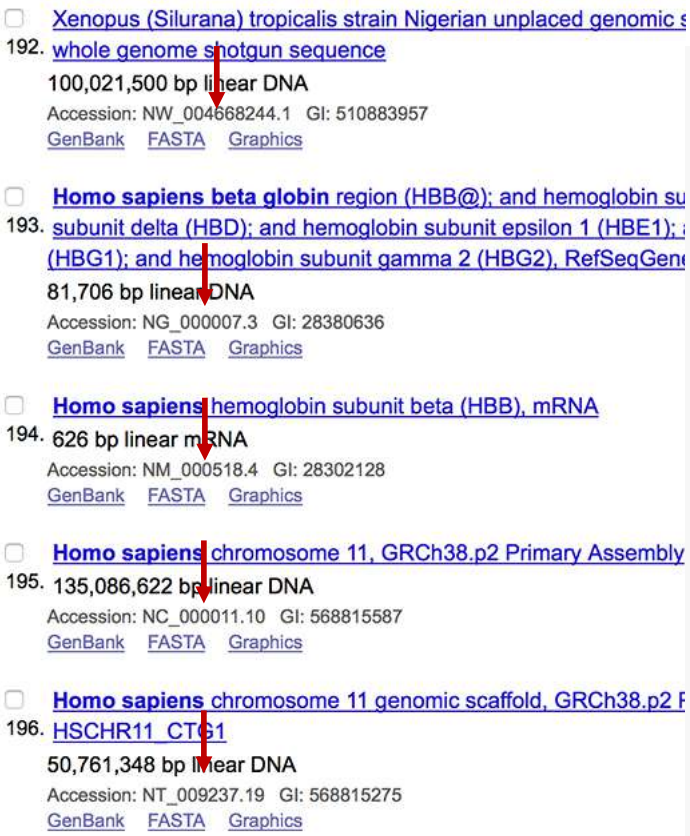

Codes d'identification :

« accession number »

=> Accès à l'information complète

Enregistrement type

RefSeq :

NN_123456 (ou NN_123456789)

Protéine : NP_ ; XP_ ; AP_ ; YP_ ; WP_

ARN : NM_ ; NR_ ; XM_ ; XR_

Génome : NC_ ; NG_ ; NT_ ; NW_ ; NZ_ ; NS_ ; AC_

RefSeq

Accession prefix	Molecule type	Comment
AC_	Genomic	Complete genomic molecule, usually alternate assembly
NC_	Genomic	Complete genomic molecule, usually reference assembly
NG_	Genomic	Incomplete genomic region
NT_	Genomic	Contig or scaffold, clone-based or WGS[a]
NW_	Genomic	Contig or scaffold, primarily WGS[a]
NZ_[b]	Genomic	Complete genomes and unfinished WGS data
NM_	mRNA	Protein-coding transcripts (usually curated)
NR_	RNA	Non-protein-coding transcripts
XM_[c]	mRNA	Predicted model protein-coding transcript
XR_[c]	RNA	Predicted model non-protein-coding transcript
AP_	Protein	Annotated on AC_ alternate assembly
NP_	Protein	Associated with an NM_ or NC_ accession
YP_[c]	Protein	Annotated on genomic molecules without an instantiated transcript record
XP_[c]	Protein	Predicted model, associated with an XM_ accession
WP_	Protein	Non-redundant across multiple strains and species

Les formats

- Les données sont disponibles sous la forme de **fichiers plats (flat files)**
- Chaque entrée est individualisée par un **séparateur** (« **//** »)
- Les données sont structurées selon un **format** propre à chaque banque
- Ce format est décrit dans les « release notes » associées à chaque distribution

https://www.ncbi.nlm.nih.gov/genbank/samplerecord/

Sample GenBank Record

This page presents an annotated sample GenBank record (accession number **U49845**) in its *GenBank Flat File* format. You can see the corresponding live record for U49845, and see examples of other records that show a range of biological features.

```
LOCUS       SCU49845     5028 bp    DNA             PLN       21-JUN-1999
DEFINITION  Saccharomyces cerevisiae TCP1-beta gene, partial cds, and Axl2p
            (AXL2) and Rev7p (REV7) genes, complete cds.
ACCESSION   U49845
VERSION     U49845.1  GI:1293613
```