CM2 – Nov. 2025

Les alignements de séquences
Principes et usages

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Les alignements de séquences

Pourquoi comparer des objets ?

Une Granny Smith

Qu’est-ce ?

C’est une pomme

Pourquoi comparer des objets ?

C’est une Granny Smith, comment le savez-vous ?

Taille
Forme
Couleur
Fonction

Environ 10 cm de diamètre
Rond
Couleur verte
Fruit

Comparaison à une référence:
Les aliments > les fruits > les pommes > Granny Smith

Pourquoi comparer des objets ?

Qu’est-ce que c’est ?

La réponse n’est pas aussi simple, mais…

Pourquoi comparer des objets ?

Grâce à vos références
Cela ressemble à…

un citron

des mûres

des litchis

Étapes du processus

Donc, pour identifier un objet :

Observation, Description

↓

Comparaison

↓

Tri, Classement, Rangement

Application aux séquences

Alignement de séquences

Manière d’arranger des séquences d’ADN, d’ARN ou de protéines respectivement les unes par rapport aux autres de façon à identifier des régions similaires

Rôle de l’alignement

Une ressemblance peut indiquer :

- ✓ une fonction biologique particulière ou proche,
- ✓ des propriétés de structures communes,
- ✓ une histoire évolutive commune.

Cette ressemblance va permettre :

- ✓ d’identifier des sites fonctionnels (consensus),
- ✓ prédire la ou les fonctions d’une protéine,
- ✓ prédire la structure secondaire (voire tertiaire) d’une protéine,
- ✓ établir une phylogénie.

Alignement de séquences

La méthode la plus intuitive d'alignement est :

l'observation visuelle

- ✓ simple,
- ✓ informative,
- ✓ indique des similarités globales, locales et des répétitions

Méthode des Matrices de Pixels (Dot Plot)

Outil graphique pour la comparaison

Principe :

✓ Les séquences sont étirées le long des axes d'un tableau (matrice)

✓ Place un point à l'intersection colonne-ligne en cas d'identité

➢ **Une similarité entre 2 séquences se traduit par une diagonale**

Dot plot (principe)

Graphe par matrice de pixels

Séquence 1

Séquence 2

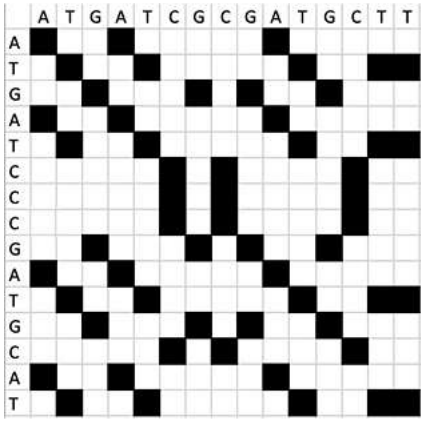

Marquage de toutes les positions identiques

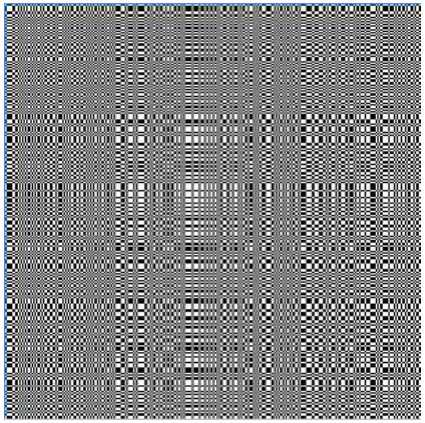

⇨ diagramme bruité

Dot plot (Réalité)

Le filtrage permet la réduction du bruit

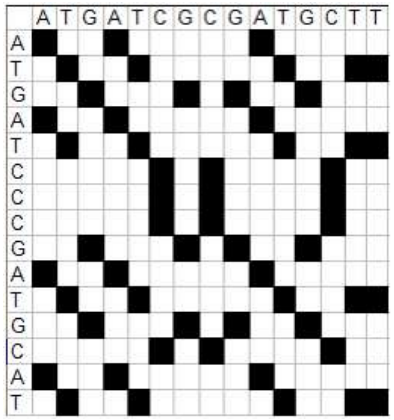

Dotplot non filtré

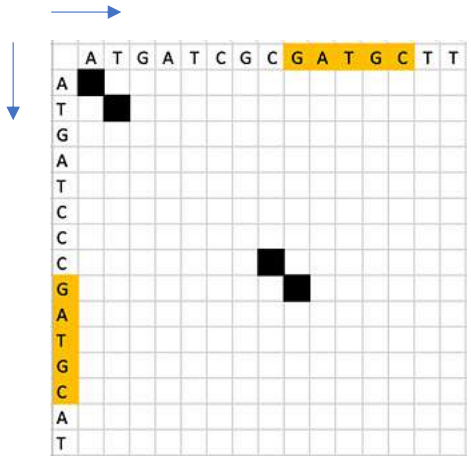

Filtrage **fenêtre de 5 nucléotides**
Critère retenu : au moins 4 positions identiques

Dot plot

Effet du filtrage sur le dotplot d'une séquence par rapport à elle-même

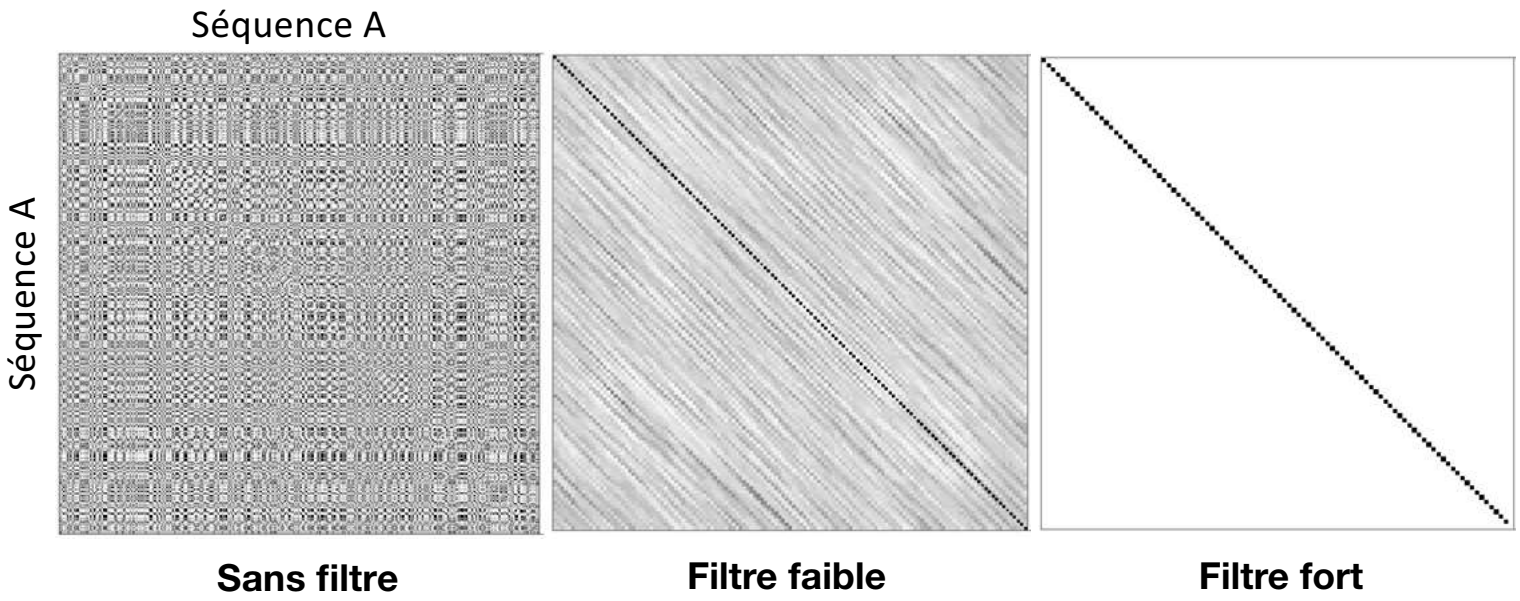

Dot plot – Intérêt

1) Repérer graphiquement les exons et les introns

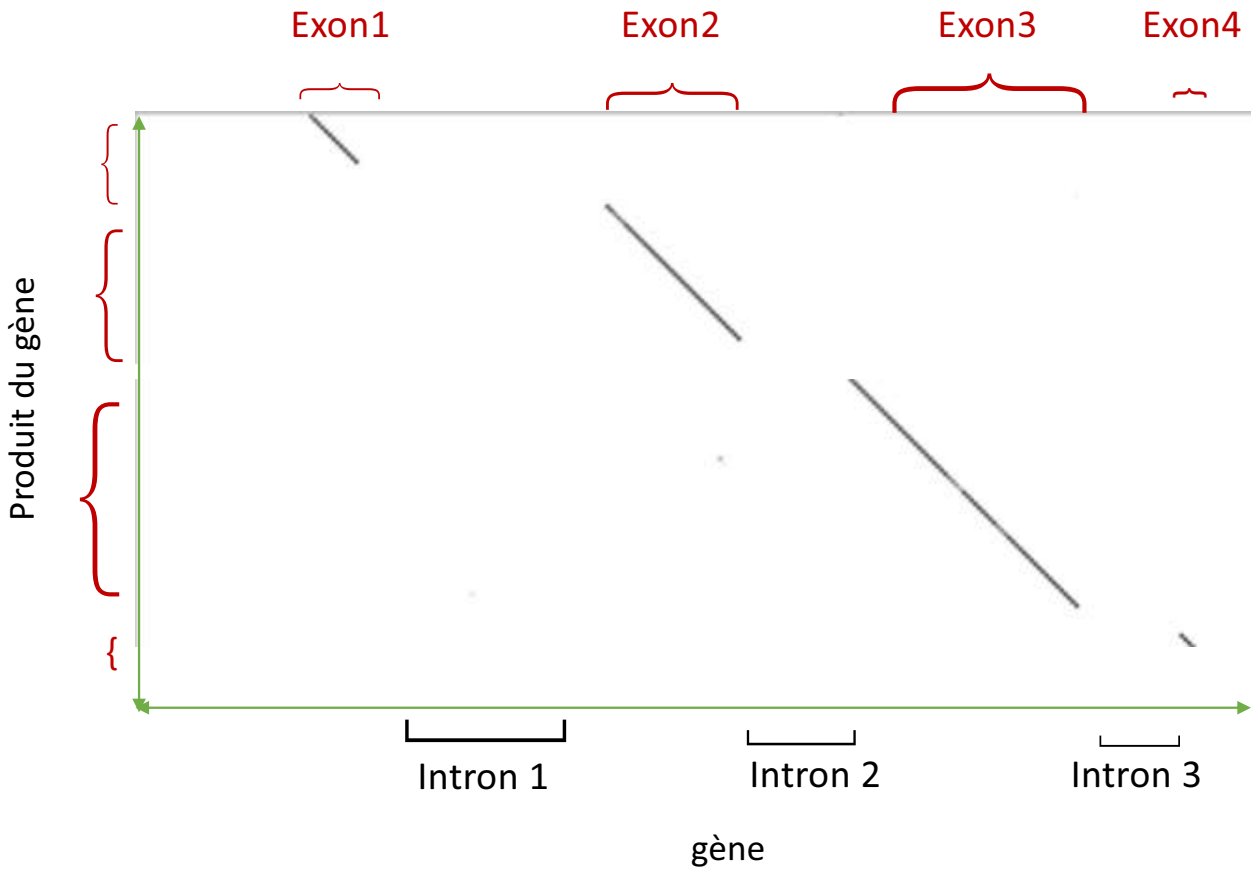

Dot plot – Intérêt

P24014 *Drosophila*

```
MAAPSRTTLMPPPFRLQLRLLILPILLLLRHDAVHAEPYSGGFGSSAVSSGGLGSVGIHIPGGGVGVITEARCPRVCSCT
GLNVDCSHRGLTSVPRKISADVERLELQGNNLTVIYETDFQRLTKLRMLQLTDNQIHTIERNSFQDLVSLERLDISNNVI
TTVGRRVFKGAQSLRSLQLDNNQITCLDEHAFKGLVELEILTLNNNNLTSLPHNIFGGLGRLRALRLSDNPFACDCHLSW
LSRFLRSATRLAPYTRCQSPSQLKGQNVADLHDQEFKCSGLTEHAPMECGAENSCPHPCRCADGIVDCREKSLTSVPVTL
PDDTTDVRLEQNFITELPPKSFSSFRRLRRIDLSNNNISRIAHDALSGLKQLTTLVLYGNKIKDLPSGVFKGLGSLRLLL
LNANEISCIRKDAFRDLHSLSLLSLYDNNIQSLANGTFDAMKSMKTVHLAKNPFICDCNLRWLADYLHKNPIETSGARCE
SPKRMHRRRIESLREEKFKCSWGELRMKLSGECRMDSDCPAMCHCEGTTVDCTGRRLKEIPRDIPLHTTELLLNDNELGR
ISSDGLFGRLPHLVKLELKRNQLTGIEPNAFEGASHIQELQLGENKIKEISNKMFLGLHQLKTLNLYDNQISCVMPGSFE
HLNSLTSLNLASNPFNCNCHLAWFAECVRKKSLNGGAARCGAPSKVRDVQIKDLPHSEFKCSSENSEGCLGDGYCPPSCT
CTGTVVACSRNQLKEIPRGIPAETSELYLESNEIEQIHYERIRHLRSLTRLDLSNNQITILSNYTFANLTKLSTLIISYN
KLQCLQRHALSGLNNLRVVSLHGNRISMLPEGSFEDLKSLTHIALGSNPLYCDCGLKWFSDWIKLDYVEPGIARCAEPEQ
MKDKLILSTPSSSFVCRGRVRNDILAKCNACFEQPCQNQAQCVALPQREYQCLCQPGYHGKHCEFMIDACYGNPCRNNAT
CTVLEEGRFSCQCAPGYTGARCETNIDDCLGEIKCQNNATCIDGVESYKCECQPGFSGEFCDTKIQFCSPEFNPCANGAK
CMDHFTHYSCDCQAGFHGTNCTDNIDDCQNHMCQNGGTCVDGINDYQCRCPDDYTGKYCEGHNMISMMYPQTSPCQNHEC
KHGVCFQPNAQGSDYLCRCHPGYTGKWCEYLTSISFVHNNSFVELEPLRTRPEANVTIVFSSAEQNGILMYDGQDAHLAV
ELFNGRIRVSYDVGNHPVSTMYSFEMVADGKYHAVELLAIKKNFTLRVDRGLARSIINEGSNDYLKLTTPMFLGGLPVDP
AQQAYKNWQIRNLTSFKGCMKEVWINHKLVDFGNAQRQQKITPGCALLEGEQQEEEDDEQDFMDETPHIKEEPVDPCLEN
KCRRGSRCVPNSNARDGYQCKCKHGQRGRYCDQGEGSTEPPTVTAASTCRKEQVREYYTENDCRSRQPLKYAKCVGGCGN
```

Dot plot – Intérêt

2) Mettre en évidence les domaines répétés

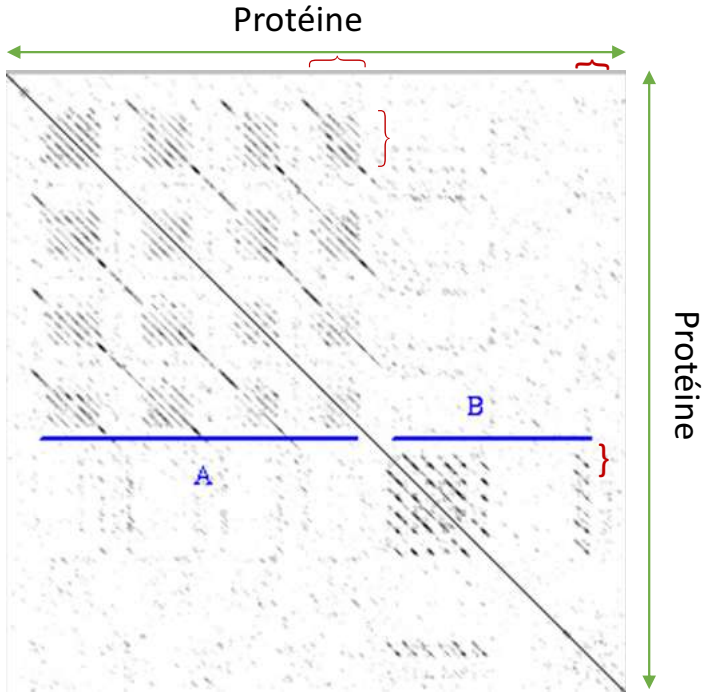

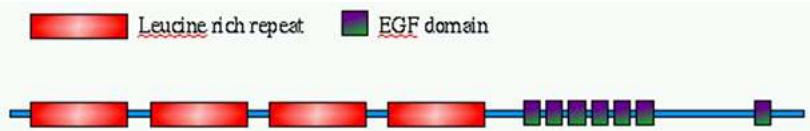

Dot plot – Intérêt

4) Mettre en évidence les terminateurs de traduction (Stem loop dans l'ARNm)

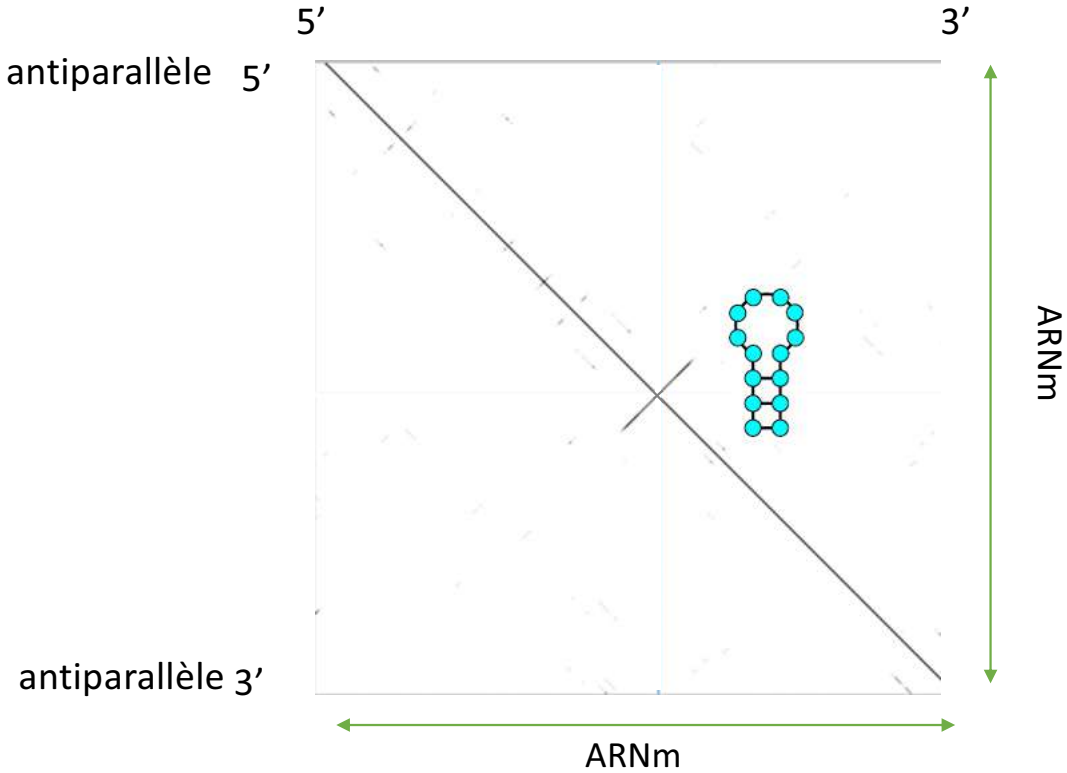

Dot plot – Intérêt

5) AlphaFold (juillet 2021)

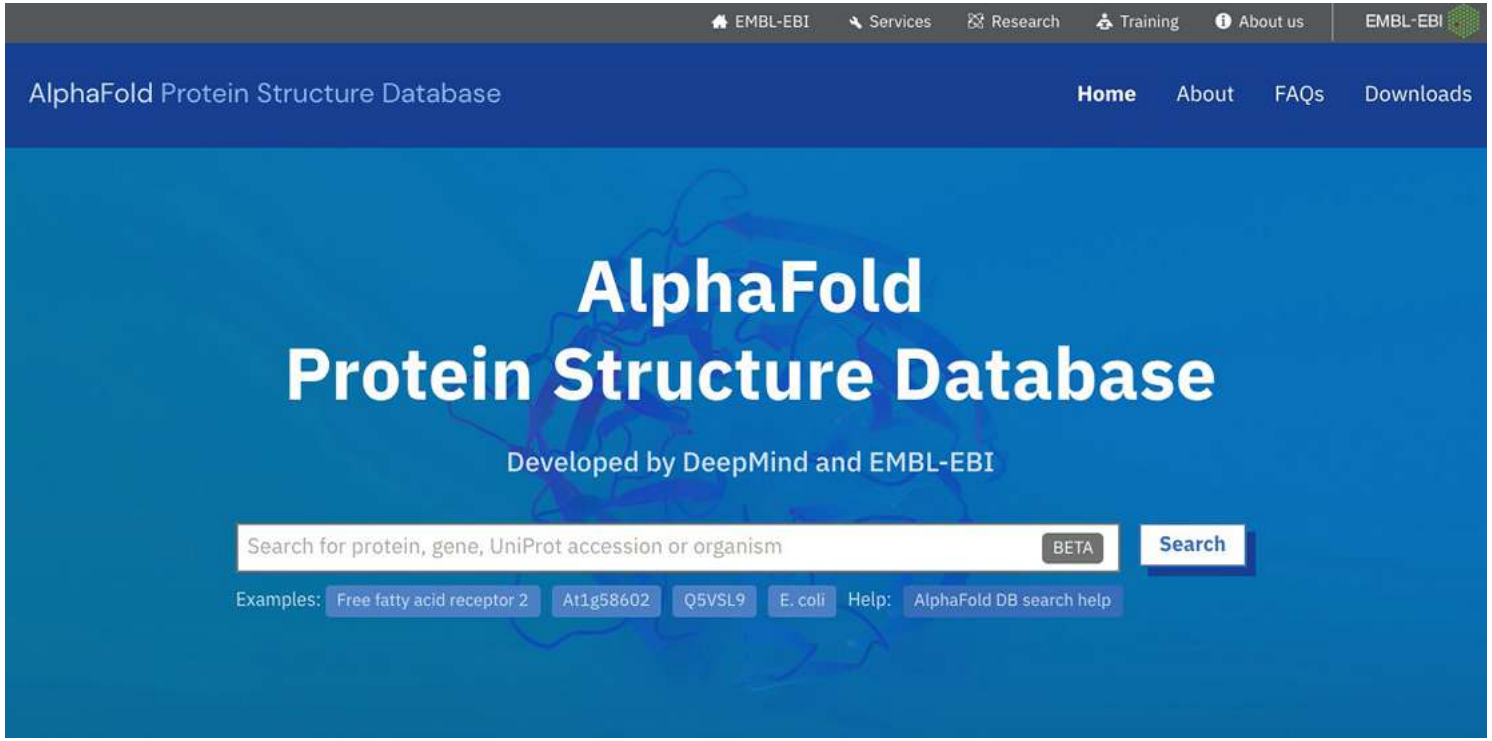

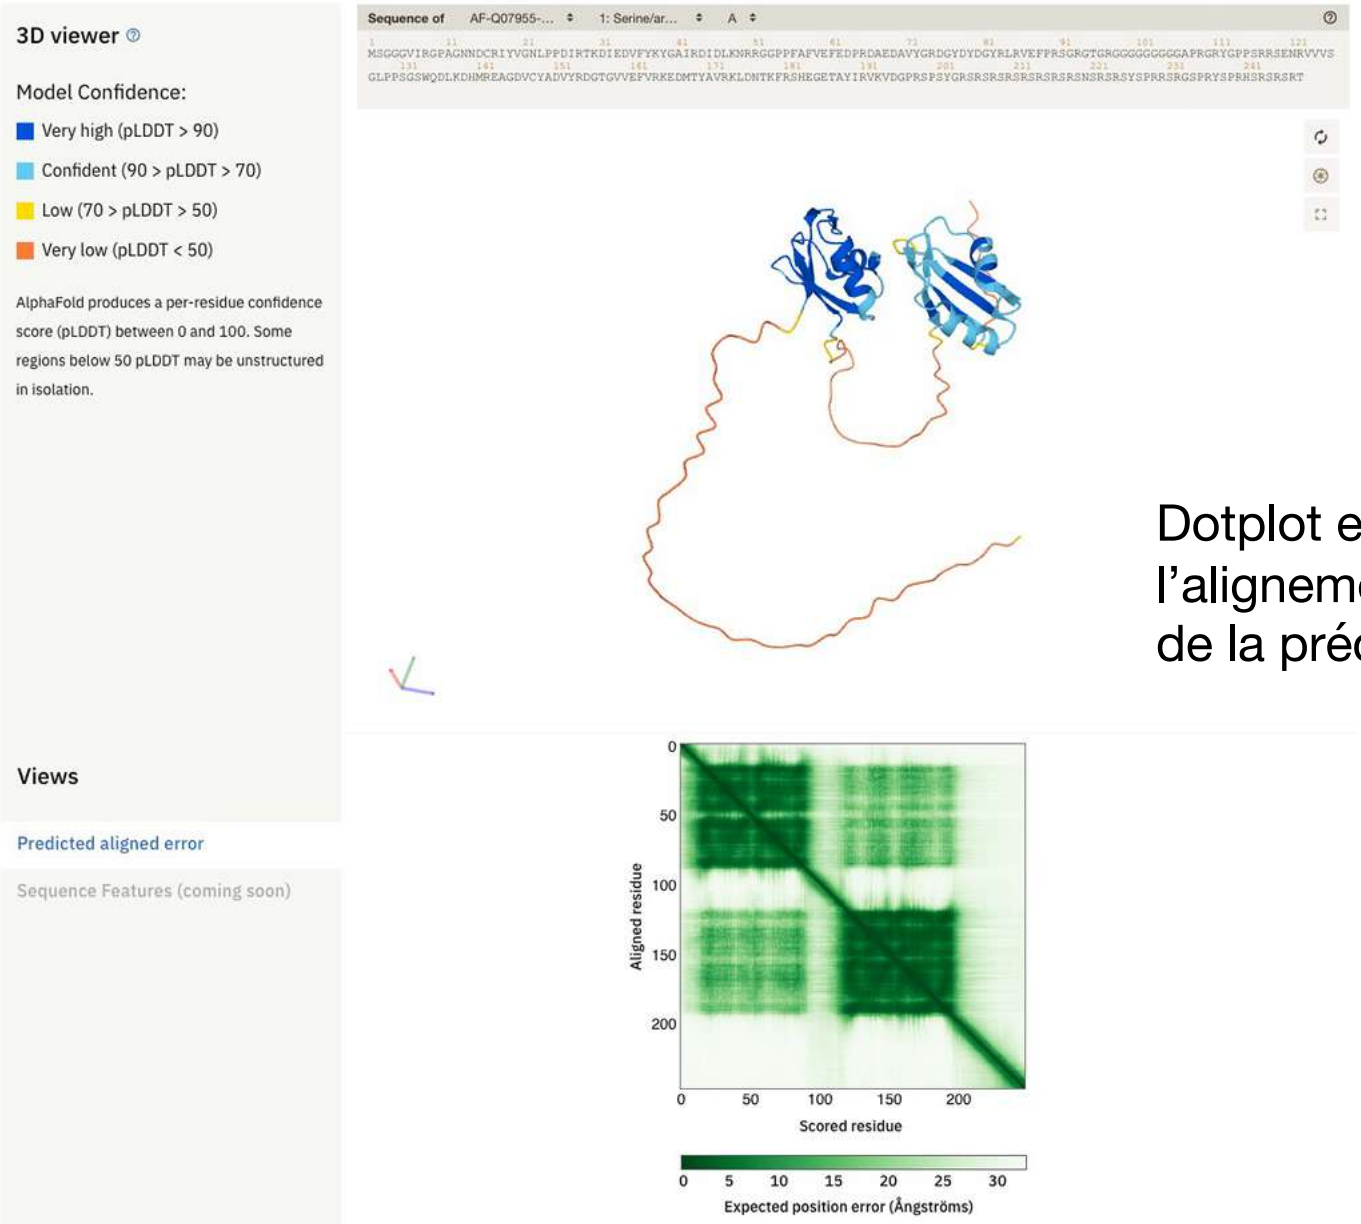

Dotplot entre la position calculée et l'alignement des résidus -> Validation de la prédiction de structure

Dot plot

Avantages :

✓ simple

✓ très informatif

Inconvénients :

✓ interprétation ➢ pas de mesure objective

✓ identification ➢ pas de méthode de détection automatique

➢ Besoin d'une mesure quantititative de similarité

Comment attribuer une valeur ?

Données :

✓ une paire de séquences (ADN ou protéine)

✓ un schéma de score : comment compter ce qui se ressemble ?

Buts :

✓ déterminer le degré de similarité (meilleur score)

✓ montrer cette similarité (meilleur alignement)

Modèle du score

Modélisation d'une matrice de similarité (ou matrice de substitution) :

✓ permet de définir un score de similarité ou de ressemblance entre éléments de séquences,

✓ matrice 4x4 pour les acides nucléiques (4 possibilités),

✓ matrice 20x20 pour les acides aminés (20 possibilités),

✓ elles conservent l'ensemble des scores obtenus lorsqu'on substitue un élément par un autre.

Matrice de pixels

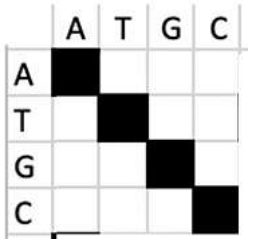

Matrice d'identité

	A	C	G	T
A	1	0	0	0
C	0	1	0	0
G	0	0	1	0
T	0	0	0	1

Identité : N = N
Transition : R < > R, Y < > Y
Transversion : R ≠ Y

Matrice 3 scores

	A	C	G	T
A	I	0	T	0
C	0	I	0	T
G	T	0	I	0
T	0	T	0	I

Calculer un score

Séq 1 : ACTGACGATGCC Séq 2 : AGTCACGATCCT

Alignement forcé:

ACTGACGATGCC
AGTCACGATCCT

Calcul de scores:

1) Matrice d'identité

ACTGACGATGCC
AGTCACGATCCT

	A	C	G	T
A	1	0	0	0
C	0	1	0	0
G	0	0	1	0
T	0	0	0	1

101011111010
= 8

2) Matrice 3 scores (I=3,T=1)

ACTGACGATGCC
AGTCACGATCCT

	A	C	G	T
A	3	0	1	0
C	0	3	0	1
G	1	0	3	0
T	0	1	0	3

303033333031
= 25

Amélioration du modèle : l'InDel ou Gap

Ces matrices ne suffisent pas toujours à définir au mieux la comparaison entre deux séquences

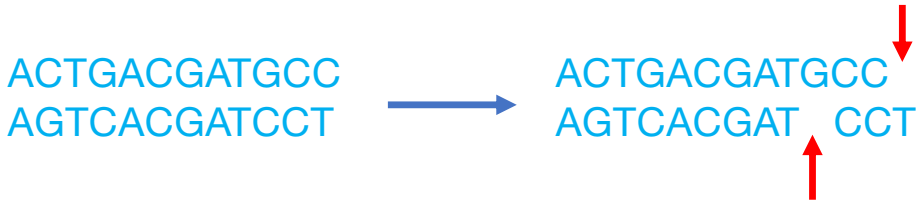

On a donc rapidement ajouté la possibilité de permettre l'insertion ou la délétion d'une ou plusieurs positions afin d'améliorer le score d'une comparaison

Permet de faire ressortir les zones très similaires ou identiques

- **gap (indel)**
- Implique un **score pénalisant**

Le score

$$Score = \sum se - \sum p$$

se : score élémentaire de substitution

p : pénalité d'indel

Le score est donc fonction de :

- ✓ la matrice de similitude utilisée
- ✓ la valeur attribuée aux indels (la pénalité)
- ✓ la longueur de la séquence

Calculer le score (avec une pénalité)

Séq 1 : AGTGACGTCT Séq 2 : AGGAGGTCTC

1) Matrice d'identité

Alignement sans gap :

```
AGTGACGTCT
AGGAGGTCTC
1100000000
= 2
```

2) Matrice 3 scores

```
AGTGACGTCT
AGGAGGTCTC
3301100111
= 11
```

Calcul de scores avec gap :

	A	C	G	T
A	1	0	0	0
C	0	1	0	0
G	0	0	1	0
T	0	0	0	1

```
AGTGACGTCT
AG-GAGGTCTC
11P11011110
```

$= 8 * I - (1 * P)$

$= 3$ ($|P = 5|$)

	A	C	G	T
A	3	0	1	0
C	0	3	0	1
G	1	0	3	0
T	0	1	0	3

```
AGTGACGTCT
AG-GAGGTCTC
33P33033330
```

$= 8 * I - (1 * P)$

$= 19$ ($|P = 5|$)

Alignement de séquences

Deux types d'alignements

Local Alignment

Target Sequence

```
5' ACTACTAGATTACTTACGGATCAGGTACTTTAGAGGCTTGCAACCA 3'
             |||| |||||| |||||||||||||||
Query Sequence 5' TACTCACGGATGAGGTACTTTAGAGGC 3'
```

Global Alignment

Target Sequence

```
5' ACTACTAGATTACTTACGGATCAGGTACTTTAGAGGCTTGCAACCA 3'
   |||||||||||    |||||||  |||||||||||||| |||||||
5' ACTACTAGATT----ACGGATC--GTACTTTAGAGGCTAGCAACCA 3'
```

Query Sequence

Alignement de séquences

Alignement global	Alignement local
Alignement sur la totalité de la séquence	Recherche de régions de haut niveau de similarité
Contient la totalité des 2 séquences	Alignement de parties des deux séquences
Préférable si les 2 séquences sont de tailles équivalentes	Possible avec n'importe quelles séquences, puisqu'il recherche des régions similaires
Utilisé pour comparer des gènes homologues (ex: même gène chez l'humain et la souris) ou des protéines de fonction proche	Utiliser pour rechercher des motifs particuliers dans les génomes ou les protéines
Technique décrite par l'algorithme de Needlemann-Wunsch	Technique décrite par l'algorithme de Smith-Waterman

Comment obtenir le meilleur alignement ?

Modélisation du meilleur alignement

Combien d'alignements possibles pour 2 séquences de longueur n = m = 3 ?

Sans gap : 1

Avec 1 gap
par séquence : 6

Avec 2 gaps
par séquence : 25

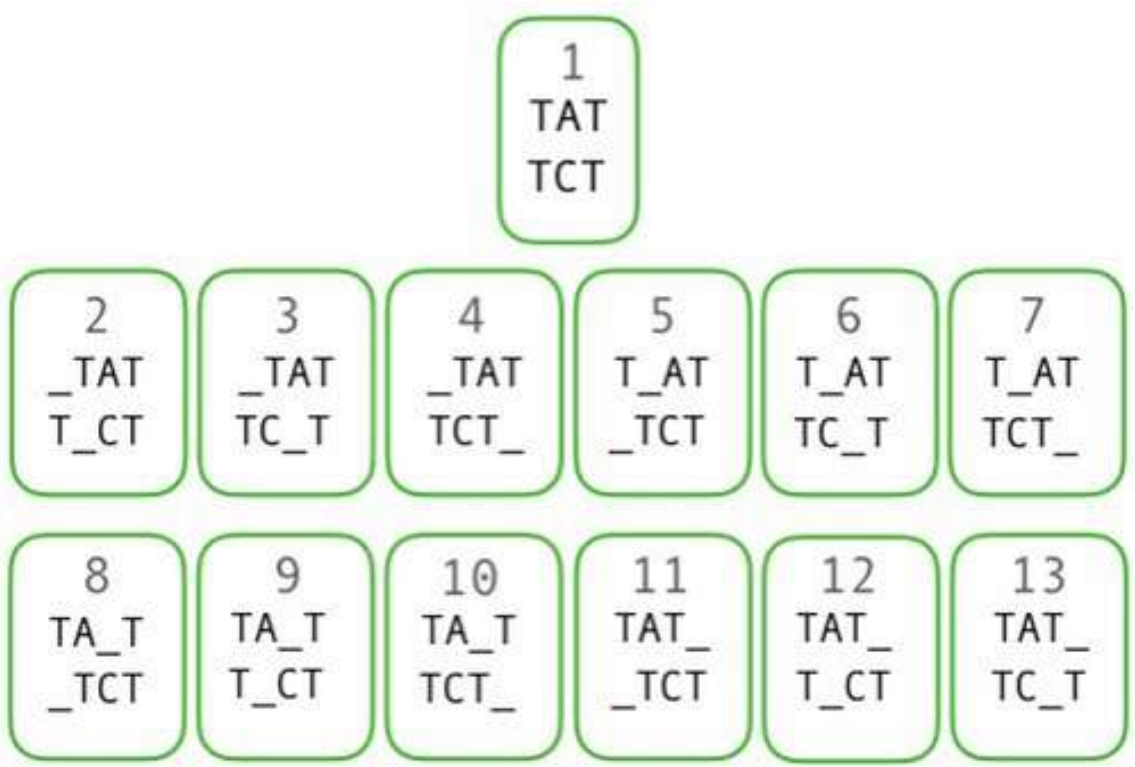

Modélisation du meilleur alignement

Le nombre maximal d'alignements de 2 séquences de longueur m et n se modélise de la manière suivante :

$$\sum_{x=n-m}^{n} = \frac{(x+m)!}{x!\,(x+m-n)!\,(n-x)!}$$

m = n	Nb d'Alignements
3	25
4	63
5	1683
20	2.60×10^{14}
100	$2,05 \times 10^{75}$
500	$1,52 \times 10^{381}$
1000	$6,44 \times 10^{763}$

Modélisation du meilleur alignement

Alignement de 2 séquences de longueur *m et n quand m = n*

$$f(n,n) \sim \frac{(x+m)!}{x!\,(x+m-n)!\,(n-x)!}$$

$$\Rightarrow f(1000,1000) \sim 10^{764}$$

- Nombre d'Avogadro : 10^{24}
  le nombre d'entités élémentaires (atomes, molécules, etc.) dans une mole de matière

- Nombre total d'atomes dans l'univers ≈ 10^{88}

Programmation dynamique (R. Bellman 1950)

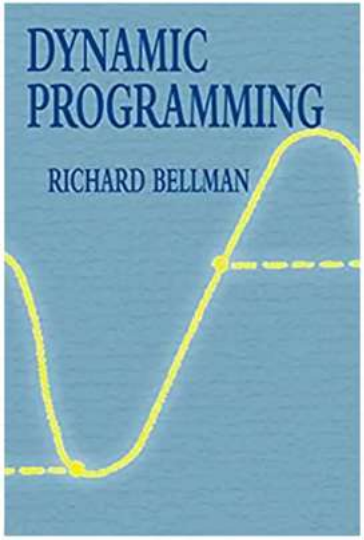

- ✓ Décomposer le problème en sous-problèmes
- ✓ Ne pas calculer 2 fois le même sous-problème

- ✓ Options possibles pour une position d'alignement :

- ✓ Soit on a une identité
- ✓ Soit on déplace horizontalement
- ✓ Soit on déplace verticalement

Programmation dynamique (Bellman 1950)

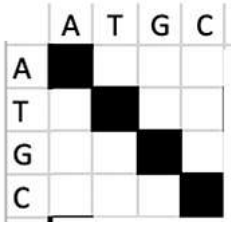

✓ Pour une position donnée :

- ✓Si on a une identité, il faut ajouter la valeur d'identité
- ✓Si on doit créer un gap en H, il faut ajouter la pénalité sur la séquence H
- ✓Si on doit créer un gap en V, il faut ajouter la pénalité sur la séquence V

✓ Cette méthode de calcul (algorithme) développée par Bellman en 1950 est beaucoup plus complexe

✓ En 1970, Saul B. Needleman et Christian D. Wunsch l'adapte pour l'alignement de paires de séquences du début à la fin -> Algorithme d'alignement global

Programmation dynamique

1- Deux séquences A et B

2- Positionnées sur une matrice

3- Sont alignées par application d’un algorithme de calcul

Programmation dynamique

1- Scoring matrix

Contient les 2 séquences à analyser et les valeurs de gap au début de chacune

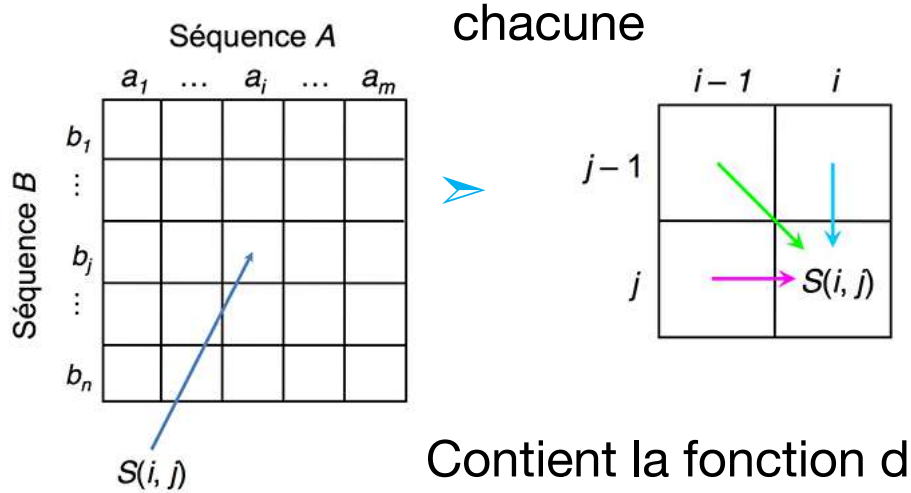

2- Scoring function

Contient la fonction de calcul donnant la valeur d'un match, gap et mismatch

3- Trace matrix

Contient la provenance du meilleur calcul obtenu par la « scoring function »

Mise en application
Needlemann-Wunsch (Alignement global)

Alignement : Seq1 = ABCD Seq2 = ACD

	A	B	C	D
A				
C				
D				

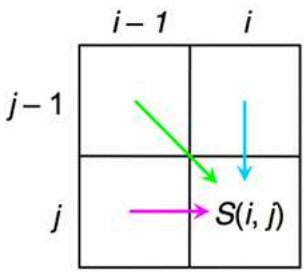

Mise en application
Needlemann-Wunsch (Alignement global)

	A	B	C	D
A				
C				
D				

	A	B	C	D
A				
C				
D				

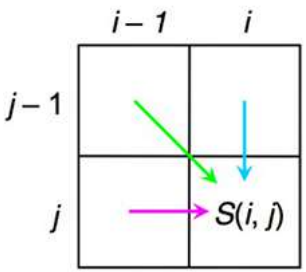

Mise en application
Needlemann-Wunsch (Alignement global)

	A	B	C	D
A				
C				
D				

Scoring matrix = Matrice de score

	A	B	C	D
A				
C				
D				

Trace matrix = Matrice de trajectoire

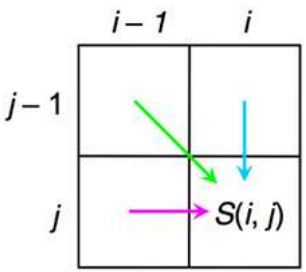

Mise en application
Needlemann-Wunsch (Alignement global)

	A	B	C	D
A				
C				
D				

Scoring matrix = Matrice de score

	A	B	C	D

Trace matrix = Matrice de trajectoire

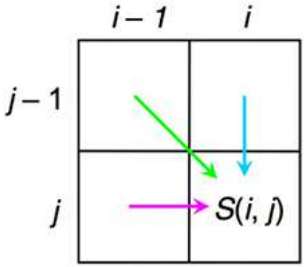

Mise en application
Needlemann-Wunsch (Alignement global)

		A	B	C	D
A					
C					
D					

Scoring matrix = Matrice de score

	A	B	C	D

Trace matrix = Matrice de trajectoire

Mise en application
Needlemann-Wunsch (Alignement global)

pour |P = 10|

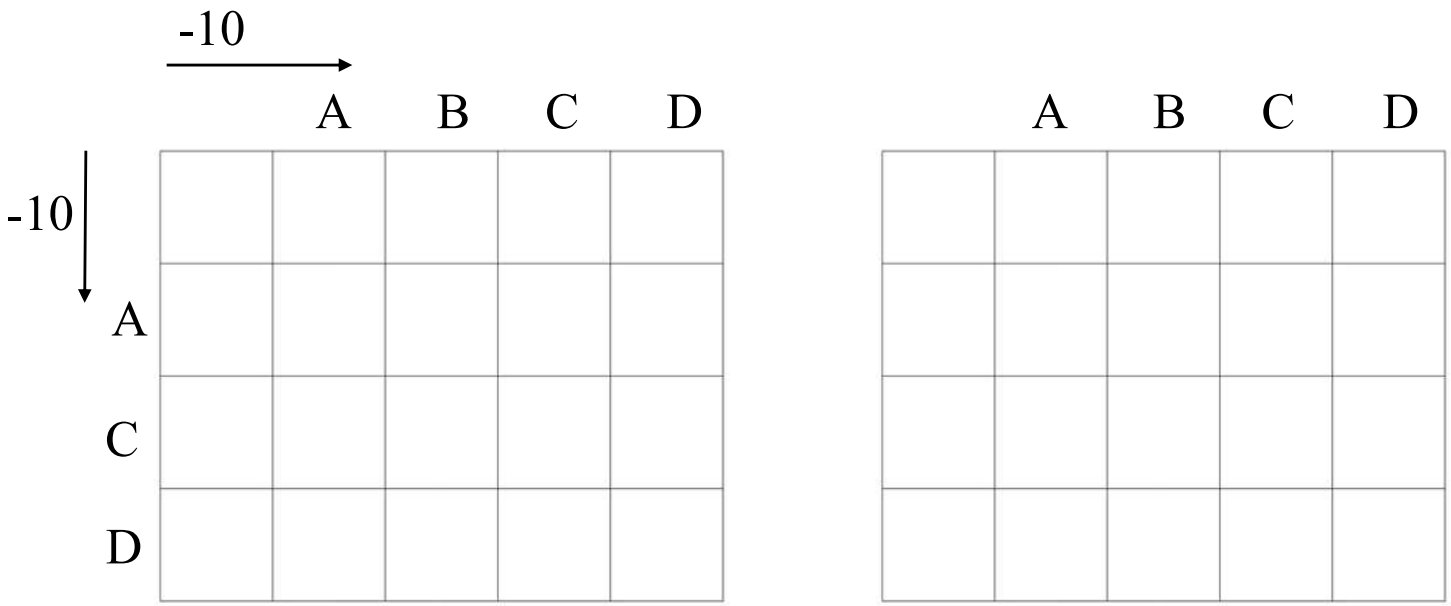

Scoring matrix = Matrice de score Trace matrix = Matrice de trajectoire

Mise en application
Needlemann-Wunsch (Alignement global)

pour P = 10

-10 →

-10 ↓

		A	B	C	D
	0	-10			
A	-10				
C					
D					

Scoring matrix = Matrice de score

	A	B	C	D
fin	G			
H				

Trace matrix = Matrice de trajectoire

1) La 1ère case s'initialise à 0
2) Tout déplacement sur la 1ère ligne ou la 1ère colonne implique la création d'un gap (-Pénalité)

3) La trace des calculs est conservée dans la matrice de trajectoire

Mise en application
Needlemann-Wunsch (Alignement global)

pour P = 10

-10 →

-10 ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10				
C	-20				
D	-30				

Scoring matrix = Matrice de score

	A	B	C	D
fin	G	G	G	G
H				
H				
H				

Trace matrix = Matrice de trajectoire

1) La 1ère case s'initialise à 0
2) Tout déplacement sur la 1ère ligne ou la 1ère colonne implique la création d'un gap (-Pénalité)

3) La trace des calculs est conservée dans la matrice de trajectoire

Mise en application
Needlemann-Wunsch (Alignement global)

pour P = 10

-10 →

-10 ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10				
C	-20				
D	-30				

Scoring matrix = Matrice de score

	A	B	C	D
fin	G	G	G	G
H				
H				
H				

Trace matrix = Matrice de trajectoire

1) La 1ère case s'initialise à 0
2) Tout déplacement sur la 1ère ligne ou la 1ère colonne implique la création d'un gap (-Pénalité)

3) La trace des calculs est conservée dans la matrice de trajectoire

Mise en application
Needlemann-Wunsch (Alignement global)

-10 →

-10 ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10				
C	-20				
D	-30				

	A	B	C	D
fin	G	G	G	G
H				
H				
H				

Scoring function = fonction de score

$$S(i,j) = \max \{S(i-1,j-1)+S_{conv}(i,j),\ S(i-1,j)+p,\ S(i,j-1)+p\}$$

$S_{conv}(i,j)$ = Score dans la matrice de substitution

Mise en application

-10 →

-10 ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10	1	0	0	0
C	-20	0	0	1	0
D	-30	0	0	0	1

	A	B	C	D
fin	G	G	G	G
H				
H				
H				

1) la matrice de conversion basée sur la matrice de substitution définie (ex: la matrice d'identité) est créée

2) l'algorithme est appliqué sur la matrice de conversion, la transformant en 'scoring matrix'

Mise en application

-10 (i) →

-10 (j) ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10	1 $_{1}$	$_{0}$	$_{0}$	$_{0}$
C	-20	$_{0}$	$_{0}$	$_{1}$	$_{0}$
D	-30	$_{0}$	$_{0}$	$_{0}$	$_{1}$

	A	B	C	D
fin	G	G	G	G
H	Diag			
H				
H				

Recalcul de la matrice avec les règles suivantes :

S(i,j) = max {*S*(i-1,j-1)+*S*conv(i,j), *S*(i-1,j)+*p*, *S*(i,j-1)+*p*}

*S*conv(i,j) = Score dans la matrice de substitution

p = pénalité (ici ***p* = -10**)

Mise en application

-10 (i) →

-10 (j) ↓

		A	B	C	D
	0	-10	-20	-30	-40
A	-10	1 $_{1}$	$\boxed{-9 \;_{0}}$	-19 $_{0}$	-29 $_{0}$
C	-20	-9 $_{0}$	1 $_{0}$	-8 $_{1}$	-18 $_{0}$
D	-30	-19 $_{0}$	-9 $_{0}$	1 $_{0}$	-7 $_{1}$

	A	B	C	D
fin	G	G	G	G
H	Diag	G	G	G
H	H	Diag	Diag	G
H	H	H/Diag	Diag	Diag

Cas d'une matrice d'identité

-10 →

-10 ↓

	A	B	C	D
0	-10	-20	-30	-40
A -10	1	0	0	0
C -20	0	0	1	0
D -30	0	0	0	1

Faire les 3 calculs, prendre le max

$S(i-1,j-1)+Sid(i,j) = -10+0 = -10$

$S(i-1,j)+p = 1 -10 = \boxed{-9}$

$S(i,j-1)+p = -20-10 = -30$

Mise en application

Lecture de la dernière case vers la première
Si Diag -> Alignement des 2 séquences
Si G -> Gap sur séquence Gauche
Si H -> Gap sur séquence Haute

		A	B	C	D
	fin	G	G	G	G
A	H	Diag	G	G	G
C	H	H	Diag	Diag	G
D	H	H	H/Diag	Diag	Diag

```
A B C D
A - C D
```

L'alignement se construit donc de droite à gauche

Smith-Watermann (Alignement local)

0 →

0 ↓

		A	A	G	C	A	T	A
	0	0	0	0	0	0	0	0
T	0							
T	0							
G	0							
C	0							
A	0							
A	0							
T	0							

Préparation des matrices

Smith-Watermann (Alignement local)

0 →

0 ↓

		A	A	G	C	A	T	A
	0	0	0	0	0	0	0	0
T	0	0	0	0	0	0	1	0
T	0	0	0	0	0	0	1	0
G	0	0	0	1	0	0	0	0
C	0	0	0	0	1	0	0	0
A	0	1	1	0	0	1	0	1
A	0	1	1	0	0	1	0	1
T	0	0	0	0	0	0	1	0

1) Matrice de conversion

Smith-Watermann (Alignement local)

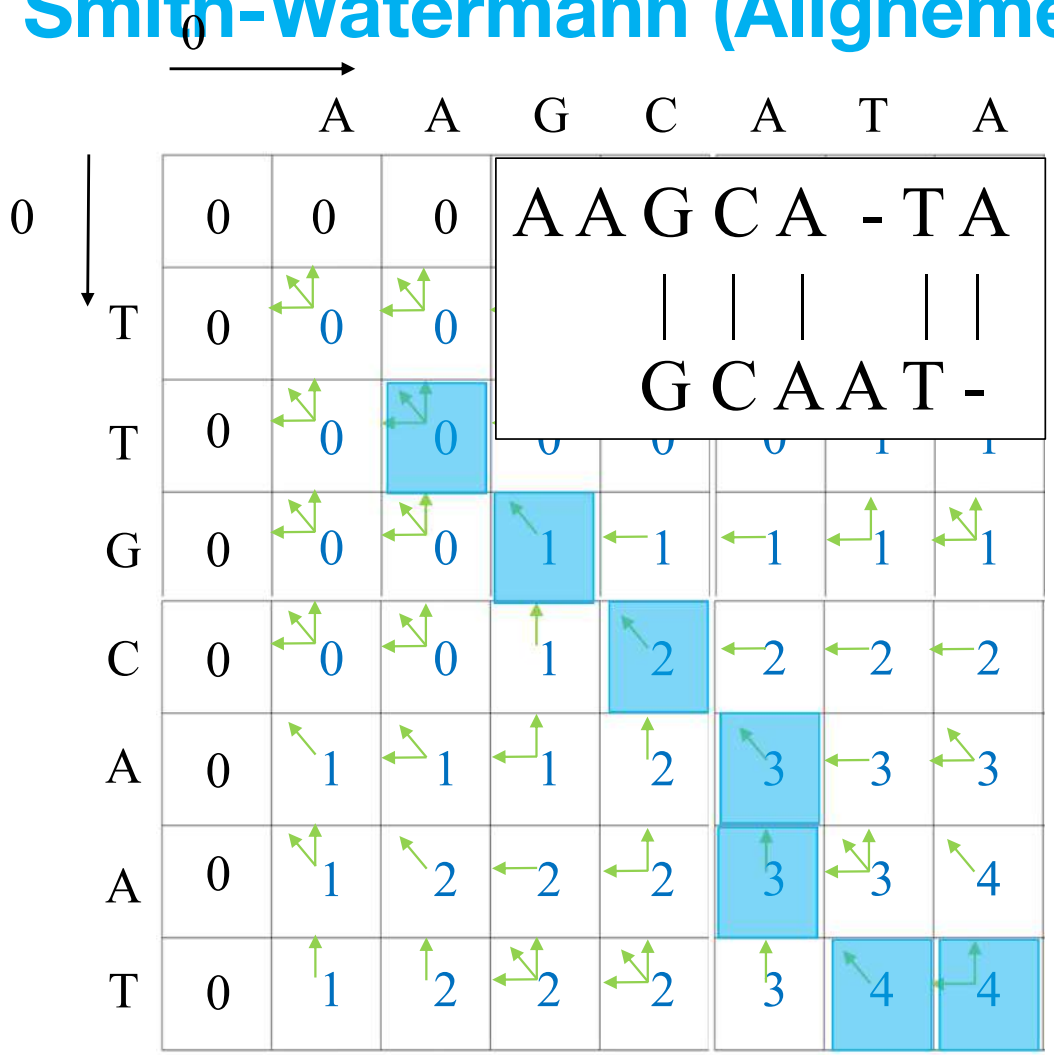

1) Matrice de conversion

2) Matrices de scores

3) Matrice de trajectoire

La lecture des trajectoires se fait en partant de la valeur la plus grande et en suivant les flèches par valeur décroissante jusqu'à 0 ou un bord

Smith-Watermann (Alignement local)

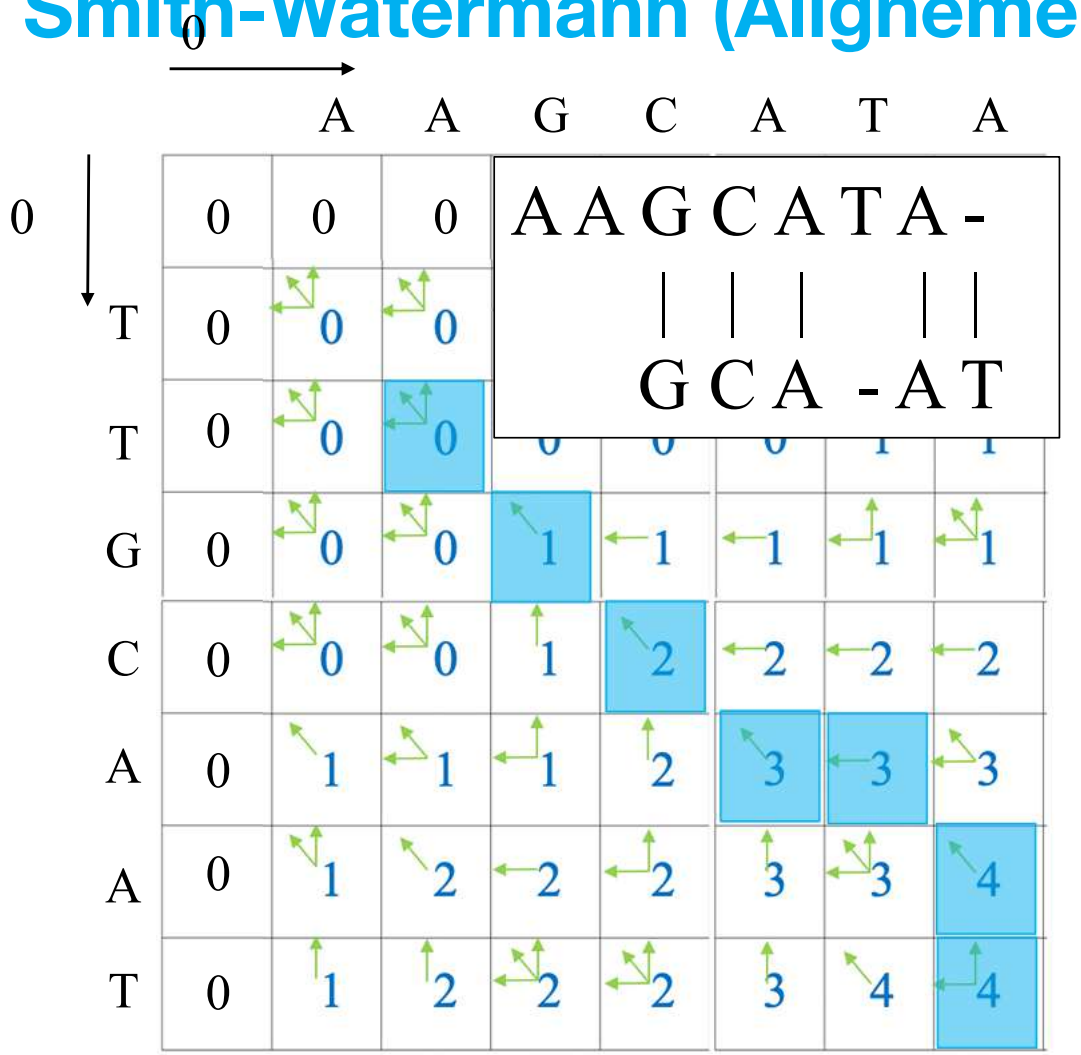

2) Matrices de scores

3) Matrice de trajectoire

La lecture des trajectoires se fait en partant de la valeur la plus grande et en suivant les flèches par valeur décroissante jusqu'à 0 ou un bord

Smith-Watermann (Alignements locaux)

Trajectoire 1

```
A A G C A - T A
    | | |   | |
    G C A A T -
```

Trajectoire 2

```
A A G C A T A -
    | | |   | |
    G C A - A T
```

Trajectoire n

Calculs de score et classement des alignements pour ne proposer que le meilleur

Programmation dynamique

- Calculs simples et rapides

- Meilleur alignement possible entre 2 séquences