CM3 – Nov 2025

BIO 504

Les matrices de substitution

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Comment comptabiliser la similarité ?

La mesure de similarité entre séquences peut reposer sur :

- Le comptage des différences entre elles (*Hamming distance*)
- Le comptage d'indels nécessaires pour les rendre identiques (*Levenshtein distance*)
- Le comptage du pourcentage d'identité
- L'usage d'un système arbitraire de score

Ces méthodes produisent une mesure de la relation entre les séquences, mais aucune ne reflètent le critère biologique qui les lient

Facteurs à prendre en compte

- La séquence primaire est essentielle pour déterminer la structure
- La structure tertiaire va déterminer la fonction
- Cette fonction peut être préservée **malgré des échanges** dans la séquence primaire
- Au contraire **une seule substitution** d'acide aminé peut altérer la fonction

- Donc en observant les mutations possibles, dans des séquences homologues, il est possible de cibler les substitutions d'acides aminés qui **NE PERTURBENT PAS** la fonction

- Un calcul de fréquences d'échange permet alors de construire un système de score pour les échanges d'acides aminés

Acteur clé de l’alignement :

La matrice de substitution

Qu’est-ce qu’une matrice de substitution?

C’est une référence souvent présentée comme un tableau (matrice)

FR	US
Gouvernement	Administration
Raisonnable	Sensible

La similarité entre 2 séquences étant dépendante de leur divergence évolutive au cours du temps, la divergence est donnée sous la forme d’une valeur calculée

Les différentes valeurs sont regroupées dans la matrice de substitution

Comment construire une matrice de substitution ?

BONJOUR

GOOD MORNING

BUONGIORNO

GOEDEMORGEN

BUENOS DÍAS

GUTEN MORGEN

Comment construire une matrice de substitution ?

GOOD MORNING
GUTEN MORGEN
GOEDEMORGEN

BONJOUR
BUONGIORNO
BUENOS DÍAS

Comment construire une matrice de substitution ?

```
G O O D M O R N I N G
G O E D E M O R G E N
G U T E N M O R G E N

B O N J O U R
B U O N G I O R N O
B U E N O S D I A S
```

Comment construire une matrice de substitution ?

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N

B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S
```

Comment construire une matrice de substitution ?

G, D/T, OR, N

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N
```

B, N

```
B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S
```

Positions clés

La pondération des positions clés sera un moyen de discriminer les deux groupes

Comment construire une matrice de substitution ?

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N
```

```
B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S
```

Comment construire une matrice de substitution ?

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N

B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S
```

⬇⬇⬇

MODÉLISATION

Comment construire une matrice de substitution ?

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N

B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S
```

1) God morgon ?
2) God natt ?
3) Bom dia ?
4) Hyvää huomenta ?

Comment construire une matrice de substitution ?

```
G O O D - - M O R N I N G
G O E D E - M O R G E N
G U - T E N M O R G E N

B - O N J - O U R
B U O N G I O R N O
B U E N O S D I A S


G O D M O R G O N
G O D N A T T
B O M D I A
H Y V Ä Ä H U O M E N T A
```

Comment construire une matrice de substitution ?

G O O D - - M O R N I N G

G O E D E - M O R G E N

G U - T E N M O R G E N

G O - D - - M O R G O N

G O - D - - - - - - - - N A T T

B - O N J - O U R

B U O N G I O R N O

B U E N O S D I A S

B - O M - - D I A

H Y V Ä Ä H U O M E N T A

Comment construire une matrice de substitution ?

G O O D - - M O R N I N G

G O E D E - M O R G E N

G U - T E N M O R G E N

G O - D - - M O R G O N

G O - D - - - - - - - - N A T T (Suédois - langues germaniques)

B - O N J - O U R

B U O N G I O R N O

B U E N O S D I A S

B - O M - - D I A (Portugais - langues romanes)

H Y V Ä Ä H U O M E N T A (Finnois - langues ouraliennes)

Comment construire une matrice de substitution ?

G O O D - - M O R N I N G

G O E D E - M O R G E N

G U - T E N M O R G E N

G O - D - - M O R G O N

B - O N J - O U R

B U O N G I O R N O

B U E N O S D I A S

B - O M - - D I A

H Y V Ä Ä H U O M E N T A

A L E I R Y L R D

A L E I N Y L R D

A Q E I N Y Q R D

Temps (évolution)

Calcul de probabilités : $p_a p_l p_e .. p_n ... p_q$ …

Les matrices modèles

Les matrices d'acides nucléiques :

- ✓ Modèle le plus simple : matrice d'identité,
- ✓ Modèle plus élaboré : matrice 3 scores

Matrice d'identité

	A	C	G	T
A	1	0	0	0
C	0	1	0	0
G	0	0	1	0
T	0	0	0	1

Matrice 3 scores

	A	C	G	T
A	3	0	1	0
C	0	3	0	1
G	1	0	3	0
T	0	1	0	3

Identité : N = N : 3
Transition : R < > R, Y < > Y : 1
Transversion : R < > Y : 0

Les matrices modèles

Cas des matrices protéiques de similitude :

✓ La matrice d'identité est un mauvais modèle

Ne permet pas d'aligner correctement les séquences légerement divergentes

✓La matrice d'identité ne considère pas que :

- L'échange dans une même famille peut être sans effet
- Il est possible de classer les acides aminés en familles

Modélisation des matrices protéiques

Propriétés physico-chimiques (diagramme de Venn)

Hydrophobic	ILVCAGMFYWHT
Polar	YWHKREODNSP
Small	VCAGDNSTP
Proline	P
Tiny	AGS
Aliphatic	ILV
Aromatic	FYWH
Positive	HKR
Négative	ED
Charged	HKRED

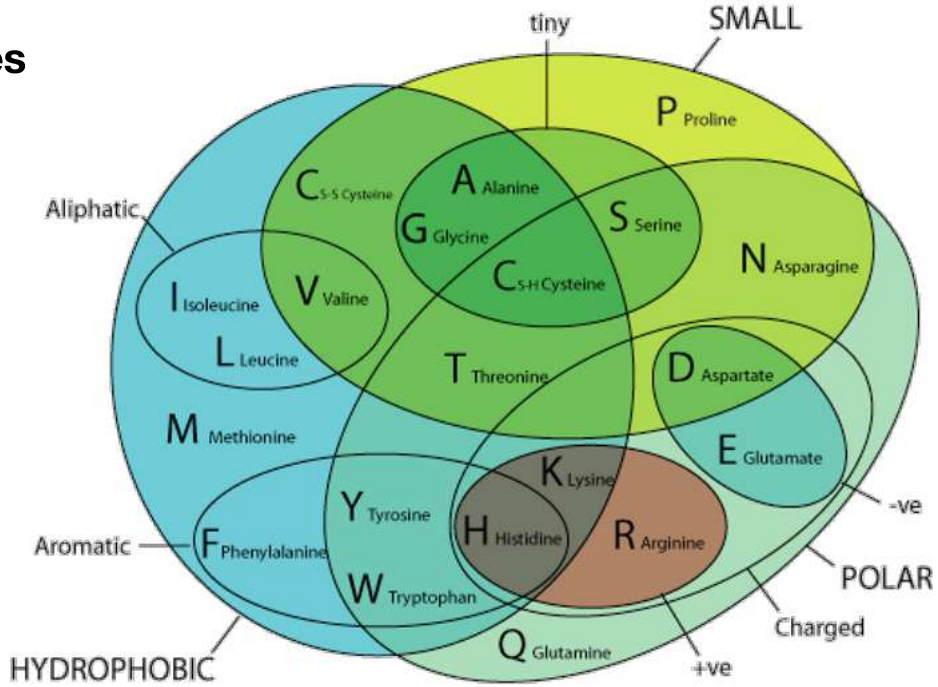

http://www.russelllab.org/aas/

Modélisation : Les matrices log-odds

May the odds be ever in your favor
(Hunger Games, S. Collins, 2009)

Travaux de Margaret Dayhoff (1970), puis des Henikoff (1990) ont produit les matrices de substitution PAM et BLOSUM toujours largement en usage aujourd'hui

q_{ij} : Fréquence de correspondance des résidus *i* et *j* dans les alignements observés

p_i : Probabilité d'apparition du résidu *i (*et idem avec *j)*

D'où on calcule le score pour la paire (*i,j*)

$$S_{i,j} = log(\frac{q_{ij}}{p_i p_j})$$

Modélisation : Les matrices log-odds

(rapport des chances exprimant le degré de dépendance entre des variables aléatoires qualitatives)

Le score de transformation de l'acide aminé *i* en acide aminé *j* est exprimé en scores "log-odds"

(*Logarithm of the odds*)

$$S = \sum_{u} log(\frac{q_{i,j}}{P_i P_j})_u$$

($s_{i,j}$) est la valeur dans la matrice de substitution associée à l'alignement des résidus *i* et *j*

u scanne la totalité des positions de l'alignement

Modélisation : Les matrices log-odds

$$S = \sum_u (s_{i,j})_u$$

$(s_{i,j}) > 0$, l'événement est beaucoup plus probable que calculé
$(s_{i,j}) < 0$, l'événement est beaucoup moins probable que calculé

S est une mesure de la probabilité d'un alignement observé par rapport à un alignement calculé

Cependant un $S > 0$ n'est pas un test suffisant pour la validité de l'alignement

Modélisation : Les matrices de similitudes

- **PAM :** (**P**oint **A**ccepted **M**utation)

Développée dans les années 70 par Margaret Dayhoff

Matrices de quantification de remplacement d'un acide aminé par un autre selon des processus acceptés par la sélection naturelle

Déduites de 71 familles (1572 mutations, séquences similaires à 85%)

La matrice donne le coût ou le gain de transformer *i* en *j* durant une étape d'évolution

La PAM1 correspond ainsi au nombre de substitutions dans le cas où 1% des acides aminés sont changés

C'est la matrice de base pour calculer les autres en considérant que des mutations répétées suivent le même profil que celui décrit par la PAM1
(Dérive de la PAM1 jusqu'à la PAM500)

PAM30, PAM70 et PAM250 : Matrices de mutation standard de Dayhoff

PAM250

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V	B	J	Z	X
A	2	-2	0	0	-2	0	0	1	-1	-1	-2	-1	-1	-3	1	1	1	-6	-3	0	0	-1	0	-1
R	-2	6	0	-1	-4	1	-1	-3	2	-2	-3	3	0	-4	0	0	-1	2	-4	-2	-1	-3	0	-1
N	0	0	2	2	-4	1	1	0	2	-2	-3	1	-2	-3	0	1	0	-4	-2	-2	2	-3	1	-1
D	0	-1	2	4	-5	2	3	1	1	-2	-4	0	-3	-6	-1	0	0	-7	-4	-2	3	-3	3	-1
C	-2	-4	-4	-5	12	-5	-5	-3	-3	-2	-6	-5	-5	-4	-3	0	-2	-8	0	-2	-4	-5	-5	-1
Q	0	1	1	2	-5	4	2	-1	3	-2	-2	1	-1	-5	0	-1	-1	-5	-4	-2	1	-2	3	-1
E	0	-1	1	3	-5	2	4	0	1	-2	-3	0	-2	-5	-1	0	0	-7	-4	-2	3	-3	3	-1
G	1	-3	0	1	-3	-1	0	5	-2	-3	-4	-2	-3	-5	0	1	0	-7	-5	-1	0	-4	0	-1
H	-1	2	2	1	-3	3	1	-2	6	-2	-2	0	-2	-2	0	-1	-1	-3	0	-2	1	-2	2	-1
I	-1	-2	-2	-2	-2	-2	-2	-3	-2	5	2	-2	2	1	-2	-1	0	-5	-1	4	-2	3	-2	-1
L	-2	-3	-3	-4	-6	-2	-3	-4	-2	2	6	-3	4	2	-3	-3	-2	-2	-1	2	-3	5	-3	-1
K	-1	3	1	0	-5	1	0	-2	0	-2	-3	5	0	-5	-1	0	0	-3	-4	-2	1	-3	0	-1
M	-1	0	-2	-3	-5	-1	-2	-3	-2	2	4	0	6	0	-2	-2	-1	-4	-2	2	-2	3	-2	-1
F	-3	-4	-3	-6	-4	-5	-5	-5	-2	1	2	-5	0	9	-5	-3	-3	0	7	-1	-4	2	-5	-1
P	1	0	0	-1	-3	0	-1	0	0	-2	-3	-1	-2	-5	6	1	0	-6	-5	-1	-1	-2	0	-1
S	1	0	1	0	0	-1	0	1	-1	-1	-3	0	-2	-3	1	2	1	-2	-3	-1	0	-2	0	-1
T	1	-1	0	0	-2	-1	0	0	-1	0	-2	0	-1	-3	0	1	3	-5	-3	0	0	-1	-1	-1
W	-6	2	-4	-7	-8	-5	-7	-7	-3	-5	-2	-3	-4	0	-6	-2	-5	17	0	-6	-5	-3	-6	-1
Y	-3	-4	-2	-4	0	-4	-4	-5	0	-1	-1	-4	-2	7	-5	-3	-3	0	10	-2	-3	-1	-4	-1
V	0	-2	-2	-2	-2	-2	-2	-1	-2	4	2	-2	2	-1	-1	-1	0	-6	-2	4	-2	2	-2	-1
B	0	-1	2	3	-4	1	3	0	1	-2	-3	1	-2	-4	-1	0	0	-5	-3	-2	3	-3	2	-1
J	-1	-3	-3	-3	-5	-2	-3	-4	-2	3	5	-3	3	2	-2	-2	-1	-3	-1	2	-3	5	-2	-1
Z	0	0	1	3	-5	3	3	0	2	-2	-3	0	-2	-5	0	0	-1	-6	-4	-2	2	-2	3	-1
X	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1	-1

Matrice 24x24

$$\sum coef(Hist) = -6$$

L'histidine (H) est l'acide aminé le plus mutable

$$\sum coef(Tryp) = -76$$

Le tryptophane (W) est l'acide aminé le moins mutable

PAM250

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	2																			
R	-2	6																		
N	0	0	2																	
D	0	-1	2	4																
C	-2	-4	-4	-5	4															
Q	0	1	1	2	-5	4														
E	0	-1	1	3	-5	2	4													
G	1	-3	0	1	-3	-1	0	5												
H	-1	2	2	1	-3	3	1	-2	6											
I	-1	-2	-2	-2	-2	-2	-2	-3	-2	5										
L	-2	-3	-3	-4	-6	-2	-3	-4	-2	2	6									
K	-1	3	1	0	-5	1	0	-2	0	-2	-3	5								
M	-1	0	-2	-3	-5	-1	-2	-3	-2	2	4	0	6							
F	-4	-4	-4	-6	-4	-5	-5	-5	-2	1	2	-5	0	9						
P	1	0	-1	-1	-3	0	-1	-1	0	-2	-3	-1	-2	-5	6					
S	1	0	1	0	0	-1	0	1	-1	-1	-3	0	-2	-3	1	3				
T	1	-1	0	0	-2	-1	0	0	-1	0	-2	0	-1	-2	0	1	3			
W	-6	2	-4	-7	-8	-5	-7	-7	-3	-5	-2	-3	-4	0	-6	-2	-5	17		
Y	-3	-4	-2	-4	0	-4	-4	-5	0	-1	-1	-4	-2	7	-5	-3	-3	0	10	
V	0	-2	-2	-2	-2	-2	-2	-1	-2	4	2	-2	2	-1	-1	-1	0	-6	-2	4

$S_{i,j} > 0$ Probabilité de remplacement fréquente
$S_{i,j} < 0$ Probabilité de remplacement rare

Modélisation : Les matrices de similitudes

- **BLOSUM :** (**BLO**cks **SU**bstitution **M**atrix)

Développée dans les années 90 par Henikoff

Matrices construites en comparant de multiples alignements de séquences protéiques largement divergentes

Calculée sur la fréquence de substitution de plus de 2000 blocs protéiques

Ces blocs sont supposés être fonctionnellement importants dans les protéines

Les segments de séquences proches dans chaque bloc sont regroupés en cluster pour éviter les biais de calcul

La clustérisation est faite selon des seuils définis comme 62% (BLOSUM62)

Ainsi, on augmente le seuil pour comparer des protéines similaires et on le diminue dans le cas de protéines divergentes

BLOSUM62 : Matrices de référence permettant de détecter des similarités dans des séquences distantes

BLOSUM62

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	4	−1	−2	−2	0	−1	−1	0	−2	−1	−1	−1	−1	−2	−1	1	0	−3	−2	0
R	−1	5	0	−2	−3	1	0	−2	0	−3	−2	2	−1	−3	−2	−1	−1	−3	−2	−3
N	−2	0	6	1	−3	0	0	0	1	−3	−3	0	−2	−3	−2	1	0	−4	−2	−3
D	−2	−2	1	6	−3	0	2	−1	−1	−3	−4	−1	−3	−3	−1	0	−1	−4	−3	−3
C	0	−3	−3	−3	9	−3	−4	−3	−3	−1	−1	−3	−1	−2	−3	−1	−1	−2	−2	−1
Q	−1	1	0	0	−3	5	2	−2	0	−3	−2	1	0	−3	−1	0	−1	−2	−1	−2
E	−1	0	0	2	−4	2	5	−2	0	−3	−3	1	−2	−3	−1	0	−1	−3	−2	−2
G	0	−2	0	−1	−3	−2	−2	6	−2	−4	−4	−2	−3	−3	−2	0	−2	−2	−3	−3
H	−2	0	1	−1	−3	0	0	−2	8	−3	−3	1	−2	−1	−2	−1	−2	−2	2	−3
I	−1	−3	−3	−3	−1	−3	−3	−4	−3	4	2	−3	1	0	−3	−2	−1	−3	−1	3
L	−1	−2	−3	−4	−1	−2	−3	−4	−3	2	4	−2	2	0	−3	−2	−1	−2	−1	1
K	−1	2	0	−1	−3	1	1	−2	−1	−3	−2	5	−1	−3	−1	0	−1	−3	−2	−2
M	−1	−1	−2	−3	−1	0	−2	−3	−2	1	2	−1	5	0	−2	−1	−1	−1	−1	1
F	−2	−3	−3	−3	−2	−3	−3	−3	−1	0	0	−3	0	6	−4	−2	−2	1	3	−1
P	−1	−2	−2	−1	−3	−1	−1	−2	−2	−3	−3	−1	−2	−4	7	−1	−1	−4	−3	−2
S	1	−1	1	0	−1	0	0	0	−1	−2	−2	0	−1	−2	−1	4	1	−3	−2	−2
T	0	−1	0	−1	−1	−1	−1	−2	−2	−1	−1	−1	−1	−2	−1	1	5	−2	−2	0
W	−3	−3	−4	−4	−2	−2	−3	−2	−2	−3	−2	−3	−1	1	−4	−3	−2	11	2	3
Y	−2	−2	−2	−3	−2	−1	−2	−3	2	−1	−1	−2	−1	3	−3	−3	−2	2	7	−1
V	0	−3	−3	−3	−1	−2	−2	−3	−3	3	1	−2	1	−1	−2	−2	0	−3	−1	4

Matrice 20x20

$$\sum coef(Gln) = -11$$

La glutamine (Q) est l'acide aminé le plus mutable

$$\sum coef(Gly) = -42$$

La glycine (G) est l'acide aminé le moins mutable

BLOSUM62

BLOSUM62

	A	R	N	D	C	Q	E	G	H	I	L	K	M	F	P	S	T	W	Y	V
A	4	-1	-2	-2	0	-1	-1	0	-2	-1	-1	-1	-1	-2	-1	1	0	-3	-2	0
R		5	0	-2	-3	1	0	-2	0	-3	-2	2	-1	-3	-2	-1	-1	-3	-2	-3
N			6	1	-3	0	0	0	1	-3	-3	0	-2	-3	-2	1	0	-4	-2	-3
D				6	-3	0	2	-1	-1	-3	-4	-1	-3	-3	-1	0	-1	-4	-3	-3
C					9	-3	-4	-3	-3	-1	-1	-3	-1	-2	-3	-1	-1	-2	-2	-1
Q						5	2	-2	0	-3	-2	1	0	-3	-1	0	-1	-2	-1	-2
E							5	-2	0	-3	-3	1	-2	-3	-1	0	-1	-3	-2	-2
G								6	-2	-4	-4	-2	-3	-3	-2	0	-2	-2	-3	-3
H									8	-3	-3	-1	-2	-1	-2	-1	-2	-2	2	-3
I										4	2	-3	1	0	-3	-2	-1	-3	-1	3
L											4	-2	2	0	-3	-2	-1	-2	-1	1
K												5	-1	-3	-1	0	-1	-3	-2	-2
M													5	0	-2	-1	-1	-1	-1	1
F														6	-4	-2	-2	1	3	-1
P															7	-1	-1	-4	-3	-2
S																4	1	-3	-2	-2
T																	5	-2	-2	0
W																		11	2	-3
Y																			7	-1
V																				4

$S_{i,j} > 0$ Probabilité de remplacement fréquente
$S_{i,j} < 0$ Probabilité de remplacement rare

Choisir une matrice

Divergence

PAM	BLOSUM
PAM100	BLOSUM90
PAM120	BLOSUM80
PAM160	BLOSUM60
PAM200	BLOSUM52
PAM250	BLOSUM45

Pas de matrice parfaite, c'est à l'utilisateur de faire un choix (plus ou moins éclairé)
Elle décrit le taux avec lequel un caractère peut se changer en un autre au cours du temps

Différence entre les PAM et les BLOSUM

✓Les matrices PAM sont basées :

- sur un modèle explicite d'évolution
- sur des mutations observées le long d'alignements globaux de régions très conservées et très riches en mutations
- chaque mutation a le même taux d'apparence
- de ce fait, les matrices de haut nombre (250) sont plus adaptées pour des séquences éloignées

✓Les matrices BLOSUM sont basées :

- sur un modèle implicite d'évolution
- sur des régions très conservées dans des séries d'alignements sans gap
- dans les groupes, les mutations ne sont pas comptabilisées de manière équivalente
- les matrices de haut nombre sont adaptées pour les séquences les plus proches

Research | Open access | Published: 14 September 2020

The ranging of amino acids substitution matrices of various types in accordance with the alignment accuracy criterion

Valery Polyanovsky, Alexander Lifanov, Natalia Esipova & Vladimir Tumanyan

BMC Bioinformatics **21**, Article number: 294 (2020) | Cite this article

3163 Accesses | **5** Citations | Metrics

Abstract

Background

The alignment of character sequences is important in bioinformatics. The quality of this procedure is determined by the substitution matrix and parameters of the insertion-deletion penalty function. These matrices are derived from sequence alignment and thus reflect the evolutionary process. Currently, in addition to evolutionary matrices, a large number of different background matrices have been obtained. To make an optimal choice of the substitution matrix and the penalty parameters, we conducted a numerical experiment using a representative sample of existing matrices of various types and origins.

Les méthodes d’alignement

La méthode graphique : Le **dotplot**

- Simple et qualitatif

Mais :

- Bruit, pas intuitif
- Difficile d’avoir des statistiques et des positions de séquence
- Limité à 2 séquences
- Pas d’automatisation, ni de large échelle

Les méthodes de **programmation dynamique** : L’alignement par paires et l’alignement multiple

- Alignements locaux ou globaux (SW – NW, matrices de substitution, gap)
- Garantie de trouver un alignement optimal pour une méthode de score donnée

Mais :

- Difficile de trouver la bonne méthode de score (processus souvent empirique plutôt que mathématique)
- Possibilité d’aligner plus de 2 séquences ou des séquences très longues au prix d’un temps de calcul pénalisant

CM 4 – Nov 2025

Des alignements

au

BLAST

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Application à l'identification

1) Les informations biologiques sont stockées dans des bases de données

2) On a des méthodes modèles pour comparer les séquences entre elles

→ Appliquons ces méthodes à la recherche de séquences dans les bases de données :

Si j'ai une séquence inconnue X, existe-t-il dans les bases de données une séquence qui peut s'aligner avec X et qui me donnerait une idée de

- sa fonction
- sa structure
- ses partenaires, etc…

Les méthodes d’alignement

La méthode graphique : Le **dotplot**

- Simple et qualitatif

Mais :

- Bruit, pas intuitif
- Difficile d’avoir des statistiques et des positions de séquence
- Limité à 2 séquences
- Pas d’automatisation, ni de large échelle

Les méthodes de **programmation dynamique** : L’alignement par paires et l’alignement multiple

- Alignements locaux ou globaux (SW – NW, matrices de substitution, gap)
- Garantie de trouver un alignement optimal pour une méthode de score donnée

Mais :

- Difficile de trouver la bonne méthode de score (processus souvent empirique plutôt que mathématique)
- Possibilité d’aligner plus de 2 séquences ou des séquences très longues au prix d’un **temps de calcul pénalisant**

Comparaison des temps de calculs

Alignement de 2 sequences de même longueur "**n**"

n	naïve (n^n)	Programmation dynamique (n^2)
5	0.3 ms	2 µs
10	16 min	10 µs
20	300 million années	40 µs
100	3e+173 trillion années	1 ms
1000	?	100 ms
10000	?	9 s

Alignement d'une séquence de long. "**n**" avec GENBANK 0.1 microsec / itération

n	Programmation dynamique (n x 85e+9)
5	11 min
10	23 min
100	4 heures
1000	1.6 jours
10000	16 jours

~20 années CPU pour scanner les 20000 gènes humains

Nécessité d’une autre méthode d’alignements pour la recherche dans les bases

Les **méthodes des mots** ou **k-tuples methods**

Basées sur des méthodes heuristiques permettant de faire des approximations rapides de programmation dynamique

Ne permettent pas d’obtenir la garantie du résultat optimal, mais un **« bon » résultat** dans un **temps raisonnable**

Utilisées pour l’analyse des grandes bases de séquences

Utilisées pour les programmes **FAST-A** et **BLAST**

La méthode des k-tuples

La méthode identifie des séries de « mots » courts dans la séquence « **Query** » qui sont ensuite testés contre les séquences « **Subject** » d'une base de données

FASTA

1 - recherche de 'k-tuplets' identiques
2 - alignement global, ancré sur la région similaire

BLAST

1 - recherche de 'mots' similaires
2 - extension des blocs similaires et alignement local

Programmes d'alignement local de séquences basés sur une **heuristique** :
Un algorithme qui fournit rapidement une solution qui n'est pas forcément optimale

Méthode approximative qui s'oppose aux méthodes exactes (trop lentes)

FASTA

Sequence Similarity Search (SSS)

Job Dispatcher Help & Privacy Your Jobs Protein **Nucleotide**

Feedback

This tool provides sequence similarity searching against protein databases using the FASTA suite of programs. FASTA provides a heuristic search with a protein query. FASTX and FASTY translate a DNA query. Optimal searches are available with SSEARCH (local), GGSEARCH (global) and GLSEARCH (global query, local database).

Databases

(Nucleotide)

Nucleotide DATABASES

Clear selection

95 Database selected

Input sequence

Sequence type

○ Protein ● DNA ○ RNA

Paste your sequence here - or use the e

Browse... No file selected.

Use the example Clear sequence More example inputs

Parameters

MATCH/MISMATCH SCORES	GAP OPEN	GAP EXTEND
+5/-4	-14	-4

KTUP	EXPECTATION UPPER LIMIT	EXPECTATION LOWER LIMIT
6	10	0

Les différentes versions de BLAST

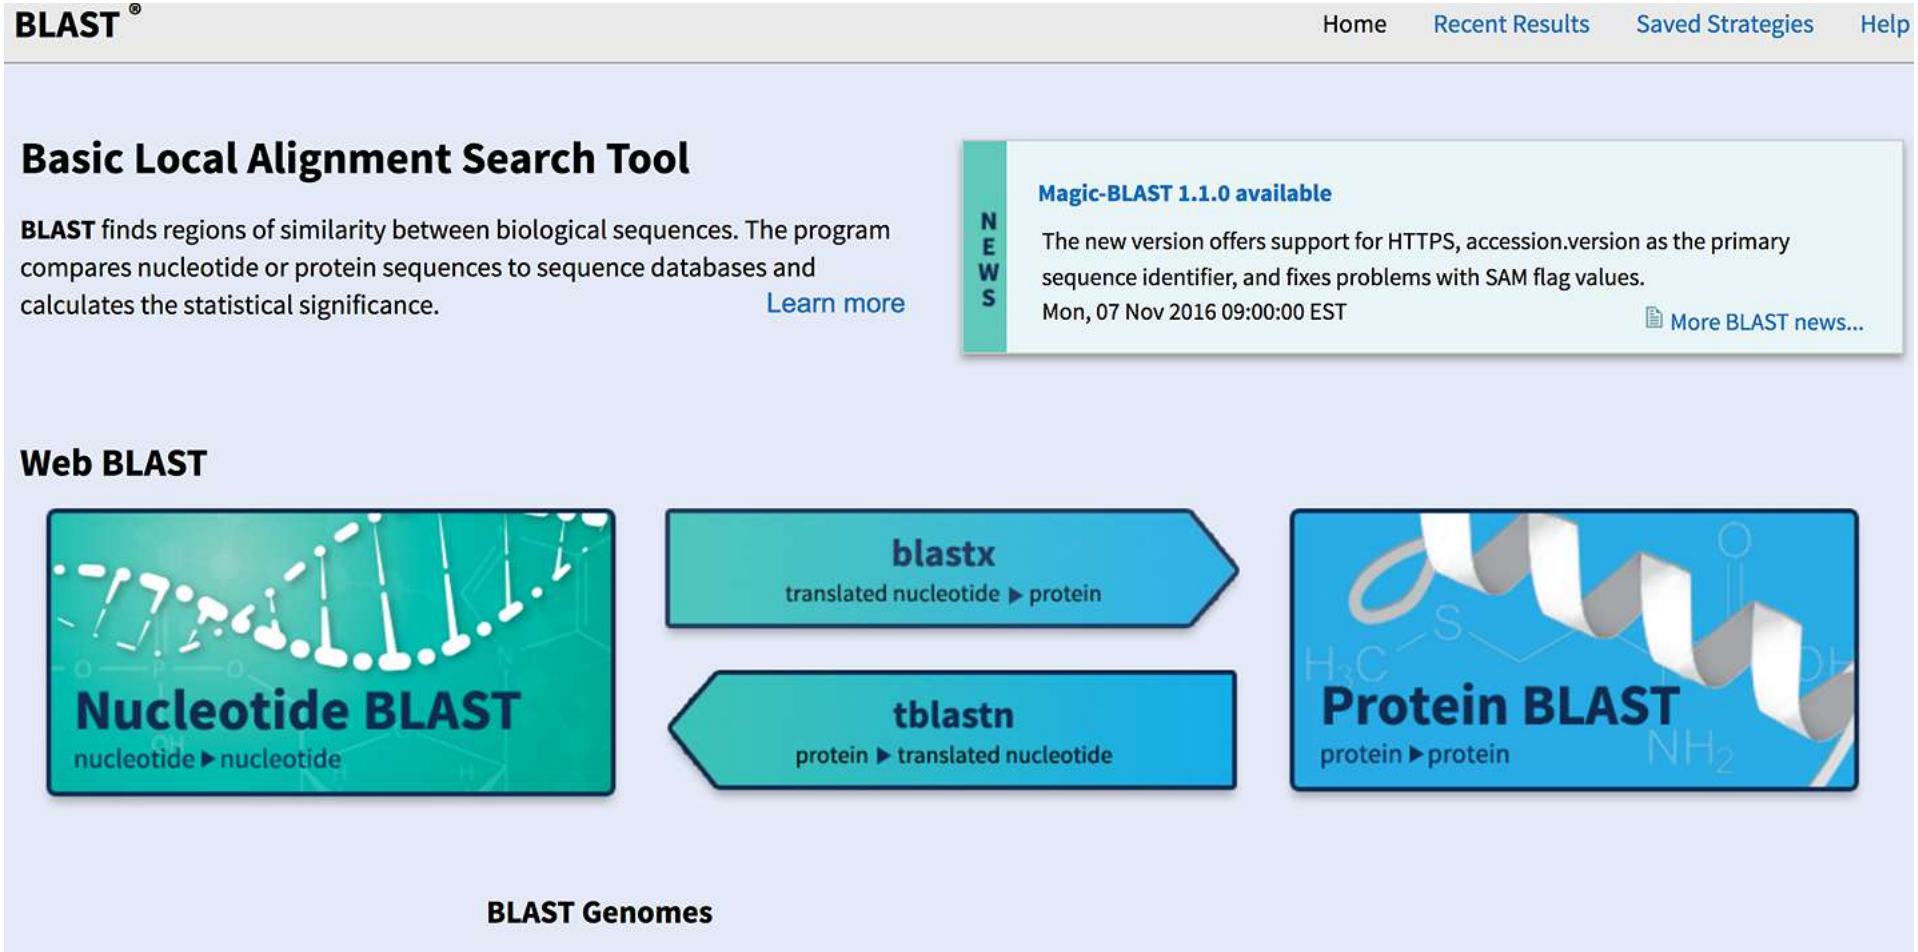

Affichage de BLAST

hemoglobin subunit beta [Homo sapiens]

Sequence ID: NP_000509.1 **Length:** 147 **Number of Matches:** 1

See 12 more title(s)

Range 1: 1 to 147 GenPept Graphics ▼ Next Match ▲ Previous Match

Score	Expect	Method	Identities	Positives	Gaps
301 bits(770)	3e-103	Compositional matrix adjust.	147/147(100%)	147/147(100%)	0/147(0%)

```
Query  1    MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK  60
            MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK
Sbjct  1    MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPK  60

Query  61   VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG  120
            VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG
Sbjct  61   VKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFG  120

Query  121  KEFTPPVQAAYQKVVAGVANALAHKYH  147
            KEFTPPVQAAYQKVVAGVANALAHKYH
Sbjct  121  KEFTPPVQAAYQKVVAGVANALAHKYH  147
```

Notions d'homologie

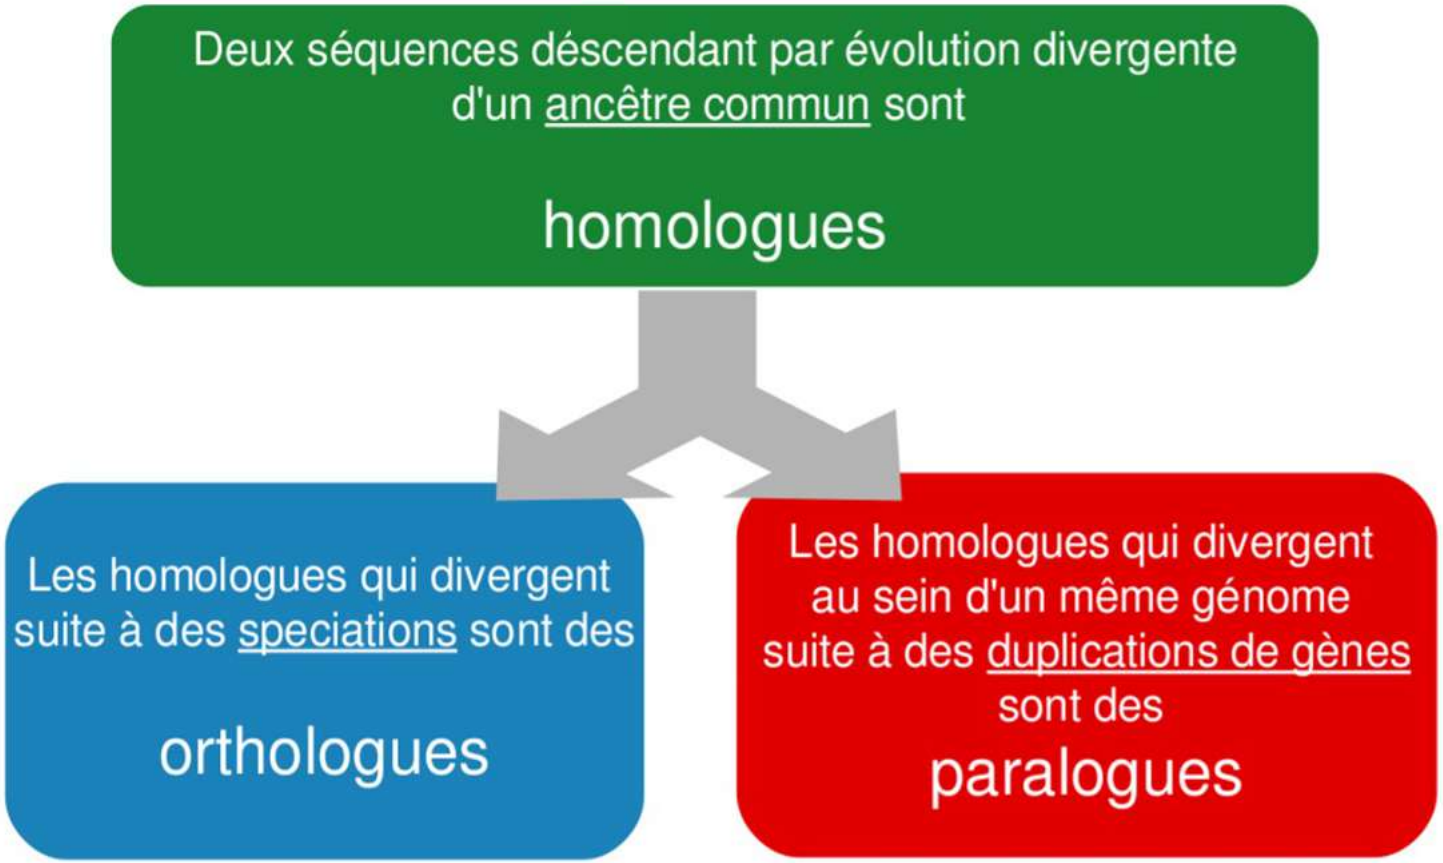

Notions d'homologie

Il n'y a **pas** de pourcentage d'homologie
l'homologie existe ou pas
Mais on calcule le pourcentage de similarité

"10 shades of grey"