CM 4 – Nov 2025

PDB, Structures 3D et AlphaFold

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Cas des histones

```
>H2A
MSGRGKQGGKARAKAKTRSSRAGLQFPVGRVHRLLRKGNYSERVGAGAPVYLAAVLEYLT
AEILELAGNAARDNKKTRIIPRHLQLAIRNDEELNKLLGRVTIAQGGVLPNIQAVLLPKK
TESHHKAKGK
>H2B
MPDPSKSAPAPKKGSKKAVTKAQKKDGKKRKRGRKESYSIYVYKVLKQVHPDTGISSKAM
GIMNSFVNDIFERIASEASRLAHYNKRSTITSREVQTAVRLLLPGELAKHAVSEGTKAVT
KYTSSK
>H3
MARTKQTARKSTGGKAPRKQLATKAARKSAPATGGVKKPHRYRPGTVALREIRRYQKSTE
LLIRKLPFQRLVREIAQDFKTDLRFQSSAVMALQEACEAYLVGLFEDTNLCAIHAKRVTI
MPKDIQLARRIRGERA
>H4
MSGRGKGGKGLGKGGAKRHRKVLRDNIQGITKPAIRRLARRGGVKRISGLIYEETRGVLK
VFLENVIRDAVTYTEHAKRKTVTAMDVVYALKRQGRTLYGFGG
```

```
CLUSTAL O(1.2.4) multiple sequence alignment


H2B     MPDPSK------SAPAPKKGS-KKAVTKA-QKKDGKKR----------------------   30
H3      MARTKQTARKSTGGKAPRKQLATKAARKSAPATGGVKKPHRYRPGTVALREIRRYQKSTE   60
H2A     -----MSGRGKQGGKA-------RAKAKTRSSRAGLQFPVG---------RVH-------   32
H4      -----MSGRGKGGKGLG-KGGAKRHRKVLRDNIQGITKP-----------AIR-------   36
                    .         :         *

H2B     KRGRKESYSIYVYKVLKQVHPDTGISSKAMGI----MNSFVNDIFERIASEASRLAHYNK   86
H3      LLIRKLPFQRLVREIAQDFKTDLRFQSSAVMALQEACEAYLVGLFE----DTNLCAIHAK   116
H2A     RLLRKGNYSERVGA-------GAPVYLAAV------LEYLTAEILE----LAGNAARDNK   75
H4      RLARRGGVKRISGLIYEETRGVLKVFLENV------I----RDAVT----YTEHA----K   78
           *:   .              .    :             .      :      *

H2B     RSTITSREVQTAVRLL------------------------LPGELAKHAVSEGTKAVTK   121
H3      RVTIMPKDIQLARRIRGERA----------------------------------------   136
H2A     KTRIIPRHLQLAIRNDEELNKLLGRVTIAQGGVLPNIQAVLLPKKTESHHKAKGK-----   130
H4      RKTVTAMDVVYALK-------RQGRTLYGFGG---------------------------   103
        :  :   .:  * :

H2B     YTSSK  126
H3      -----  136
H2A     -----  130
H4      -----  103
```

Cas des histones

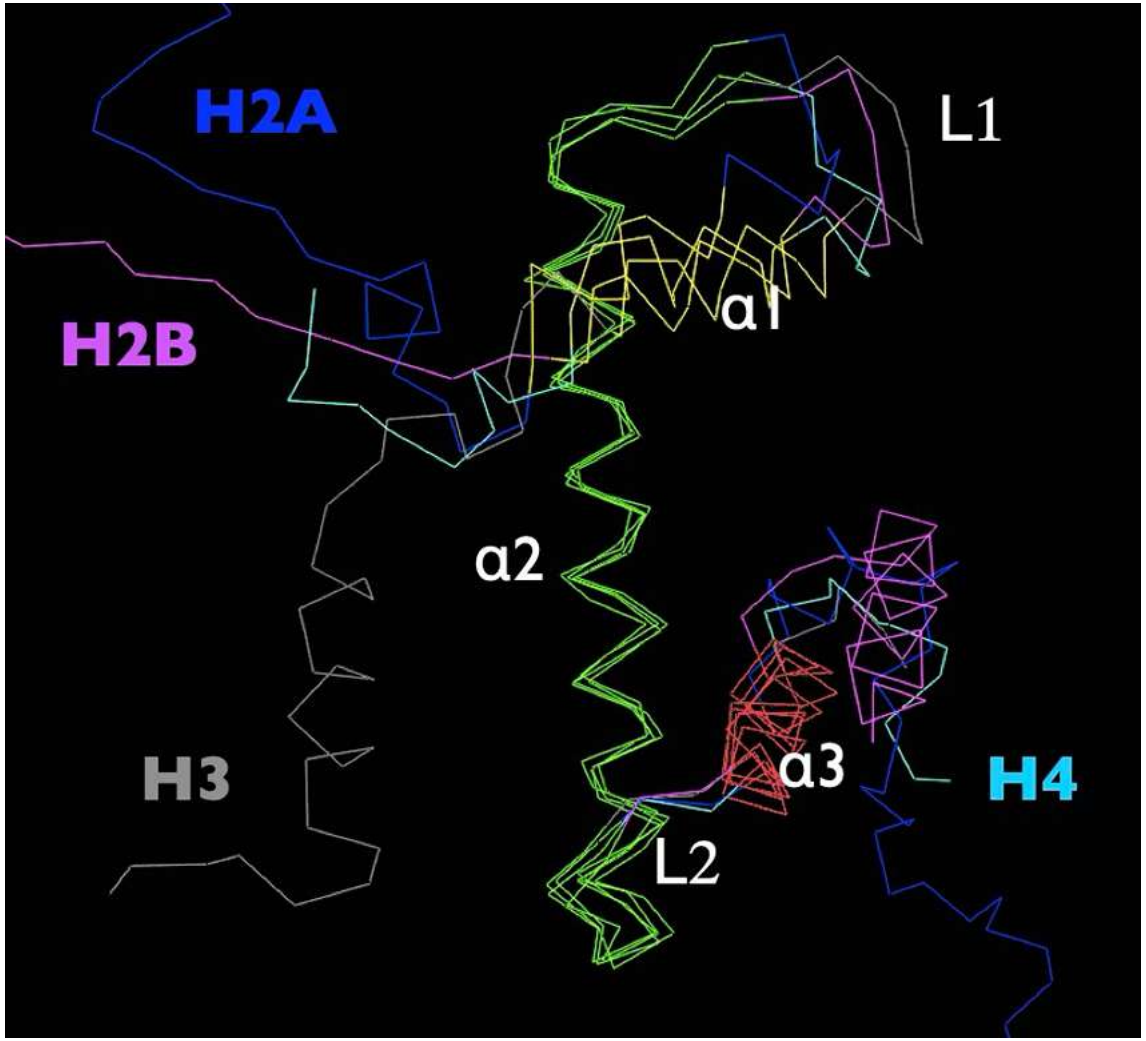

Petits rappels :
La structure primaire des protéines

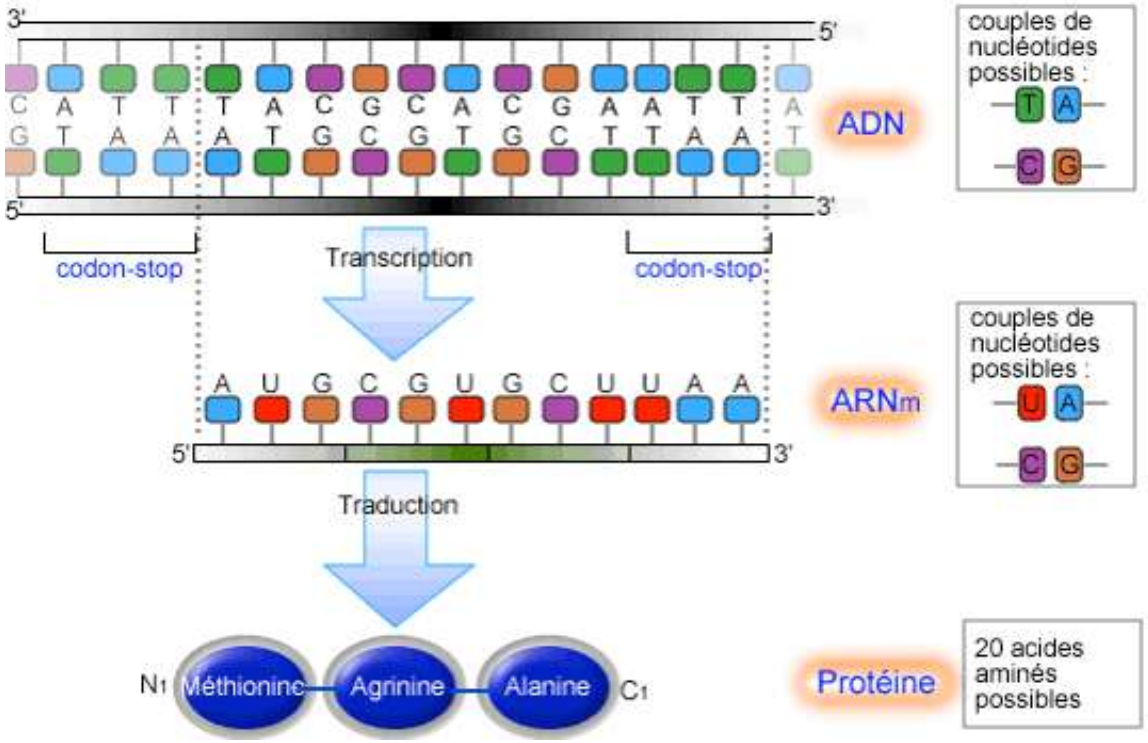

Structure secondaire des protéines

Peptide : courte séquence
Protéine : longue séquence formant des structures secondaires

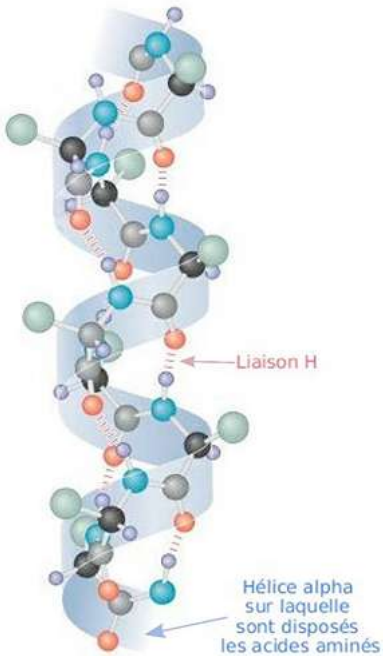

Hélice α

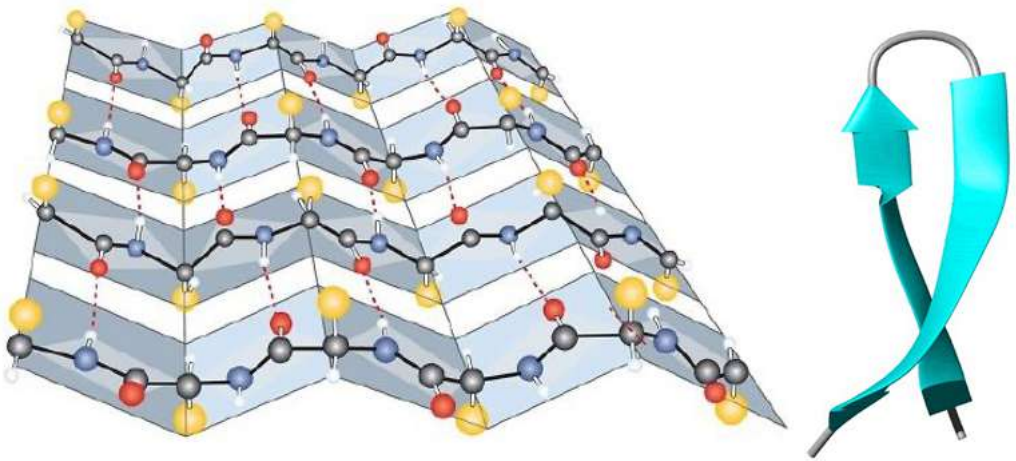

Feuillet β

Structure tertiaire des protéines

- Structures secondaires agencées les unes par rapport aux autres pour former la structure tertiaire (pont disulfure)

- Les forces qui permettent ces repliements sont les forces classiques (électrostatique, hydrogène, Van den Walls)

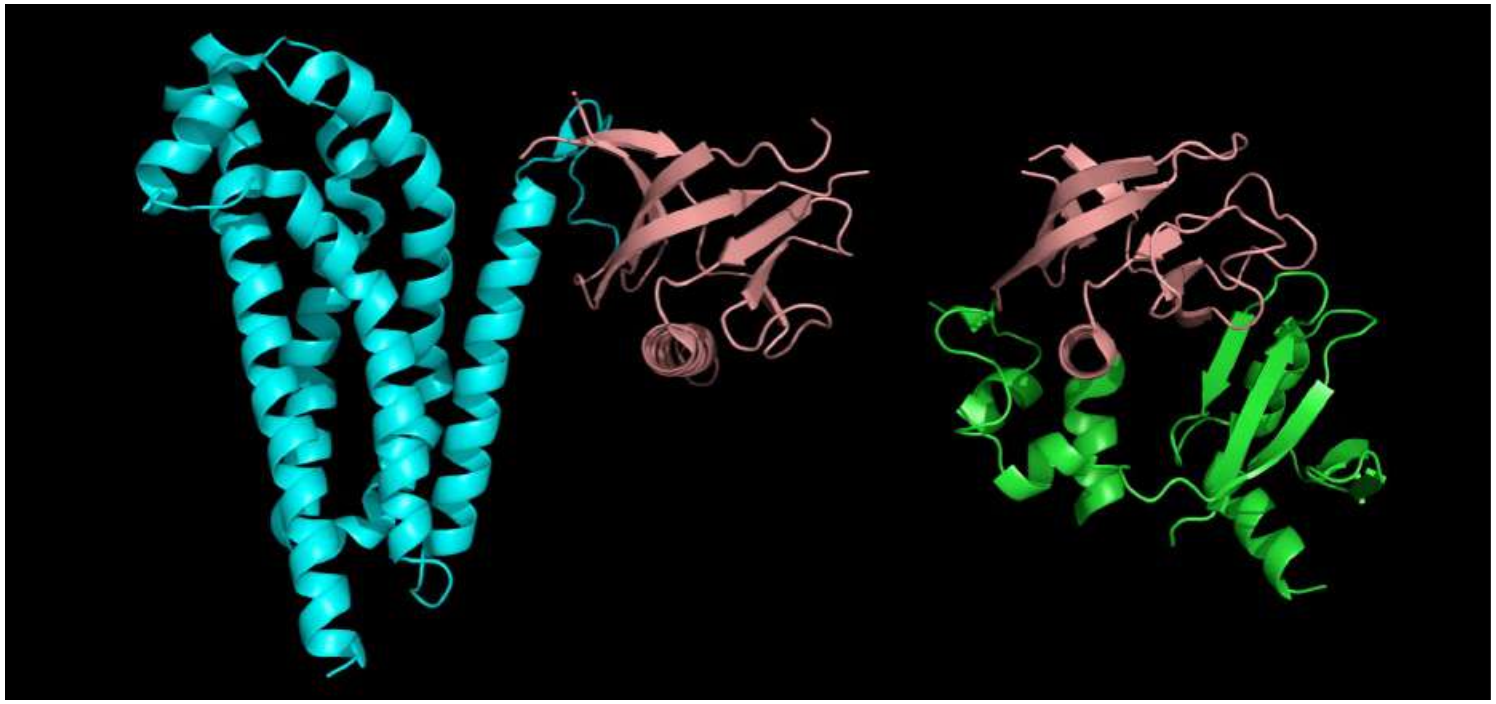

Structure tertiaire des protéines (pont disulfure)

Un pont disulfure (lien S-S) est un lien covalent fort qui, par oxydation, réunit les fonctions thiol (-SH) de deux cystéines dans une séquence peptidique

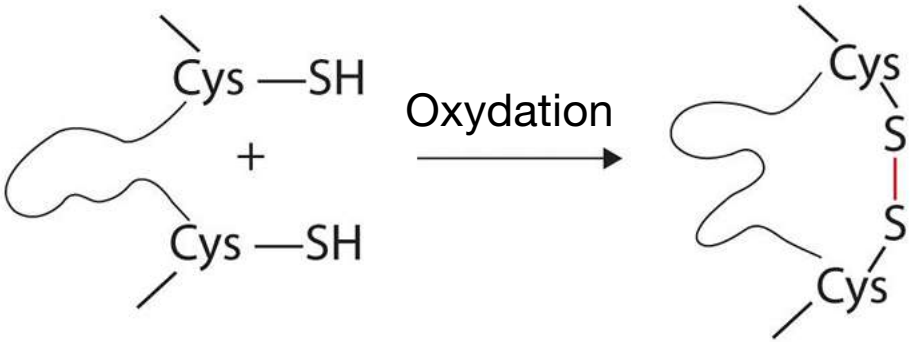

Protéines complexes

Hème

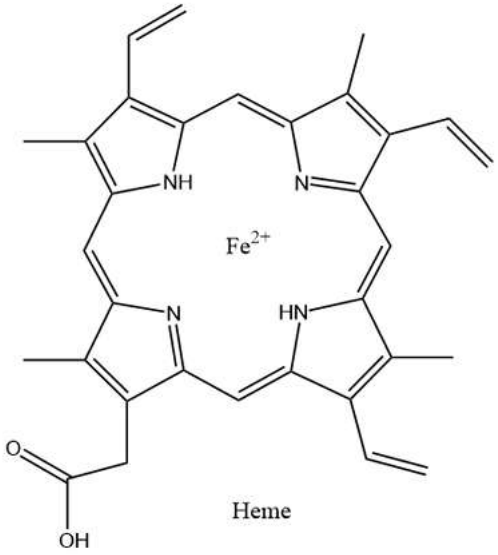

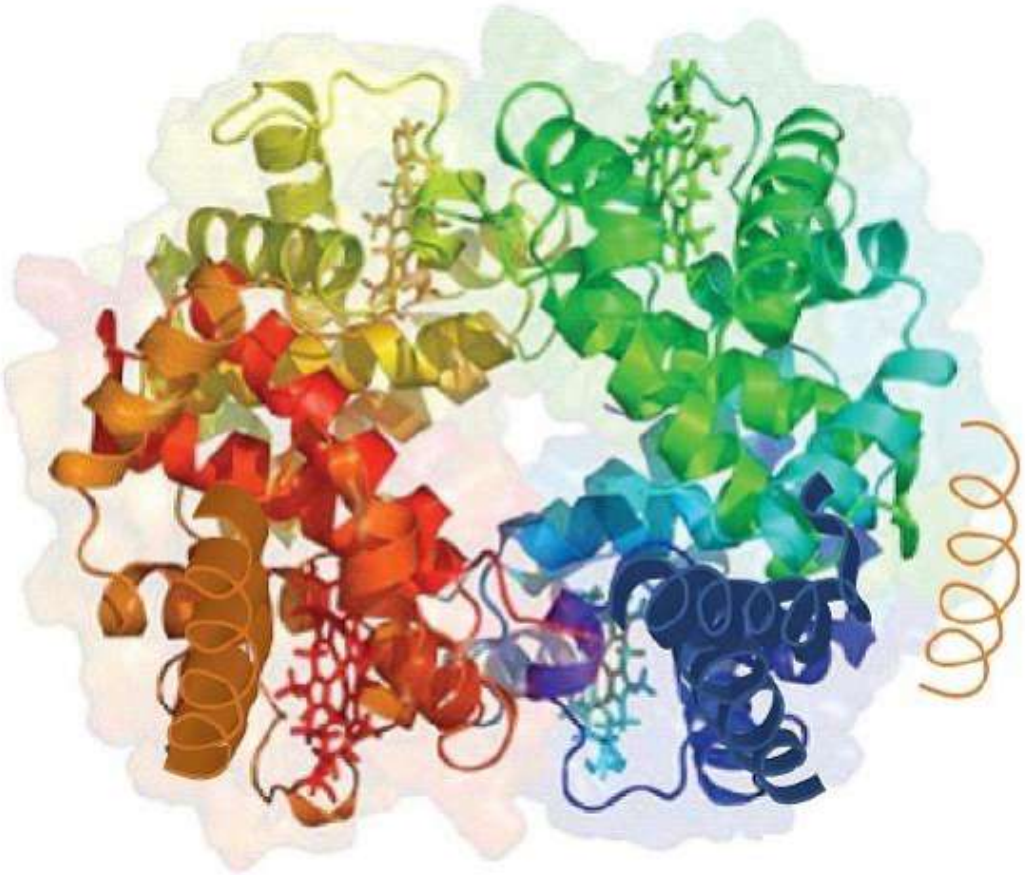

Structure quaternaire des protéines

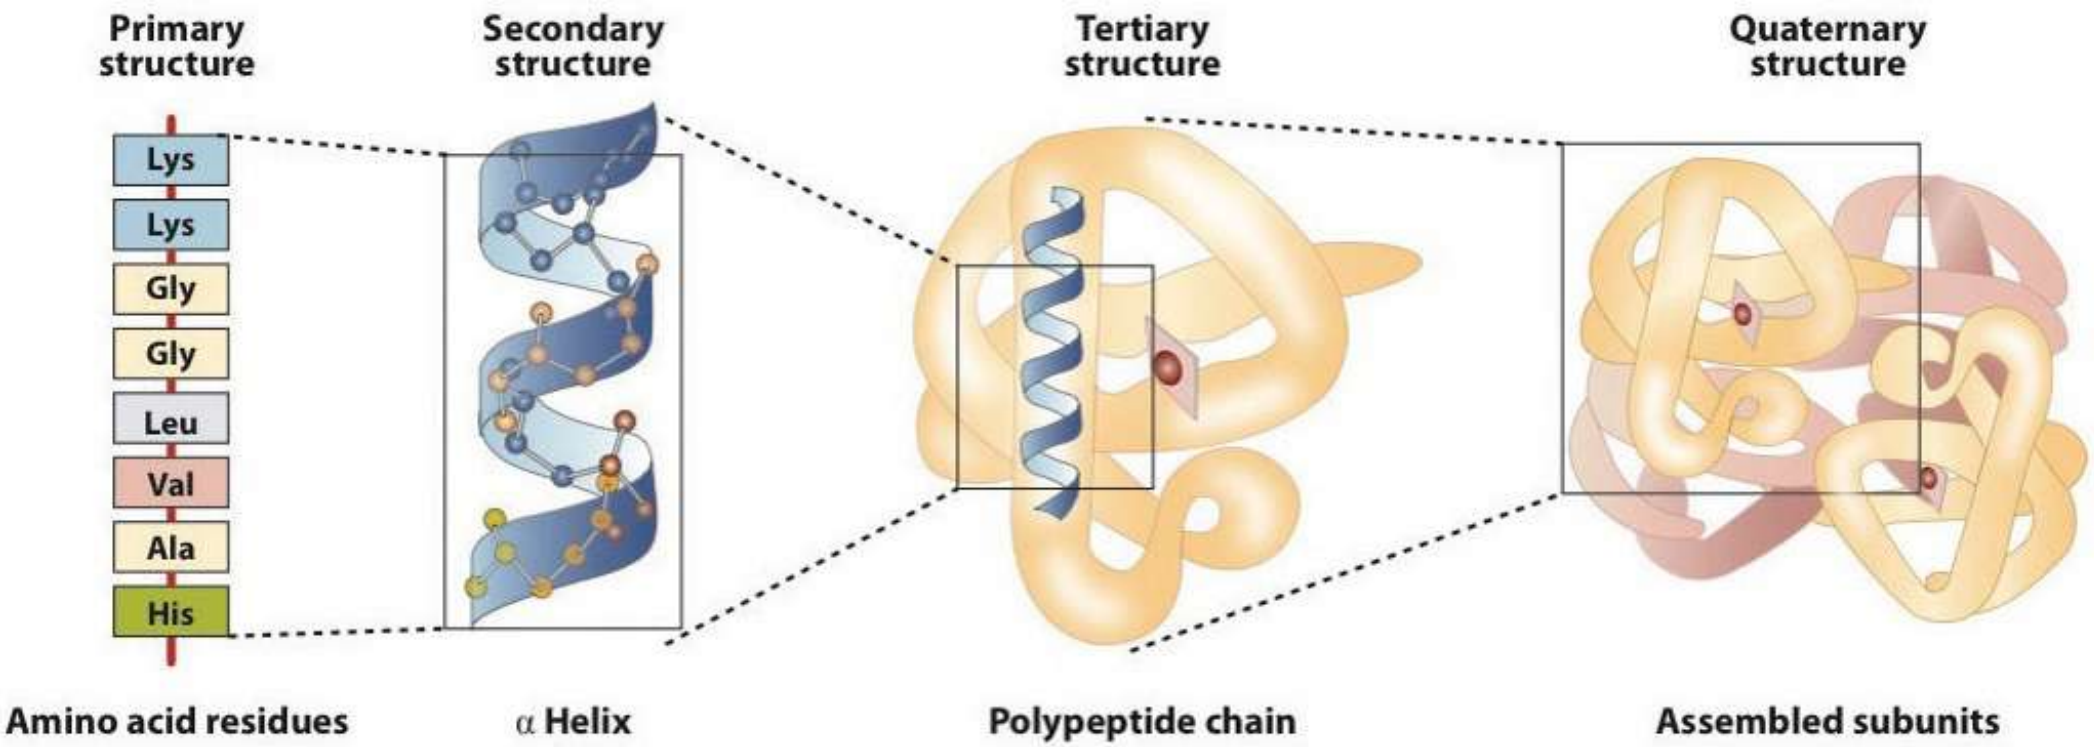

La base de données PBD

(Protein Data Bank)

Protein Data Bank

- Banque de données du Research Collaboratory for Structural Bioinformatics (Protein Data Bank ou PDB) :
  macromolécules biologiques (protéines et acides nucléiques)
- Structures 3D déterminées par cristallographie aux rayons X ou spectroscopie RMN
- Données expérimentales déposées dans la PDB par des biologistes et des biochimistes du monde entier et appartenant au domaine public.
- Leur consultation est gratuite depuis les web des banques:
  - Europe (PDBe)
  - Japon (PDBj)
  - USA: (RCSB PDB)
- La PDB est la principale source de données de biologie structurale et permet d'accéder aux structures 3D de protéines d'intérêt pharmaceutique.

Évolution exponentielle

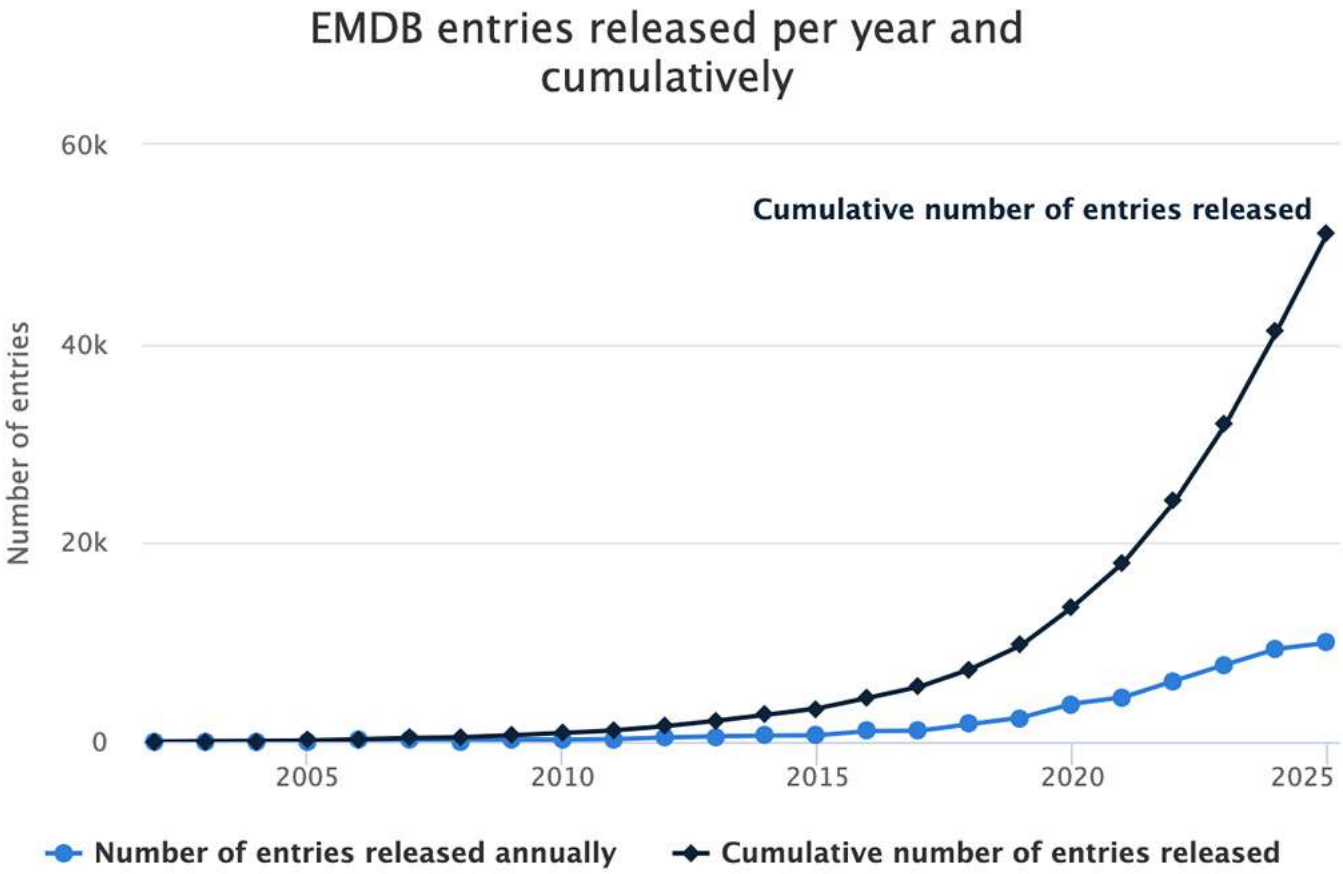

Formats de Fichiers

- Chaque modèle est référencé dans la base par un identifiant unique à **4 caractères**
- Le premier est toujours un caractère numérique, les trois suivants sont des caractères alphanumériques.
- Cet identifiant est appelé « **code pdb** »
  ex: 1a00
- Plusieurs formats existent pour les fichiers de la PDB :
  - Le format PDB
  - Le format mmCIF
  - Le format PDBML

Le format PDB

- Le **format pdb** est le **format original** de la banque
- Le guide de ce format a été révisé à plusieurs reprises
- La version actuelle est la **version 3.3**, qui existe **depuis juillet 2011**
- Les archives contiennent :
  - les **coordonnées cartésiennes** des atomes
  - la **bibliographie**
  - les **informations structurales**
  - les facteurs de la **structure cristallographique**
  - les données **expérimentales de la RMN**
- À l'origine, le format pdb a été dicté par la largeur de **cartes perforées** pour ordinateur
- En conséquence, chaque ligne contient **exactement 80 caractères**

Le format PDB

- Un fichier au format pdb est un **fichier texte** où **chaque colonne** possède sa **signification** : les 6 premières colonnes déterminent le champ du fichier.
  - « TITLE_ » : titre de la macromolécule étudiée
  - « KEYWDS » : mots-clé de l'entrée
  - « EXPDTA » : informations sur la méthode expérimentale employée
  - « SEQRES » : séquence de la protéine étudiée
  - « ATOM__ » ou « HETATM » : informations liées à un atome particulier.

Dans ces derniers champs, le nom de l'atome est décrit par les colonnes 13 à 16 (soit du treizième au seizième caractère de la ligne)

Le format PDB (3)

- Les lignes « ATOM__ » concernent les **acides aminés** ou les **acides nucléiques**
- Les lignes « HETATM » sont dédiées aux **autres molécules**
  - solvant
  - substrat
  - ion
  - détergent
- Il y a autant de lignes « ATOM__ » et « HETATM » que d'atomes observés par l'expérimentateur pour une **macromolécule** ou un **complexe donné**
- Accumulation de **données non uniformes**
- de **nombreuses erreurs**, **pas systématiquement éliminées** lors des contrôles accompagnant le dépôt des structures

Il peut s'agir de **différences** entre la **séquence** et les **résidus représentés** ou de **problèmes** liés à la **nomenclature** des atomes des acides aminés ou des ligands

Le fichier pdb

```
         1         2         3         4         5         6         7         8
12345678901234567890123456789012345678901234567890123456789012345678901234567890
```

80 colonnes

Le fichier pdb

```
         1         2         3         4         5         6         7         8
12345678901234567890123456789012345678901234567890123456789012345678901234567890
REMARK   1
REMARK   1 REFERENCE 1
REMARK   1  AUTH   W.A.HENDRICKSON,M.M.TEETER
REMARK   1  TITL   STRUCTURE OF THE HYDROPHOBIC PROTEIN CRAMBIN
REMARK   1  TITL 2 DETERMINED DIRECTLY FROM THE ANOMALOUS SCATTERING
REMARK   1  TITL 3 OF SULPHUR
REMARK   1  REF    NATURE                        V. 290   107 1981
REMARK   1  REFN                   ISSN 0028-0836
REMARK   1 REFERENCE 2
REMARK   1  AUTH   M.M.TEETER,W.A.HENDRICKSON
REMARK   1  TITL   HIGHLY ORDERED CRYSTALS OF THE PLANT SEED PROTEIN
REMARK   1  TITL 2 CRAMBIN
REMARK   1  REF    J.MOL.BIOL.                   V. 127   219 1979
REMARK   1  REFN                   ISSN 0022-2836
REMARK   2
REMARK   2 RESOLUTION.    1.50 ANGSTROMS.
REMARK   3
REMARK   3 REFINEMENT.
REMARK   3   PROGRAM     : PROLSQ
REMARK   3   AUTHORS     : KONNERT,HENDRICKSON
REMARK   3
REMARK   3  DATA USED IN REFINEMENT.
REMARK   3   RESOLUTION RANGE HIGH (ANGSTROMS) : 1.50
REMARK   3   RESOLUTION RANGE LOW  (ANGSTROMS) : NULL
REMARK   3   DATA CUTOFF            (SIGMA(F)) : NULL
REMARK   3   COMPLETENESS FOR RANGE        (%) : NULL
REMARK   3   NUMBER OF REFLECTIONS             : NULL
REMARK   4
REMARK   4 1CRN COMPLIES WITH FORMAT V. 3.15, 01-DEC-08
```

Le fichier pdb

- Le format en 80 colonnes des fichiers pdb est restrictif.
- Le nombre maximum d'atomes d'un fichier pdb est de 99999 (5 colonnes)
- Le nombre de résidus par chaîne est au maximum de 9999 (4 colonnes)
- Le nombre de chaînes est limité à 62 (1 colonne)

  - Les valeurs de cette colonne sont une des 26 lettres de l'alphabet, en minuscule ou en majuscule, ou un des chiffres de 0 à 9

  - donc : 26 + 26 + 10 = 62 possibilités

- Quand ce format a été défini, ces limitations ne semblaient pas restrictives, mais elles ont plusieurs fois été franchies lors du dépôt de structures extrêmement complexes, comme des virus, des ribosomes ou des complexes multi-enzymatiques

Le format mmCIF

- En 1990, l'Union internationale de la cristallographie (International Union of Crystallography, IUCr) a étendu aux macromolécules la représentation des données de structures cristallographiques des molécules de faible poids moléculaire
- Cette représentation est appelée CIF (Crystallographic Information File)
- Le dictionnaire mmCIF (macromolecular Crystallographic Information File) développé fin des années 90
- Première version du dictionnaire mmCIF publiée en 1996
- RCSB-PDB en 1998, adopte le format mmCIF pour le traitement et la gestion des données
- En 2001, tous les fichiers pdb ont été corrigés et convertis au format mmCIF

Visualisation des données

- Les fichiers décrivant les modèles moléculaires téléchargeables sur PDBe ou RCSB ou PDBj
- Visualisables grâce à différents logiciels
  - rasmol
  - Jmol
  - Chime
  - Cn3D
  - extension (plugin) de navigateur
  - bibliothèque mmLib pour le langage de programmation Python
  - application pour smartphone (RCSB PDBMobile)

  - PyMol
  - ChimeraX
- Le site web de la PDB contient également des ressources sur la génomique structurale

Visualisation des fichiers

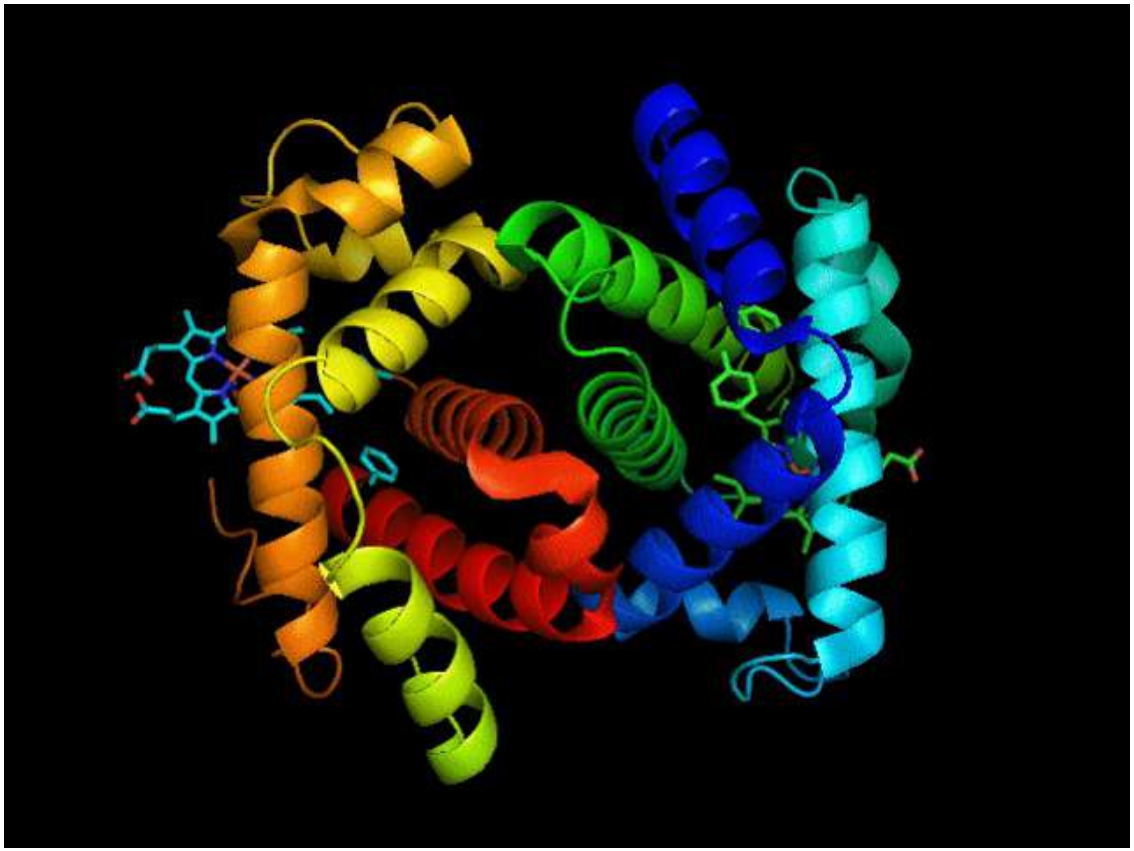

Hémoglobine 1a00.pdb

Les programmes de prédictions

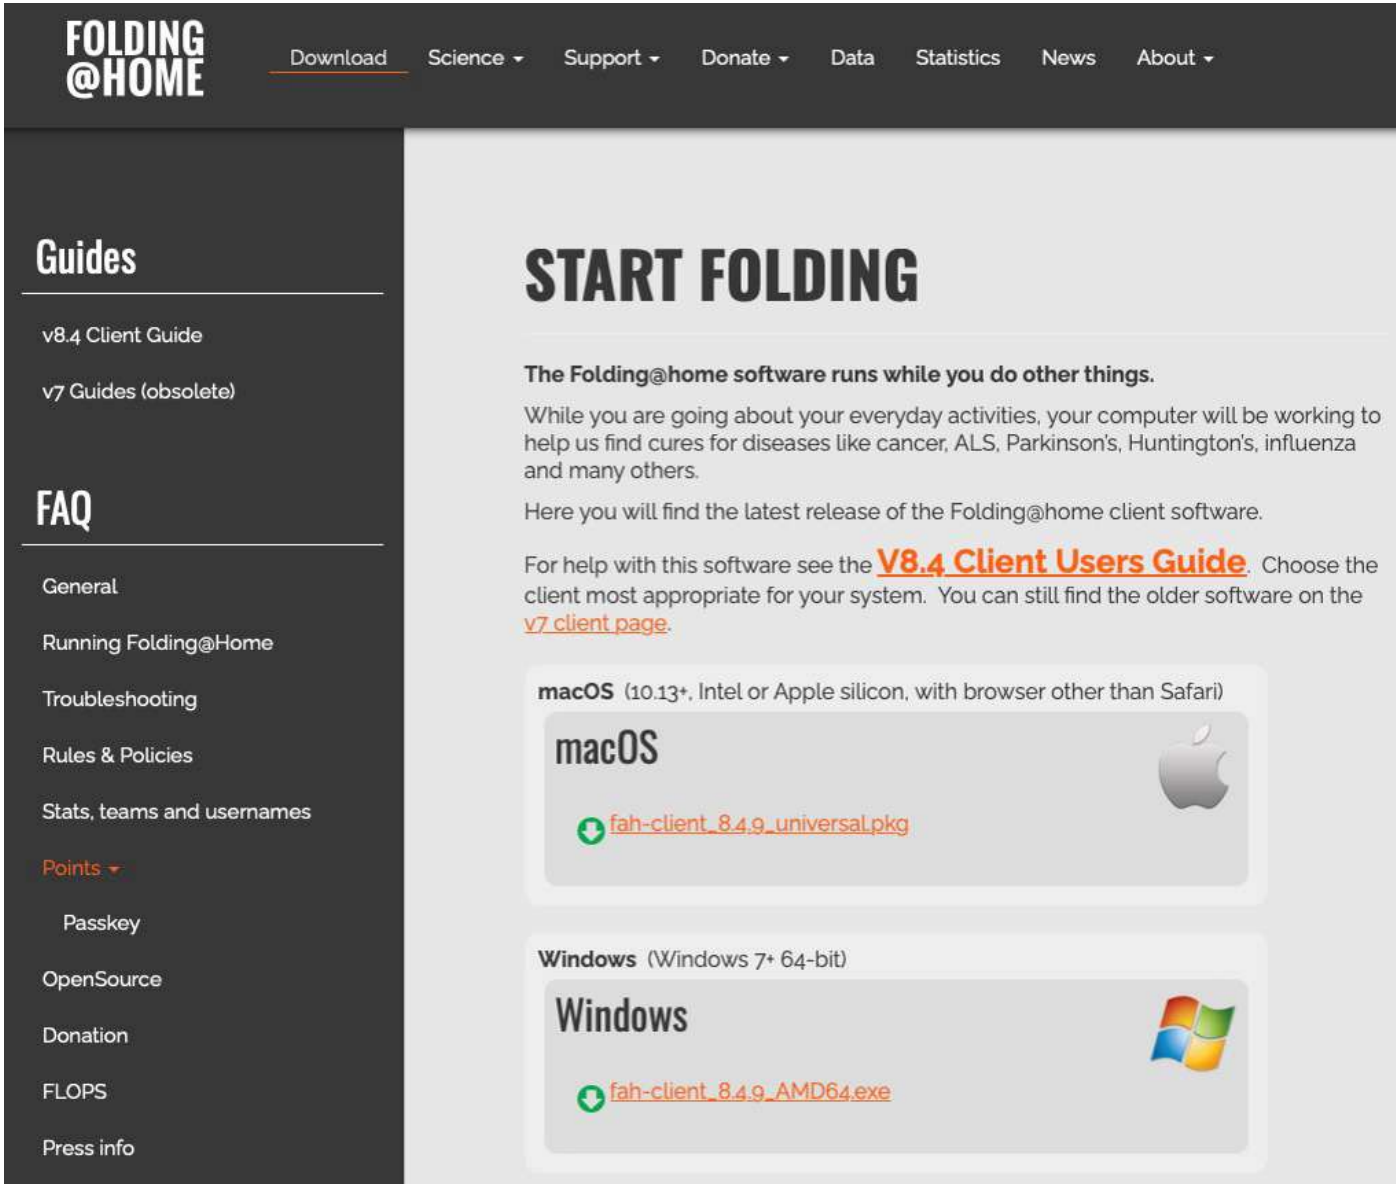

Folding@home (https://foldingathome.org/start-folding/)

- 2000, Projet soutenu par Google
- Repliement dans différentes conditions de pression et température
- Médicaments, Alzheimer, Huntington, Drépanocytose, Cancers, SIDA, etc…

Les programmes de prédictions

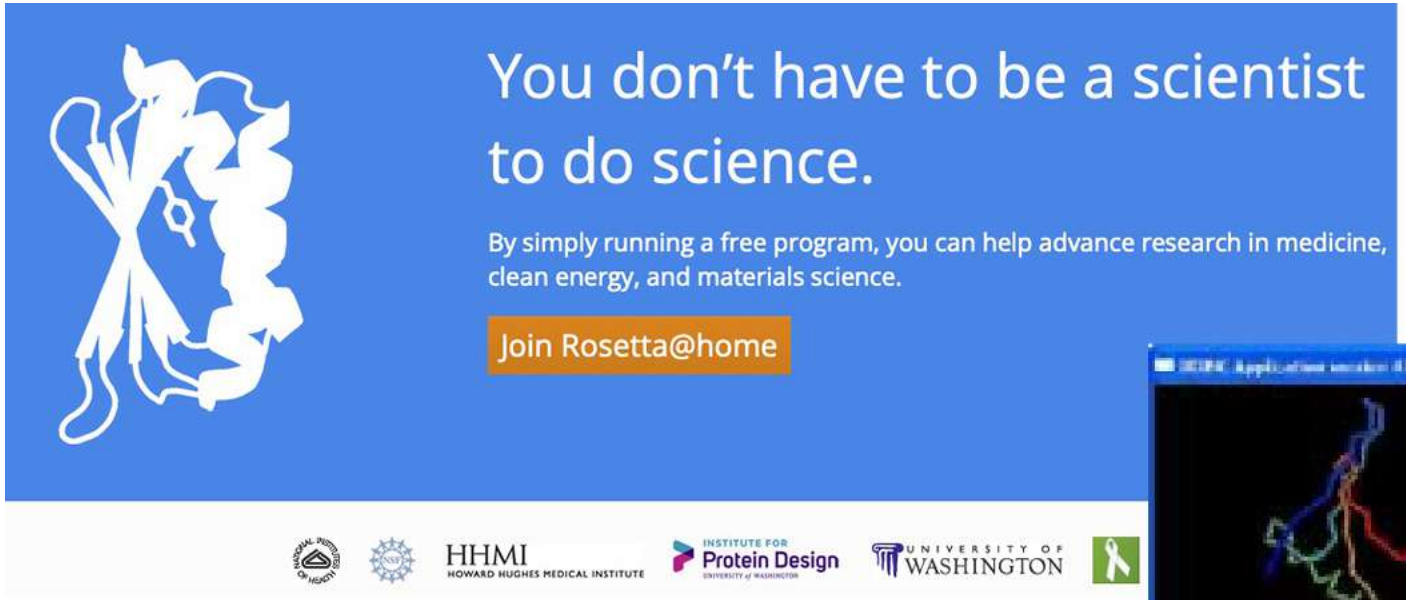

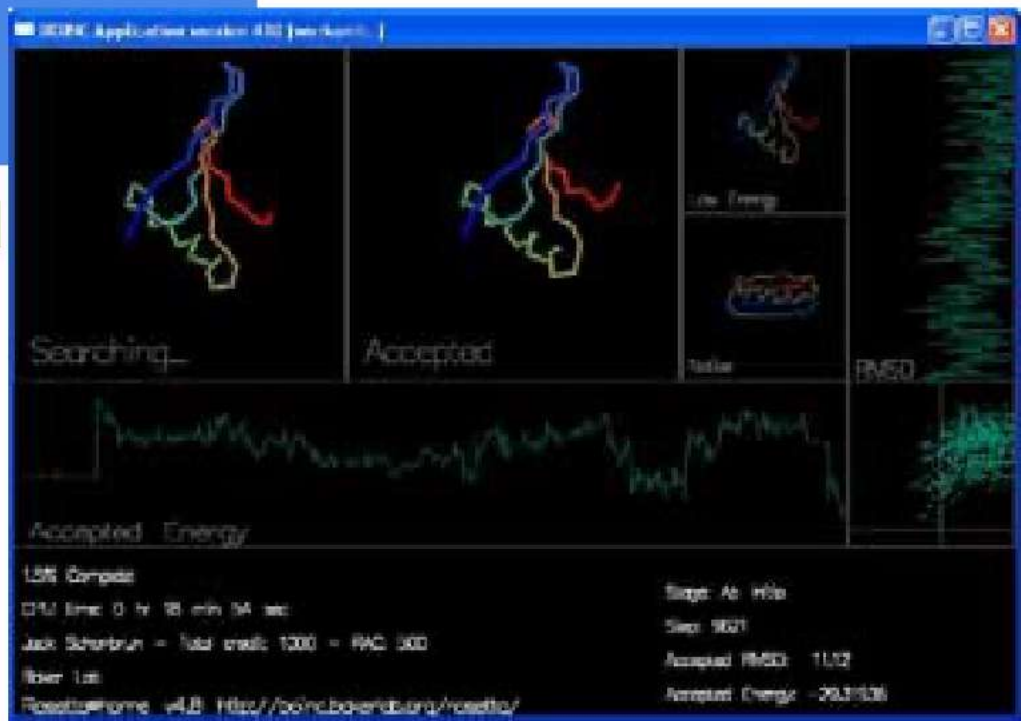

Les programmes de prédictions

Rosetta@home
Protein Folding, Design, and Docking

Rosetta@home (http://boinc.bakerlab.org/rosetta/)
- 2005, Projet de l'Université de Washington
- Déterminer la structure 3D des protéines étudiées
- Sida, Malaria, Alzheimer, Cancers, Herpès, etc…
- Publication 2010 (J. Molecular Biology)

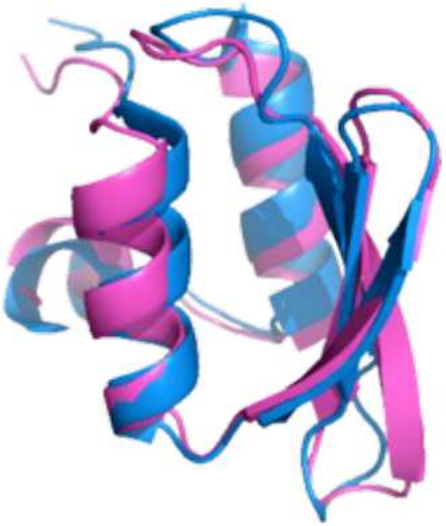

T0281, 1ère prédiction de structure à approcher la résolution atomique.
Rosetta (magenta) 1.5 Å, crystal (bleu)

Les programmes de prédictions

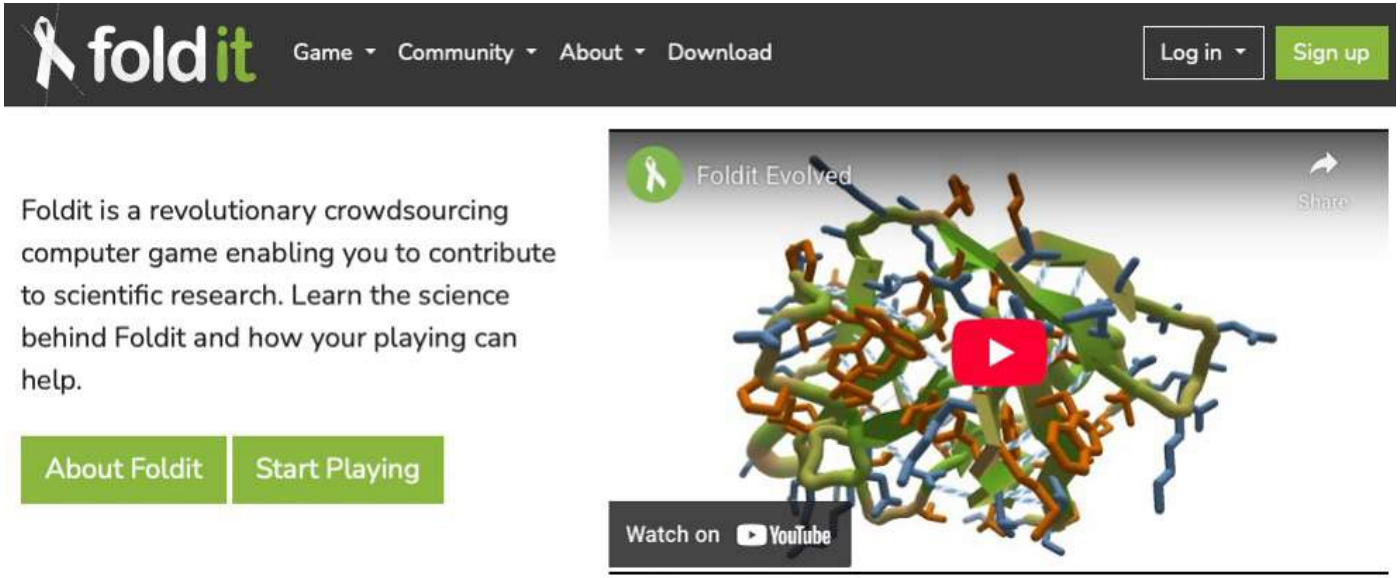

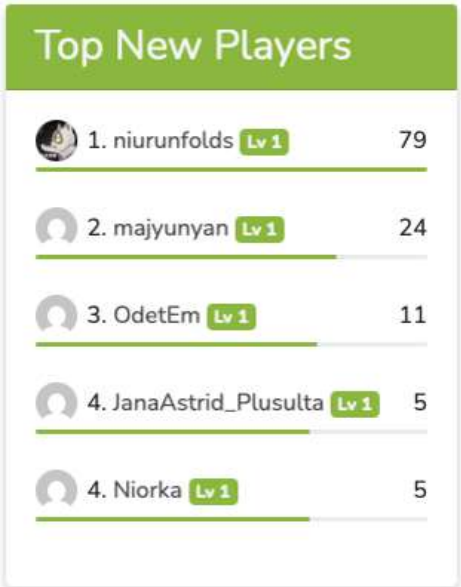

Utilisateurs (actifs) : >375 000 (>26 000)
Sites (actifs) : >1 215 000 (>66 000)
Foldit : http://fold.it/)
jeu vidéo expérimental sur le repliement des protéines, développé en collaboration entre le département d'informatique et de biochimie de l'Université de Washington. La version bêta a été publiée en mai 2008

Le défi

- plus de 200 millions de protéines sont connues

- Déterminer la structure des protéines par méthodes expérimentales
  - cristallographie aux rayons X
  - résonance magnétique nucléaire (RMN)

- Pour certaines protéines impossibles d'obtenir des données structurelles précises par des méthodes expérimentales traditionnelles

CASP

CASP Experiments

- **CASP16 (2024)**
- CASP15 (2022)
- CASP14 (2020)
- CASP13 (2018)
- CASP12 (2016)
- CASP11 (2014)
- CASP10 (2012)
- CASP9 (2010)
- CASP8 (2008)
- CASP7 (2006)
- CASP6 (2004)
- CASP5 (2002)
- CASP4 (2000)
- CASP3 (1998)
- CASP2 (1996)
- CASP1 (1994)

- La compétition CASP (Critical Assessment of Structure Prediction)
- Créé en 1994,
- Tous les deux
- Évaluation des méthodes de prédiction des structures tridimensionnelles des proteins

CASP 13 et DeepMind

- CASP13 (2018) : apparition de DeepMind dans la competition
- Victoire d'AlphaFold1

- CASP14 (2020) : AlphaFold surpasse toutes les autres équipes avec une précision jamais vue auparavant
- Niveaux de prediction comparables aux méthodes expérimentales traditionnelles

- 2021 DeepMind rend accessible gratuitement AlphaFold2

- Nov 2022 : OpenAI rend public ChatGPT 3.5

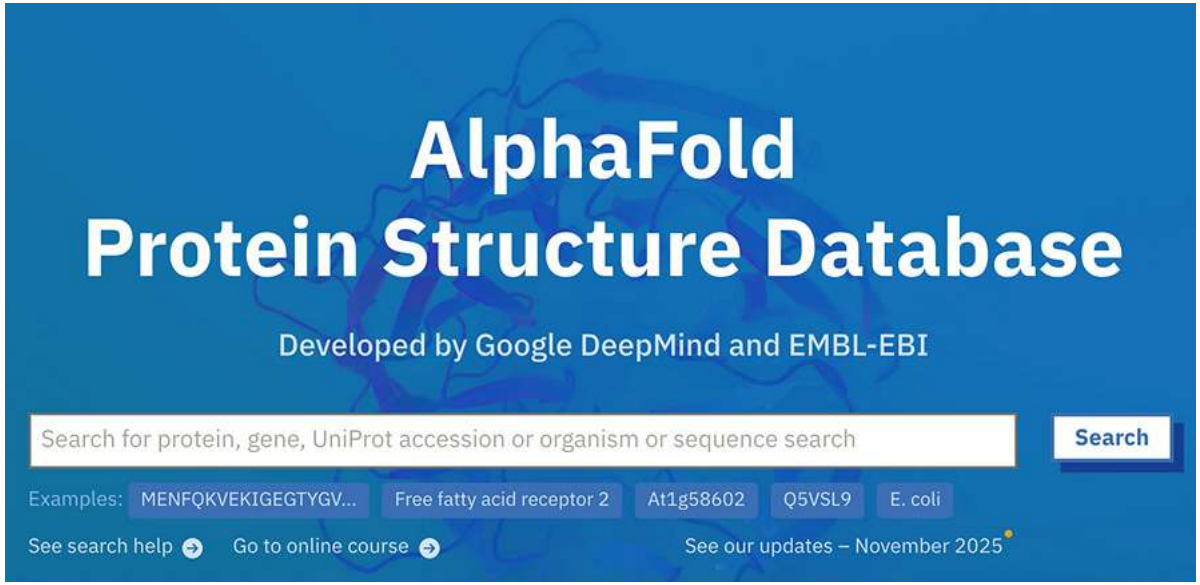

Les Transformers : « All you need is attention »

Attention Is All You Need

Ashish Vaswani* Google Brain avaswani@google.com

Noam Shazeer* Google Brain noam@google.com

Niki Parmar* Google Research nikip@google.com

Jakob Uszkoreit* Google Research usz@google.com

Llion Jones* Google Research llion@google.com

Aidan N. Gomez* † University of Toronto aidan@cs.toronto.edu

Łukasz Kaiser* Google Brain lukaszkaiser@google.com

Illia Polosukhin* ‡ illia.polosukhin@gmail.com

Abstract

The dominant sequence transduction models are based on complex recurrent or convolutional neural networks that include an encoder and a decoder. The best performing models also connect the encoder and decoder through an attention mechanism. We propose a new simple network architecture, the Transformer, based solely on attention mechanisms, dispensing with recurrence and convolutions entirely. Experiments on two machine translation tasks show these models to be superior in quality while being more parallelizable and requiring significantly less time to train. Our model achieves 28.4 BLEU on the WMT 2014 English-to-German translation task, improving over the existing best results, including ensembles, by over 2 BLEU. On the WMT 2014 English-to-French translation task, our model establishes a new single-model state-of-the-art BLEU score of 41.0 after training for 3.5 days on eight GPUs, a small fraction of the training costs of the best models from the literature.

2017

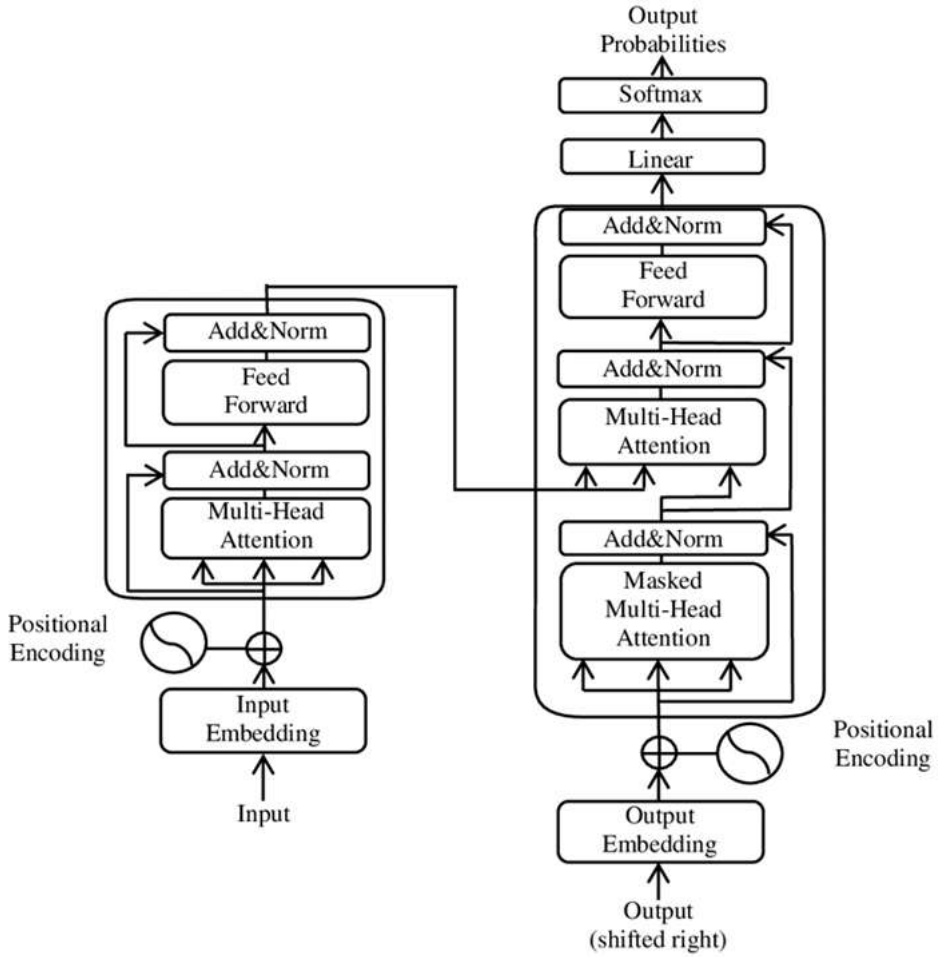

AI, ML et DL

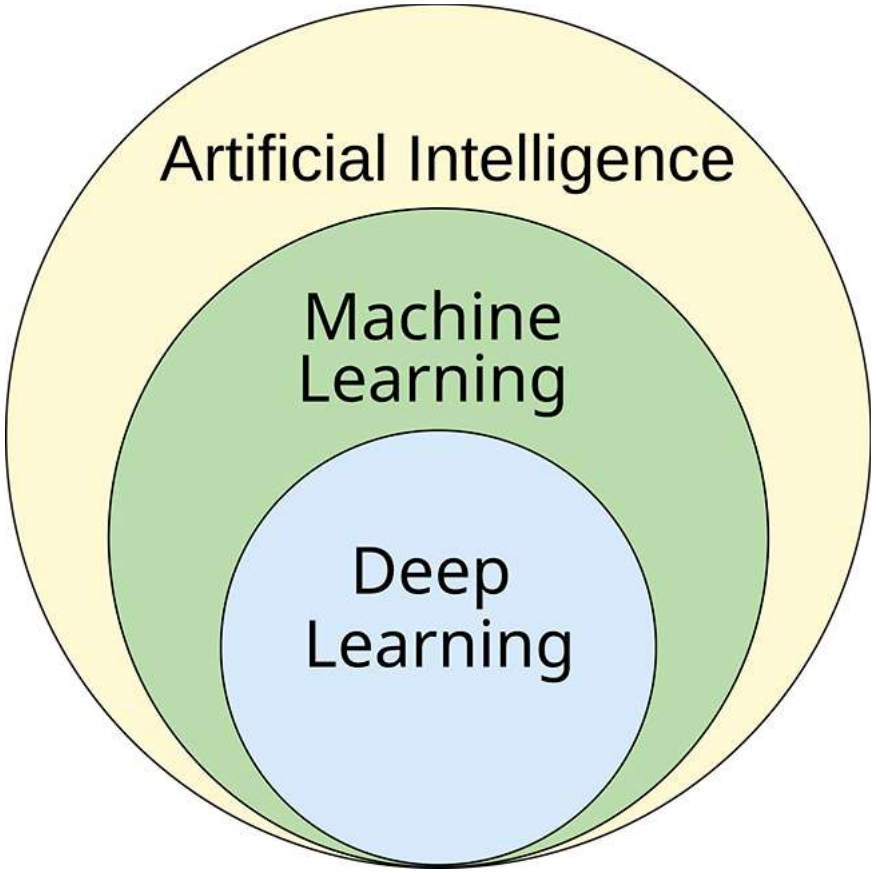
Artificial Intelligence
Machine Learning
Deep Learning

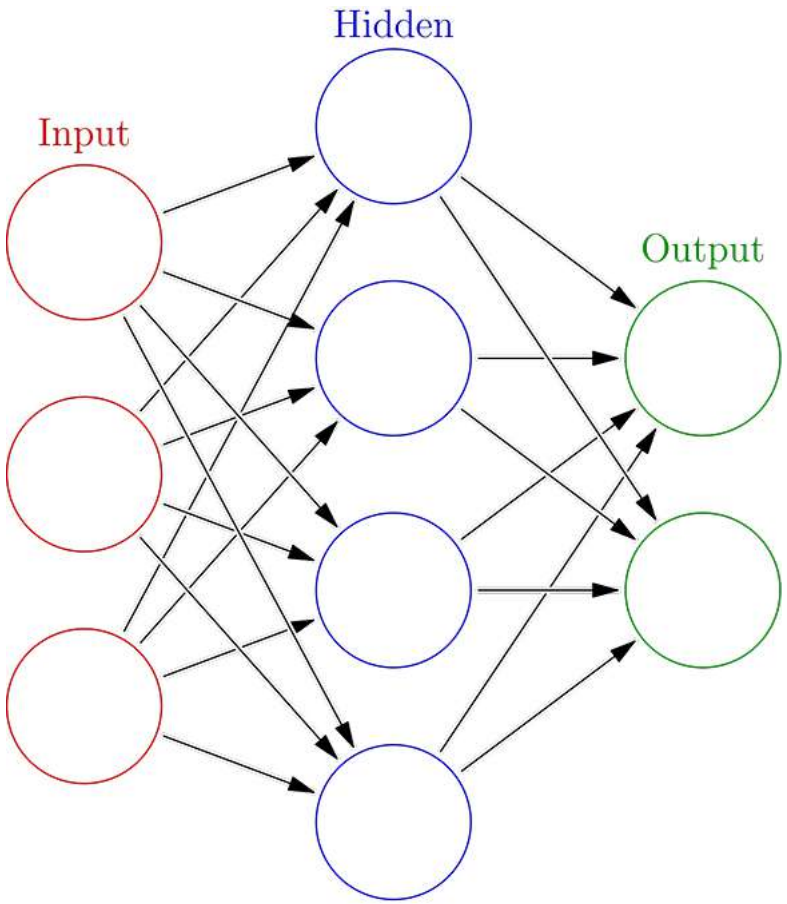
Hidden
Input
Output

AlphaFold

- DeepMind a utilisé plus de 170 000 structures protéiques de la PDB (~80-85 %)
- Entre 100 et 200 GPU

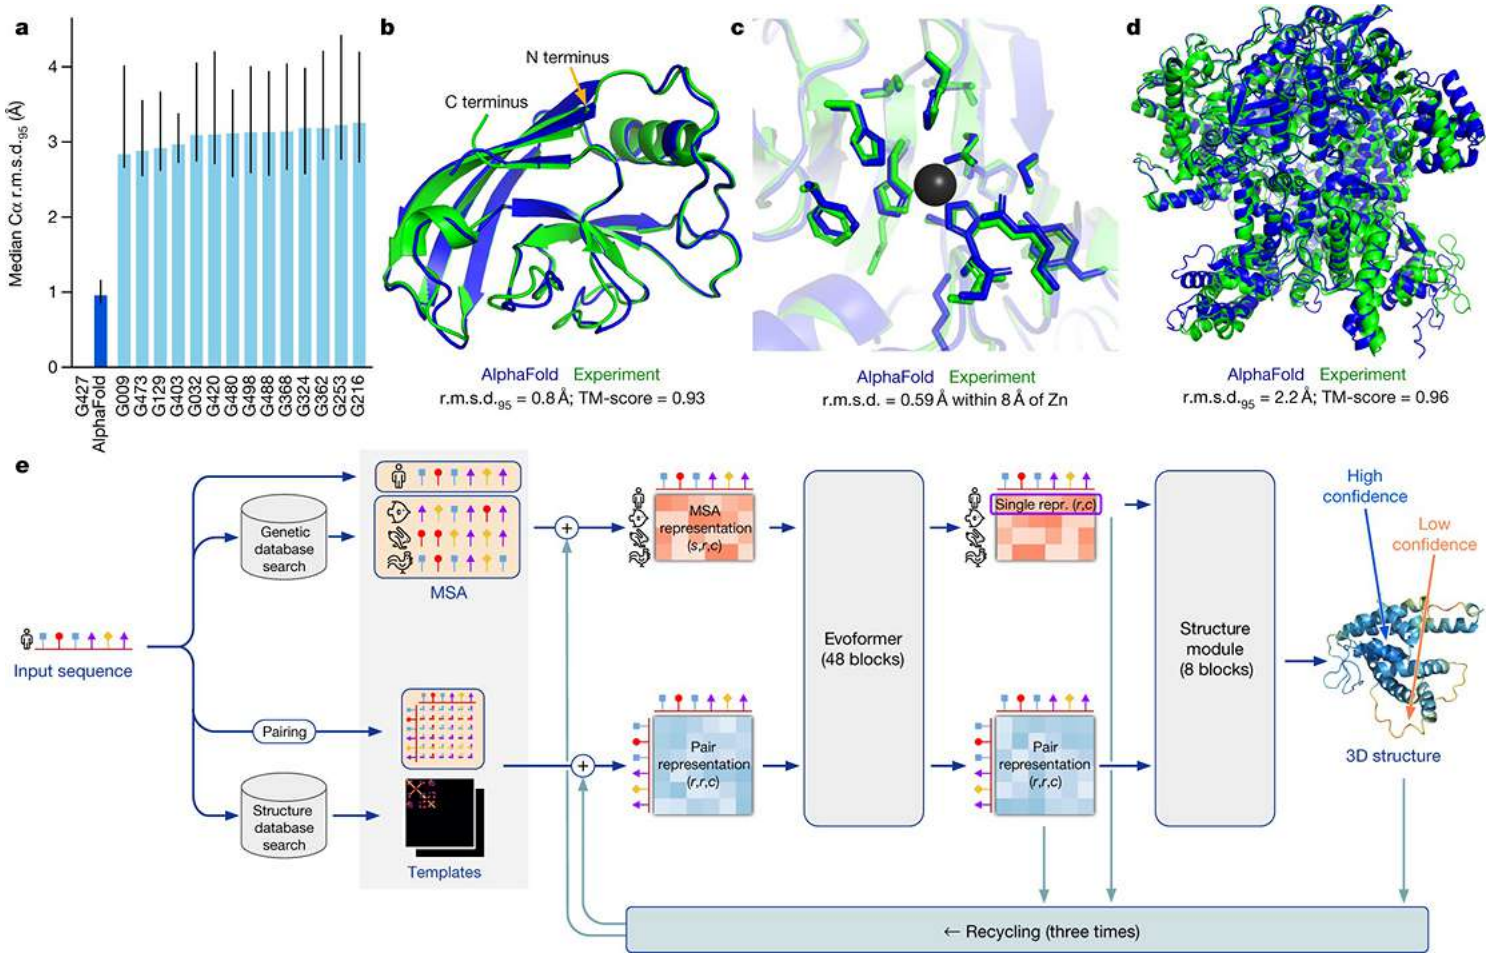

[John Jumper et al.]

Action d'AlphaFold

- **Entrée des données** : génère des alignements de séquences multiples (MSA) pour trouver des séquences similaires
- **Modélisation** : utilise des modèles de deep learning (transformers) pour analyser les relations entre les acides aminés
- **Prédiction de distances et d'angles** : prédit les distances entre les paires d'acides aminés ainsi que les angles des liaisons chimiques

détermination la forme 3D de la protéine

- **Assemblage structurel** : assemble la structure 3D de la protéine en minimisant une fonction d'énergie qui pénalise les configurations irréalistes.
- **Évaluation de la prédiction** : par rapport aux données expérimentales disponibles et application de techniques de raffinement sont utilisées pour améliorer la qualité du modèle.

AlphaFold 2 et 3

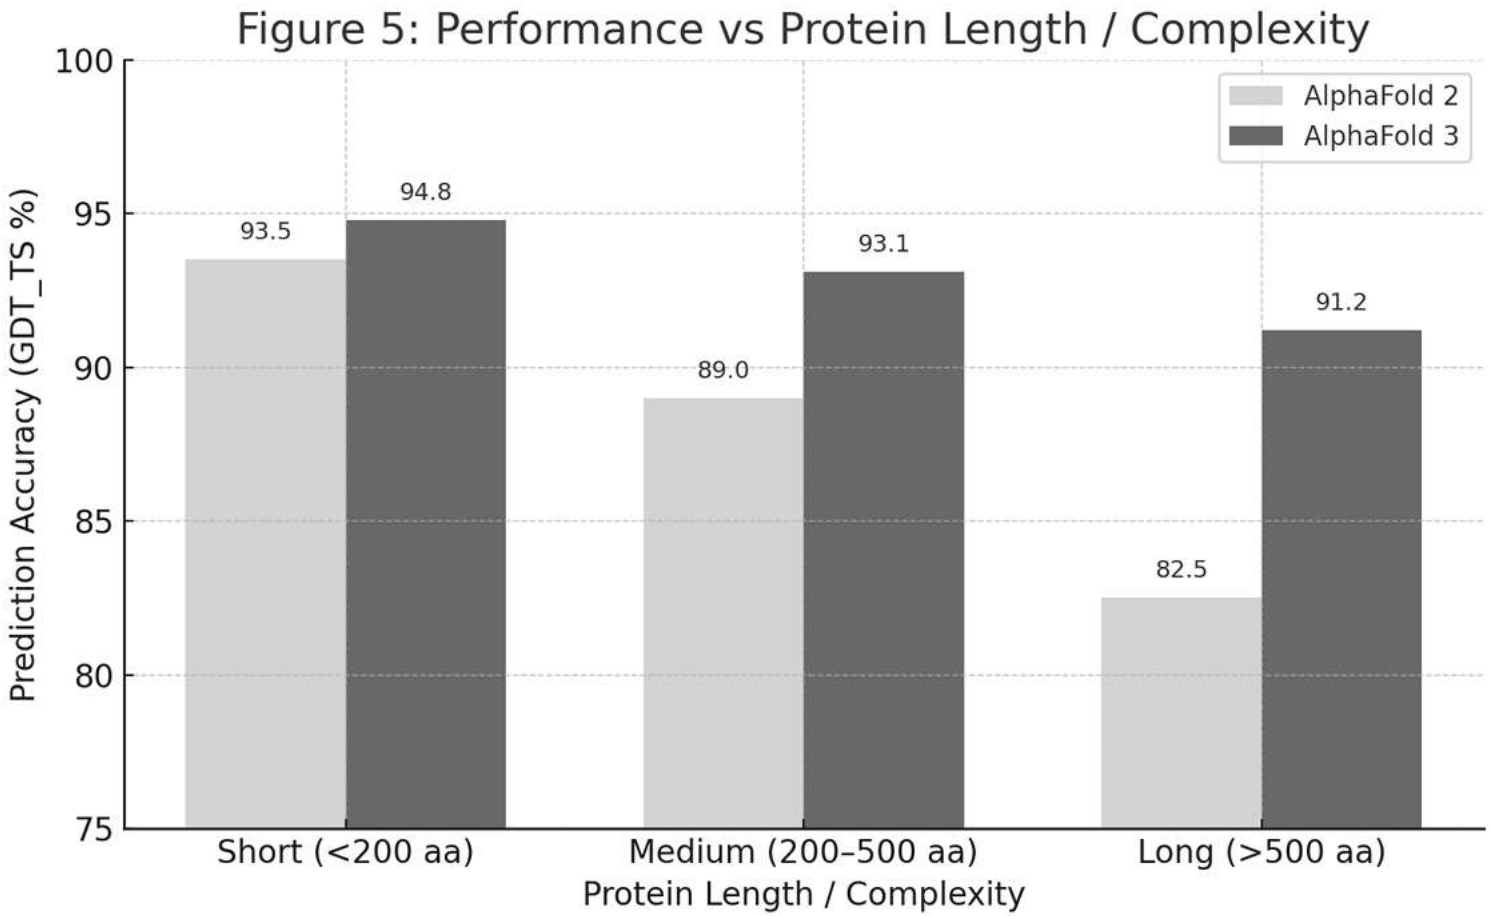

AlphaFold 2 et 3

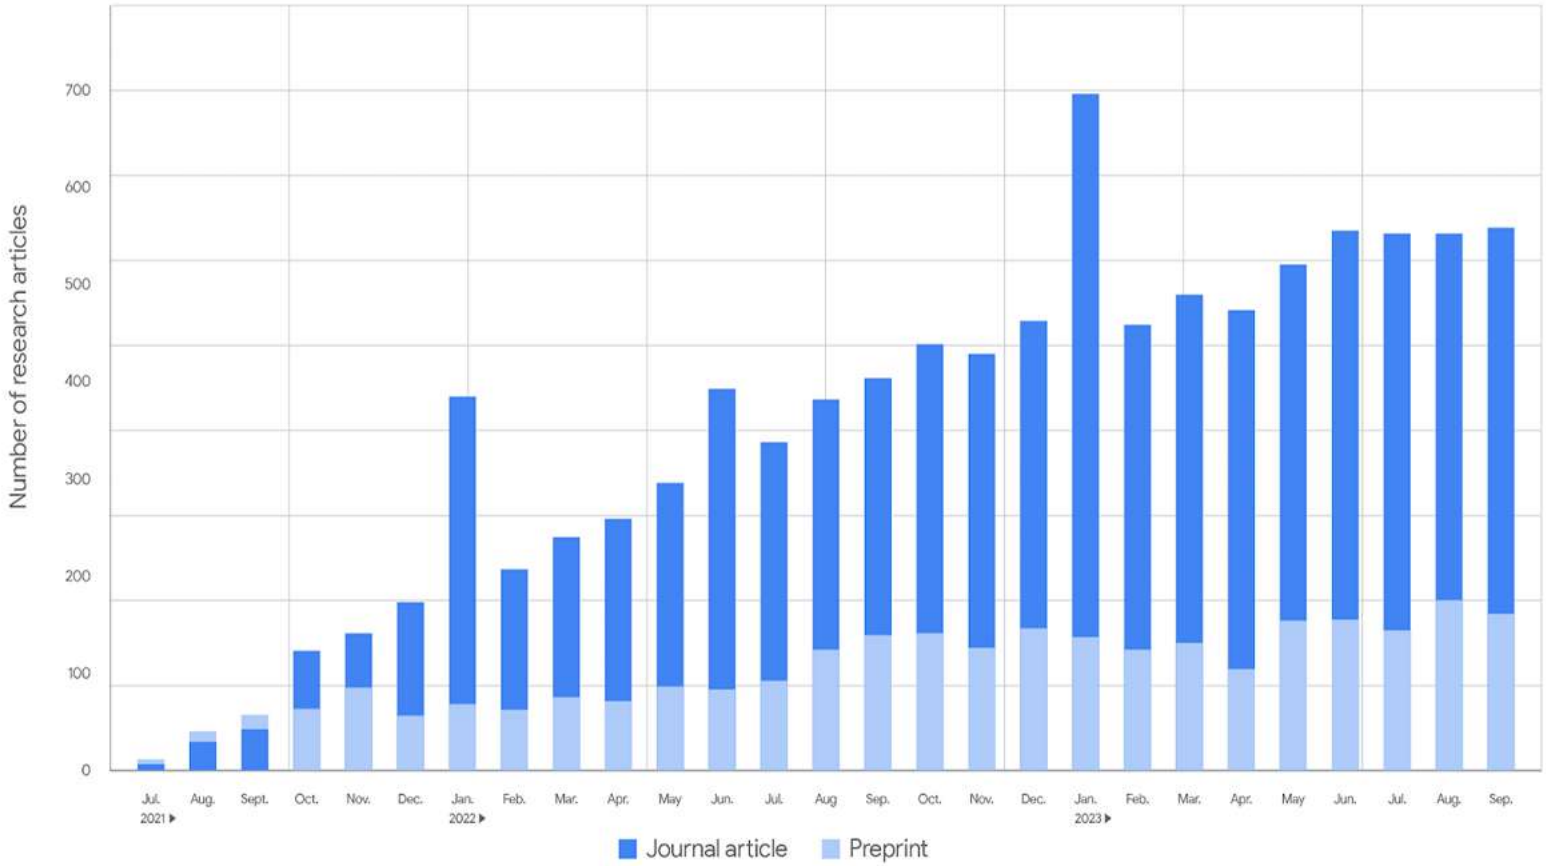

Base de données AlphaFold 2 et 3

- 350 000 structures dont 20 000 protéines connues du corps humain

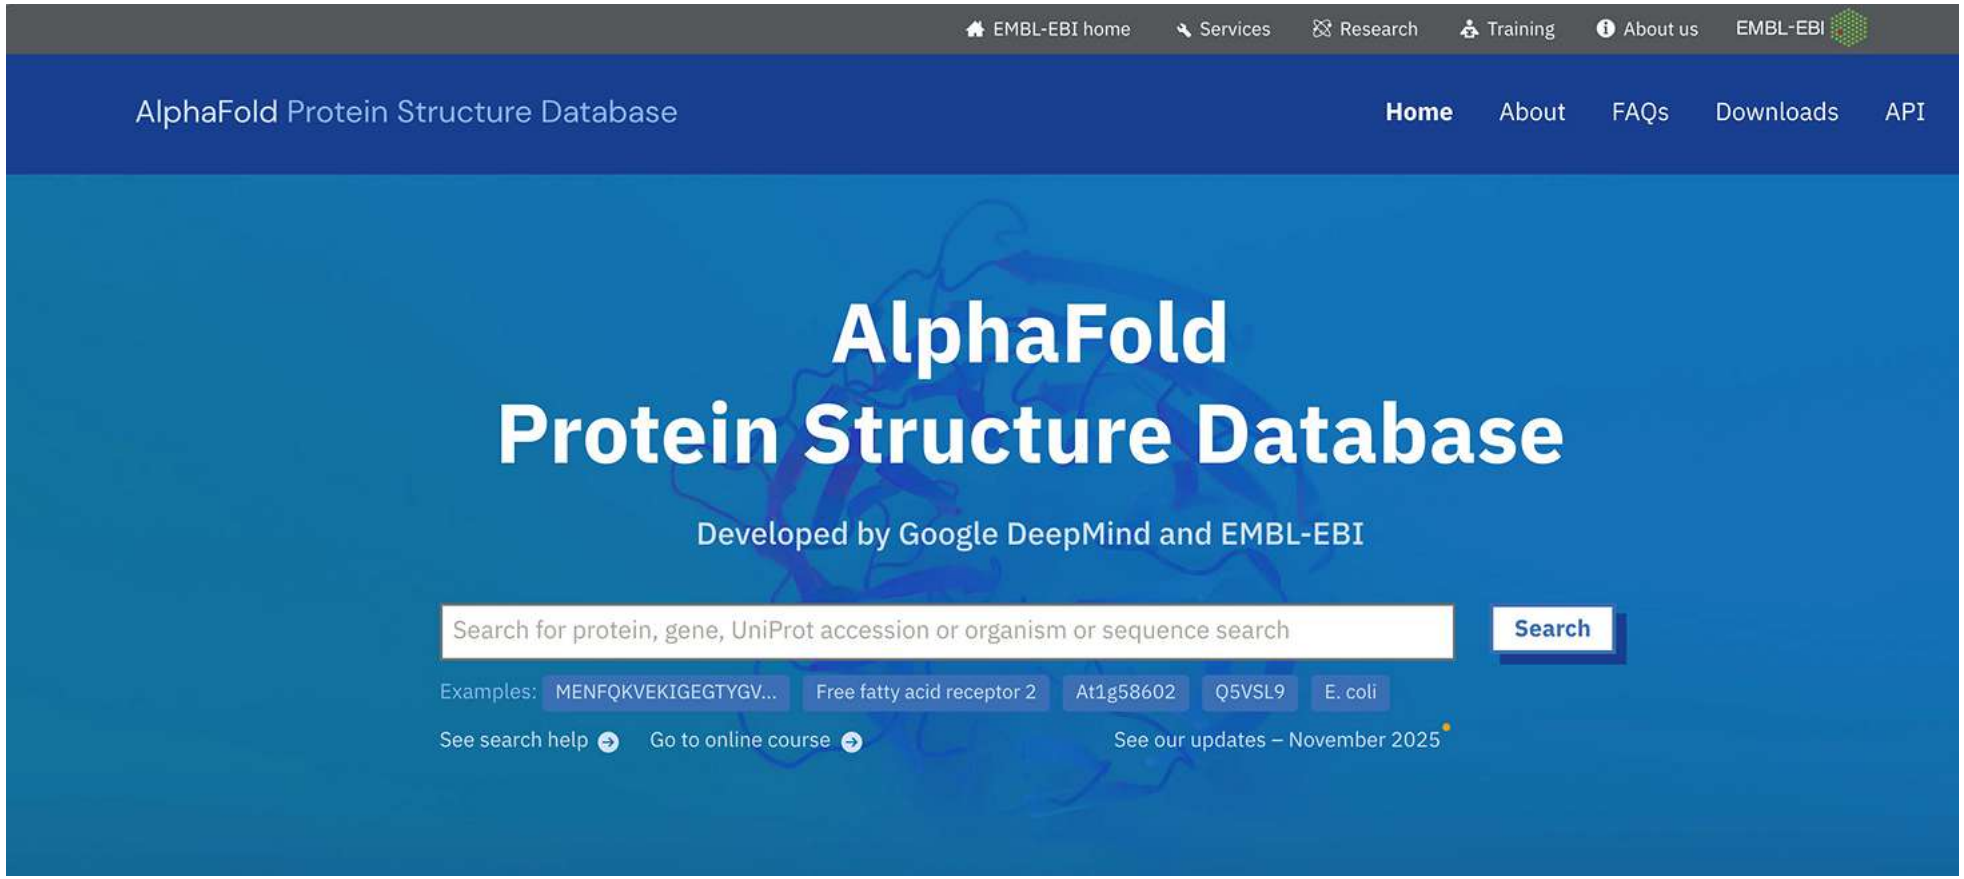

HBB dans AlphaFold 2

AlphaFold Protein Structure Database

HBB

Examples: MENFQKVEKIGEGTYGV... | Free fatty acid receptor 2 | At1g58602 | Q5VSL9 | E. coli

See searc

Showing all search results for HBB

1 - 20 of 1059 results

Filter by:

Status

Review

Reviewed (Swiss-Prot) (230)

Unreviewed (TrEMBL) (829)

Reference proteome

Show predictions for sequences found only in UniProt reference proteomes (293)

Average pLDDT score

Download data

Hemoglobin subunit beta

AF-P68871-F1-v6 • Google Deepmind dataset

Protein	Hemoglobin subunit beta
Gene	HBB
Source organism	Homo sapiens search this organism
UniProt	P68871 go to UniProt
Experimental structures	345 PDB structures for P68871 go to PDBe-KB
Average pLDDT	97.19 (Very High)
Sequence length	147

HBB dans AlphaFold 2

Hemoglobin subunit beta

Download files

AF-P68871-F1-v6 • Google Deepmind dataset •

Tell us what you think of the new look **Share your feedback**

Summary and Model Confidence | Domains | Annotations | Similar Proteins

Protein	Hemoglobin subunit beta
Gene	HBB
Source organism	Homo sapiens (Human) go to search
UniProt	P68871 go to UniProt
Biological function	Involved in oxygen transport from the lung to the various peripheral tissues. go to UniProt

Experimental structures	345 structures in PDB for P68871 go to PDBe-KB
Average pLDDT	97.19 (Very High)
pLDDT distribution	97.3% Very high
	2% High
	0.7% Low
	0% Very low

Hemoglobin subunit beta, Sequence length 147 Copy sequence

```
1         11        21        31        41        51        61        71        81        91        101       111       121       131       141
MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH
```

HBB dans AlphaFold 2

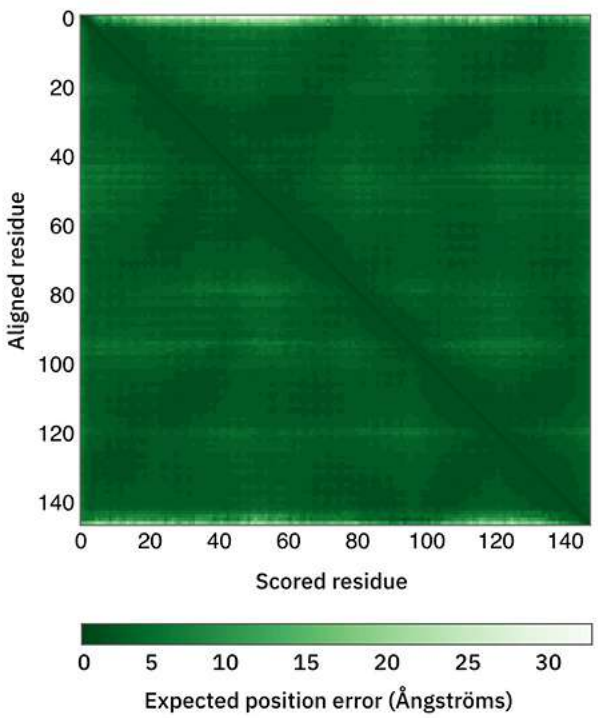

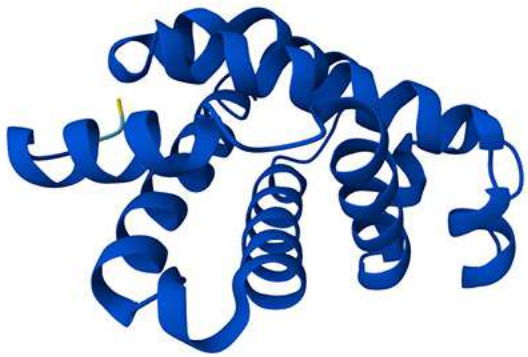

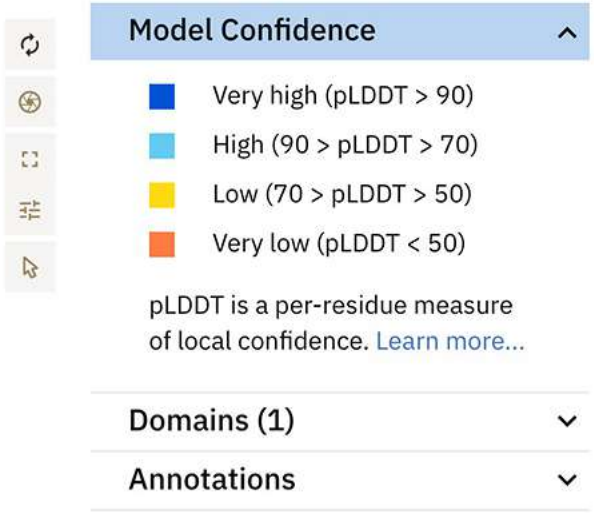

Predicted Aligned Error (PAE)

PAE measures the confidence in the relative position of two residues - **see Help section below** for more information.

Audit history

Model creation date: 1 Aug 2025

Sequence version date: 23 Jan 2007

Domaines

Summary and Model Confidence | **Domains** | Annotations | Similar Proteins

» Show Domains

Domain 1

Source	TED	Boundaries	5-142
CATH	1.10.490.10	Length	138
Quality	High-confidence ★★ Qscore: 90.38 Assignment: C.A.T.H. Homologous Superfamily	Average pLDDT	97.81

Hemoglobin subunit beta, Sequence length 147 Copy sequence

MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGKKVLGAFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVANALAHKYH

Domains

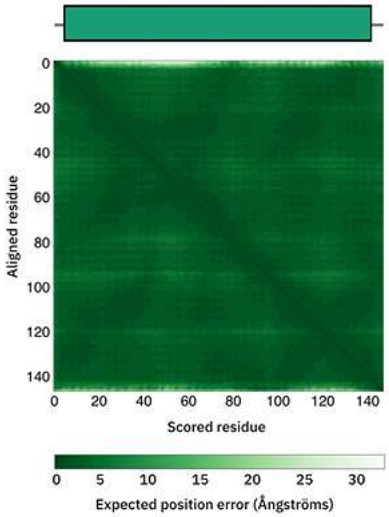

Colour by Domain 1

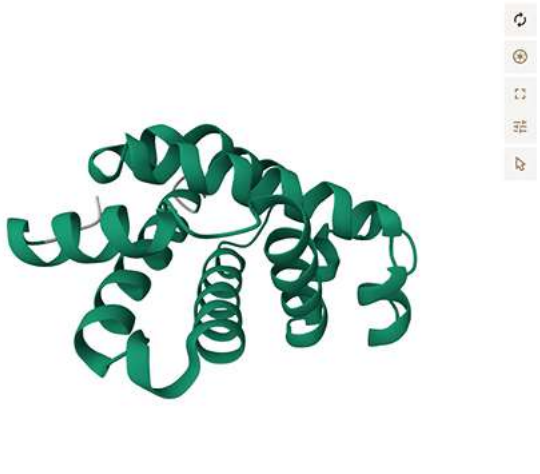

Predicted Aligned Error (PAE)

PAE measures the confidence in the relative position of two residues - **see Help section below** for more information.

Annotations

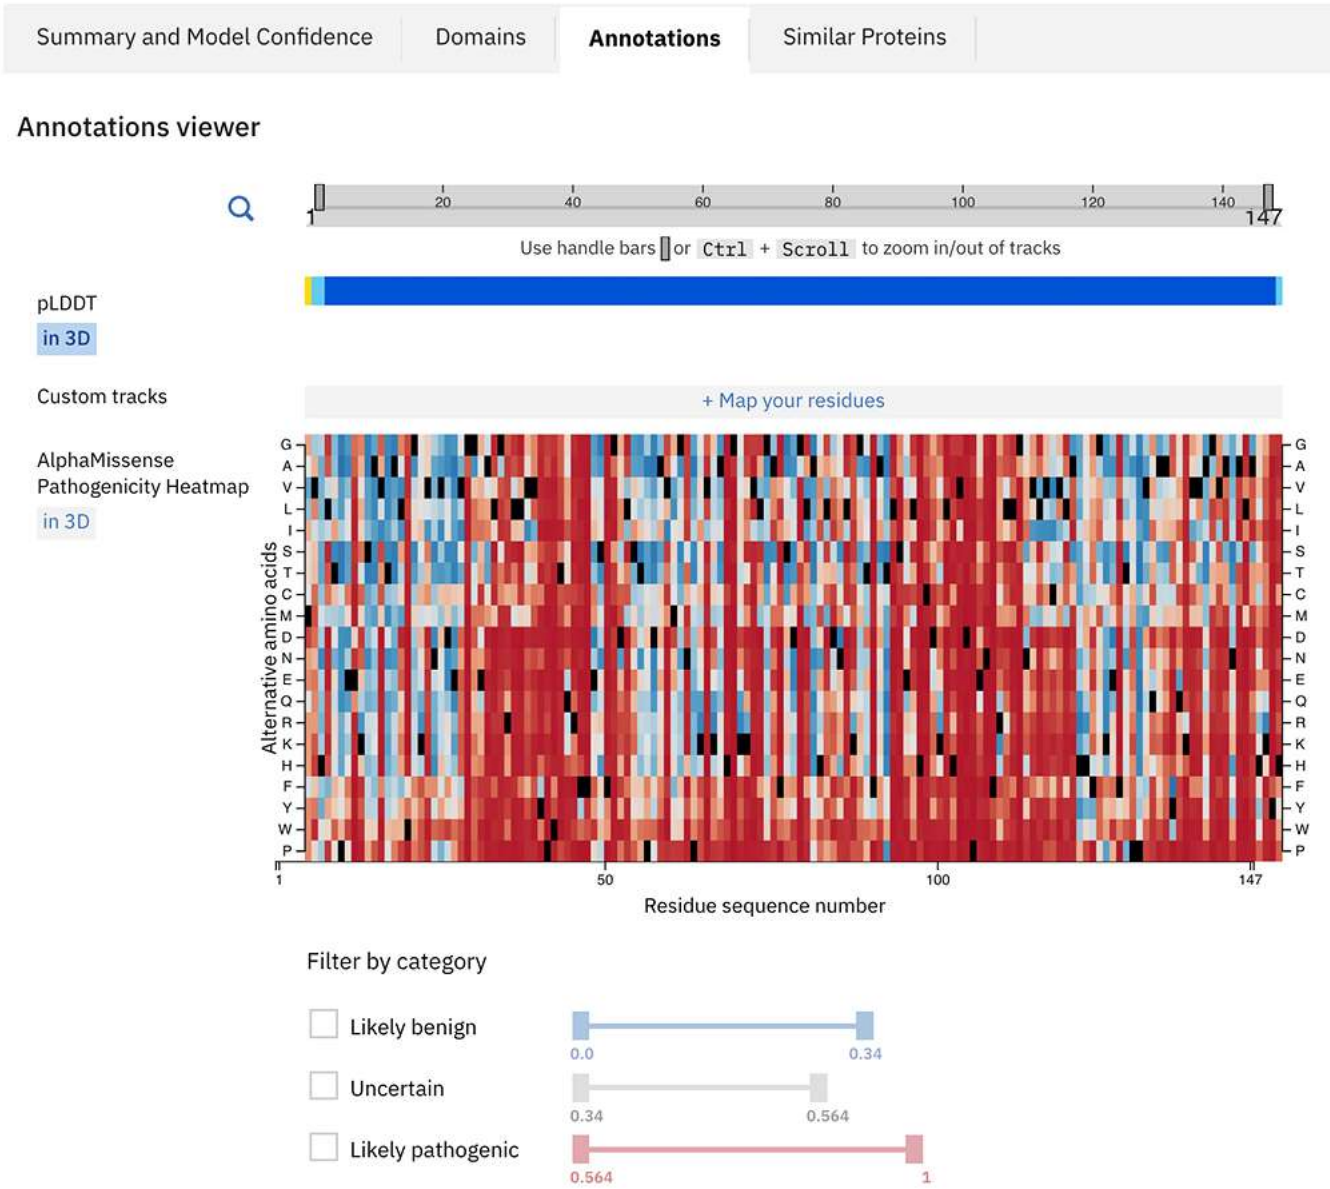

Modèles

Summary and Model Confidence | Domains | Annotations | **Similar Proteins**

Similar structures

Discover similar structures from the Protein Data Bank (PDB) and the AlphaFold Database clustered to 50% sequence identity (AFDB50) using Foldseek.

PDB structures (767) | AFDB50 structures (1000)

Download data

Search species

PDB ID and chain	Description	Species	Residue range	E-value	Seq. identity	Res. (Å)	Align in 3D
1hga_B_2	Hemoglobin subunit beta	*Homo sapiens*	2 - 147 P68871	2.95e-19	100%	2.10	
1j40_B_2	Hemoglobin subunit beta	*Homo sapiens*	2 - 147 P68871	3.10e-19	100%	1.45	
7aeu_DDD_2	Hemoglobin subunit beta	*Homo sapiens*	3 - 147 P68871	6.95e-19	100%	2.54	
1j41_B_2	Hemoglobin subunit beta	*Homo sapiens*	2 - 147 P68871	6.95e-19	100%	1.45	
1hbb_D_2	Hemoglobin subunit beta	*Homo sapiens*	2 - 147 P68871	8.40e-19	100%	1.90	
1j3z_B_2	Hemoglobin subunit beta	*Homo sapiens*	2 - 147 P68871	8.40e-19	100%	1.60	

AF-P68871-F1
Current entry

Colour by pLDDT

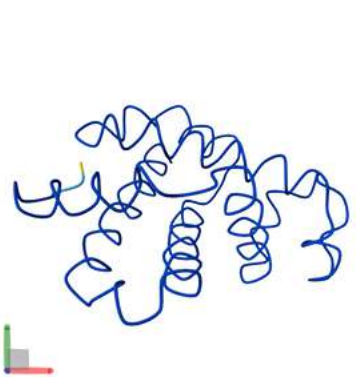

Download aligned coordinates (mmCIF)

Aligned in 3D

Toggle structures in both PDB and AFDB tables to view and align them with the entry structure in the 3D viewer. You can also download the aligned coordinates of the toggled structures and the entry structure.