CM 5 – Nov 2025

Matrices, gaps et BLAST

“Niveau 2”

iAB
EPIGENETICS • ENVIRONMENT
CELL PLASTICITY • CANCER
Institute for Advanced Biosciences
Site Santé
Allée des Alpes - 38700 La Tronche
iab.univ-grenoble-alpes.fr
IAB_Officiel
CENTRE DE RECHERCHE UGA - INSERM U 1209 - CNRS UMR 5309

UGA
UFR CHIMIE & BIOLOGIE
Université Grenoble Alpes

Choix des Matrices

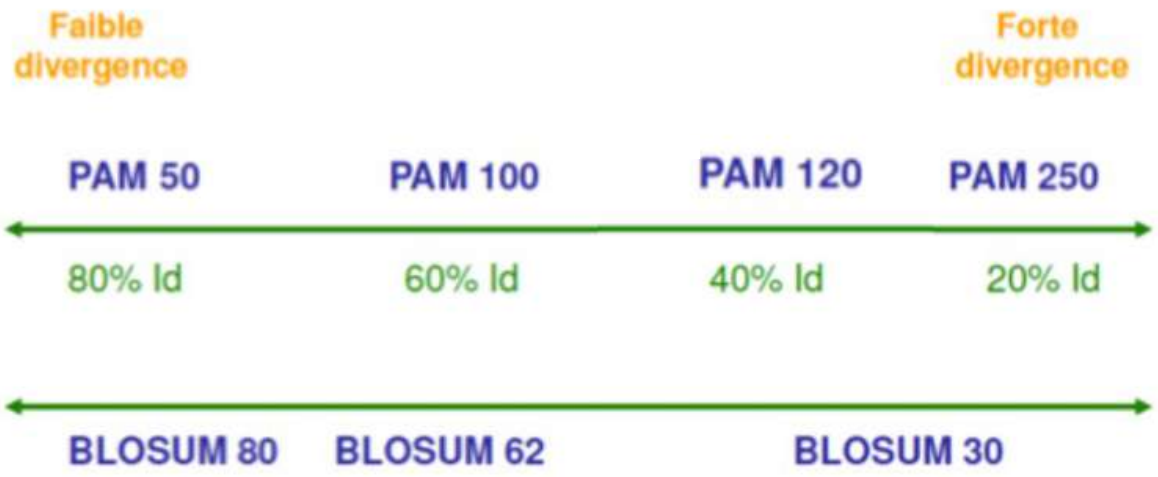

Il n'y a pas de matrice idéale

La question du gap

$$\cancel{Score = \sum se - \sum p}$$

Le bon alignement est souvent celui qui modélise le scénario évolutif le plus probable

Pour maximiser l'alignement la création de gap est souvent nécessaire

MAIS

```
TGAGATGTTCG                    TGAGATGTTCG
TGAG---TTCG                    TGAG-T--TCG
****   ****                    **** *  ***
```

Score = $8*S_i + 3*P$

Le score est identique, mais les alignements sont différents
Le modèle ne permet pas de différencier les deux

$$\cancel{f(k) = k \times P}$$

La fonction linéaire de description du gap ne peut pas prendre en compte le type de gap créé **et** sa longueur

Vers une meilleure modélisation du gap

Un seul gap de longueur *L* est plus probable que *k* gaps de longueur $L = k \times l$

- Un gap est souvent dû à un indel qui peut apporter un bloc de séquences
- Des indels séparés sont probablement le reflet de mutations successives

Or une fonction linéaire du gap ne reflète pas cette différence

On améliore le modèle en utilisant une fonction affine du gap impliquant :

- Une pénalité ***p*** d'ouverture de gap (gap open)
- Une pénalité ***e*** d'extension de gap (gap extend)

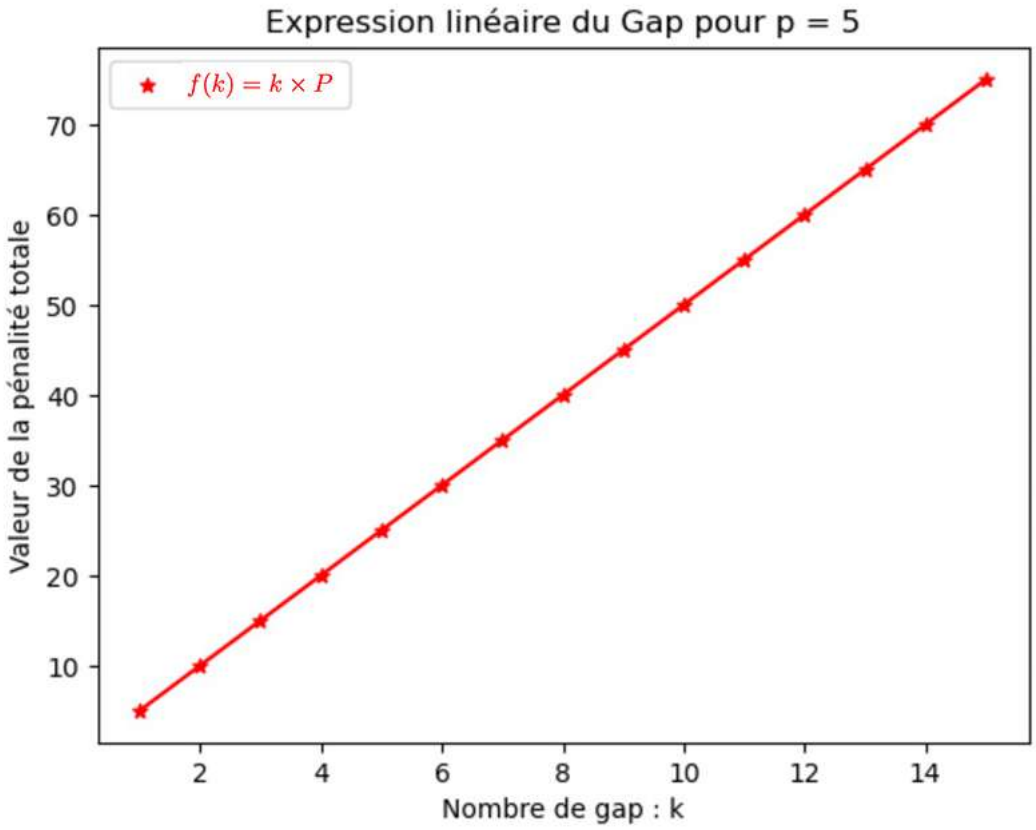

$$f(k) = k \times P$$

Vers une meilleure modélisation du gap

À la pénalité d'ouverture d'un gap s'ajoute une pénalité d'extension du gap

x gap de longueur *k* :

Pénalité affine : $f(k) = p + (k \times e)$

p : pénalité pour l'ouverture d'un gap

e : pénalité pour l'extension d'un gap

```
TGAGATGTTCG                    TGAGATGTTCG
TGAG---TTCG        ≠           TGAG-T--TCG
****   ****                    **** *  ***
```

$8*S_i + 1*P + 2*E$ ≠ $8*S_i + 2*P + 1*E$

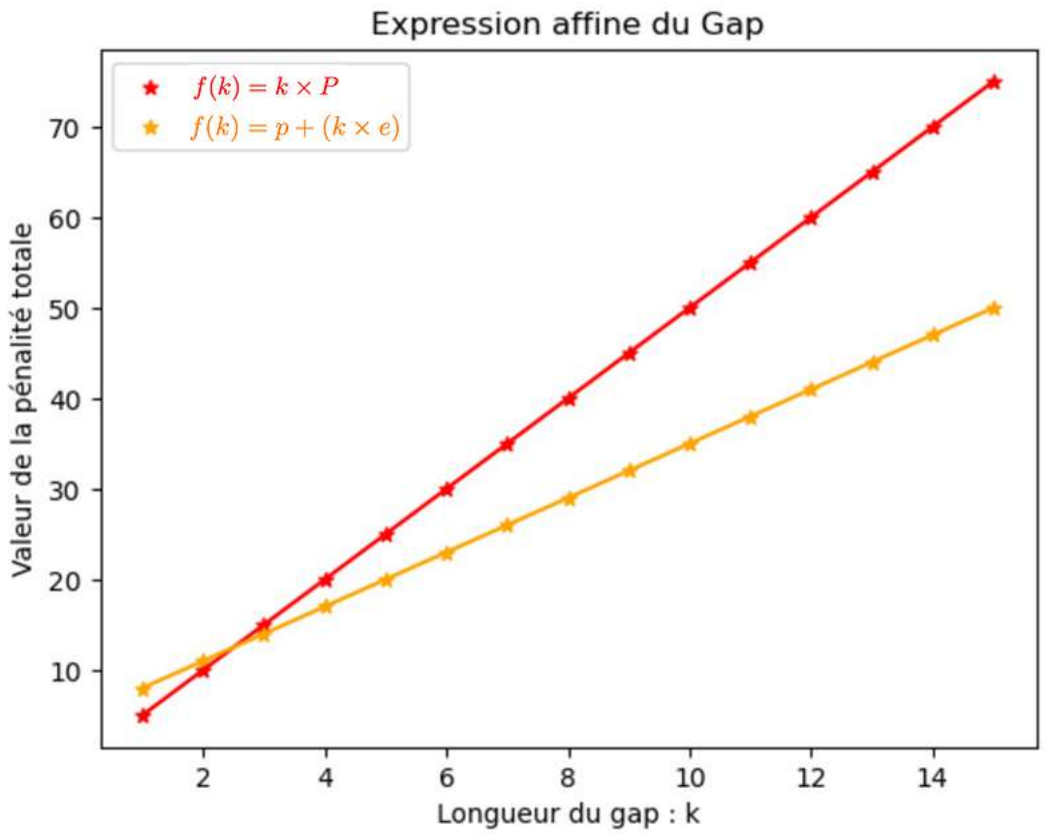

Vers une meilleure modélisation du gap

Estimation des paramètres par l'observation d'alignements réels
(basés sur l'alignement de structures connues)

Gap de longueur *k* : Pénalités logarithmiques

$$f(k) = p + (e \times log(k))$$

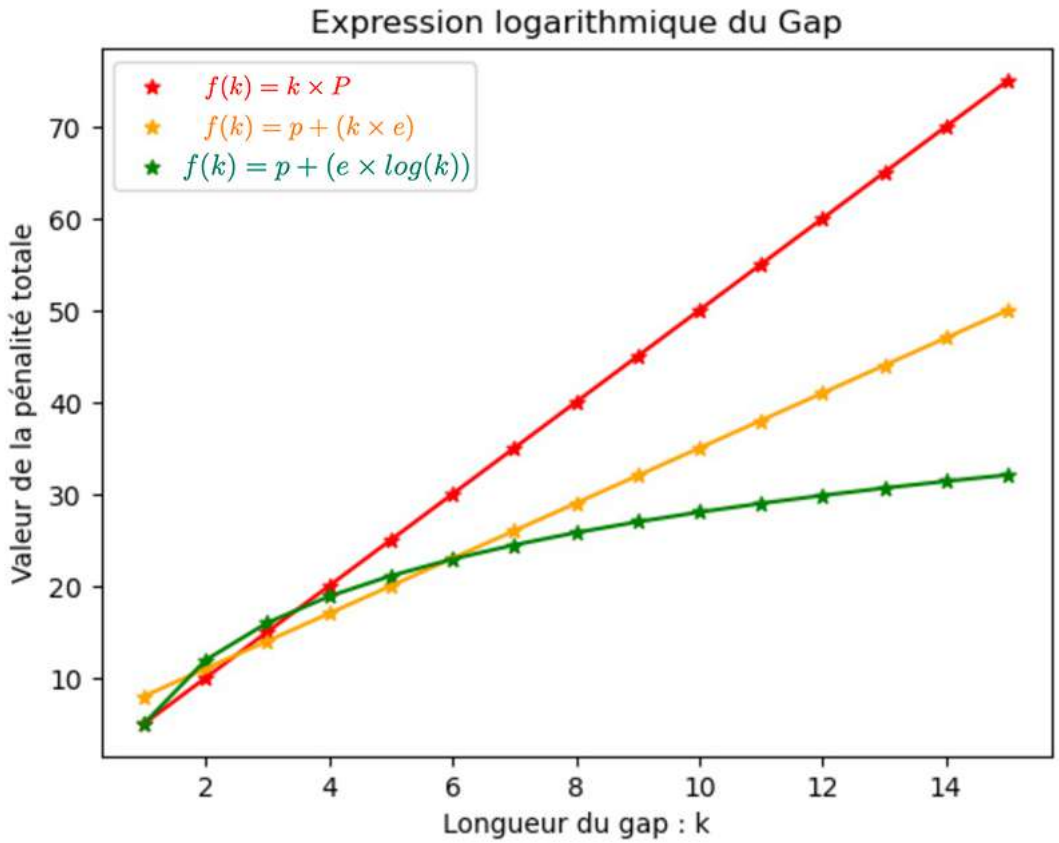

Dans les matrices PAM, la probabilité d'un gap augmente avec la distance évolutive

Rôle du type de résidus et de la structure
La probabilité d'un gap est plus forte dans une boucle (hydrophile) que dans le cœur hydrophobe des protéines :

$$f(k) = (log(k), log(\text{PAM}), \text{résidus}, \text{structure})$$

e gaps pour
par paires

amètres de gestion de création de gaps
défaut souvent ***p = -10*** et ***e = -0.5***

Parameters

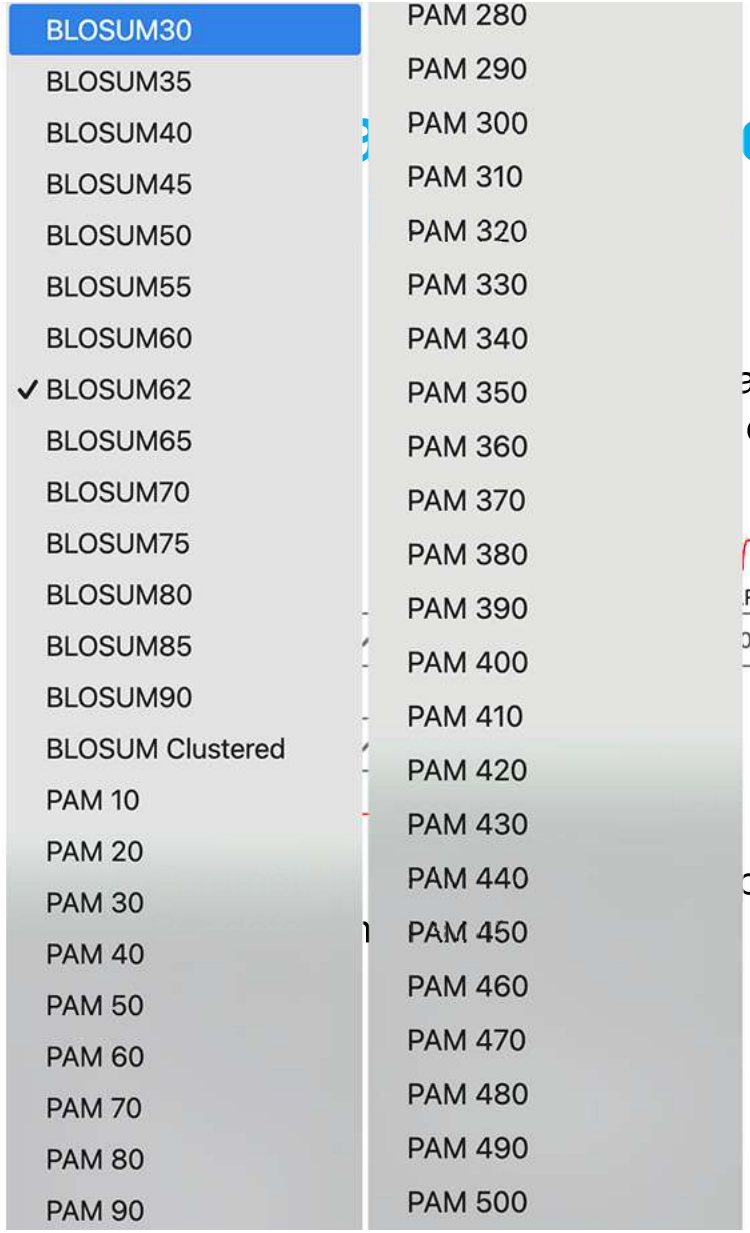

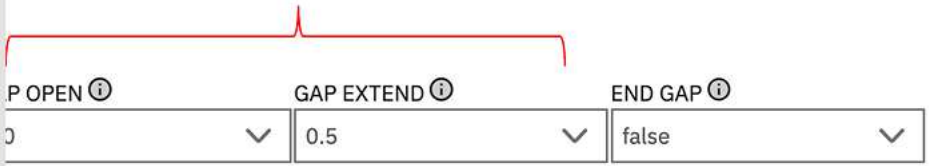

os

Paramètres de gaps pour l'alignement clustal

OUTPUT FORMAT	ClustalW with character counts
DEALIGN INPUT	no
MBED-LIKE CLUSTERING GUIDE-TREE	yes
MBED-LIKE CLUSTERING ITERATION	yes
COMBINED ITERATIONS	default(0)
MAX GUIDE TREE	default
MAX HMM ITERATIONS	default
ORDER	aligned
DISTANCE MATRIX	no
OUTPUT GUIDE TREE	yes

Less options

Paramètres de gaps pour BLAST

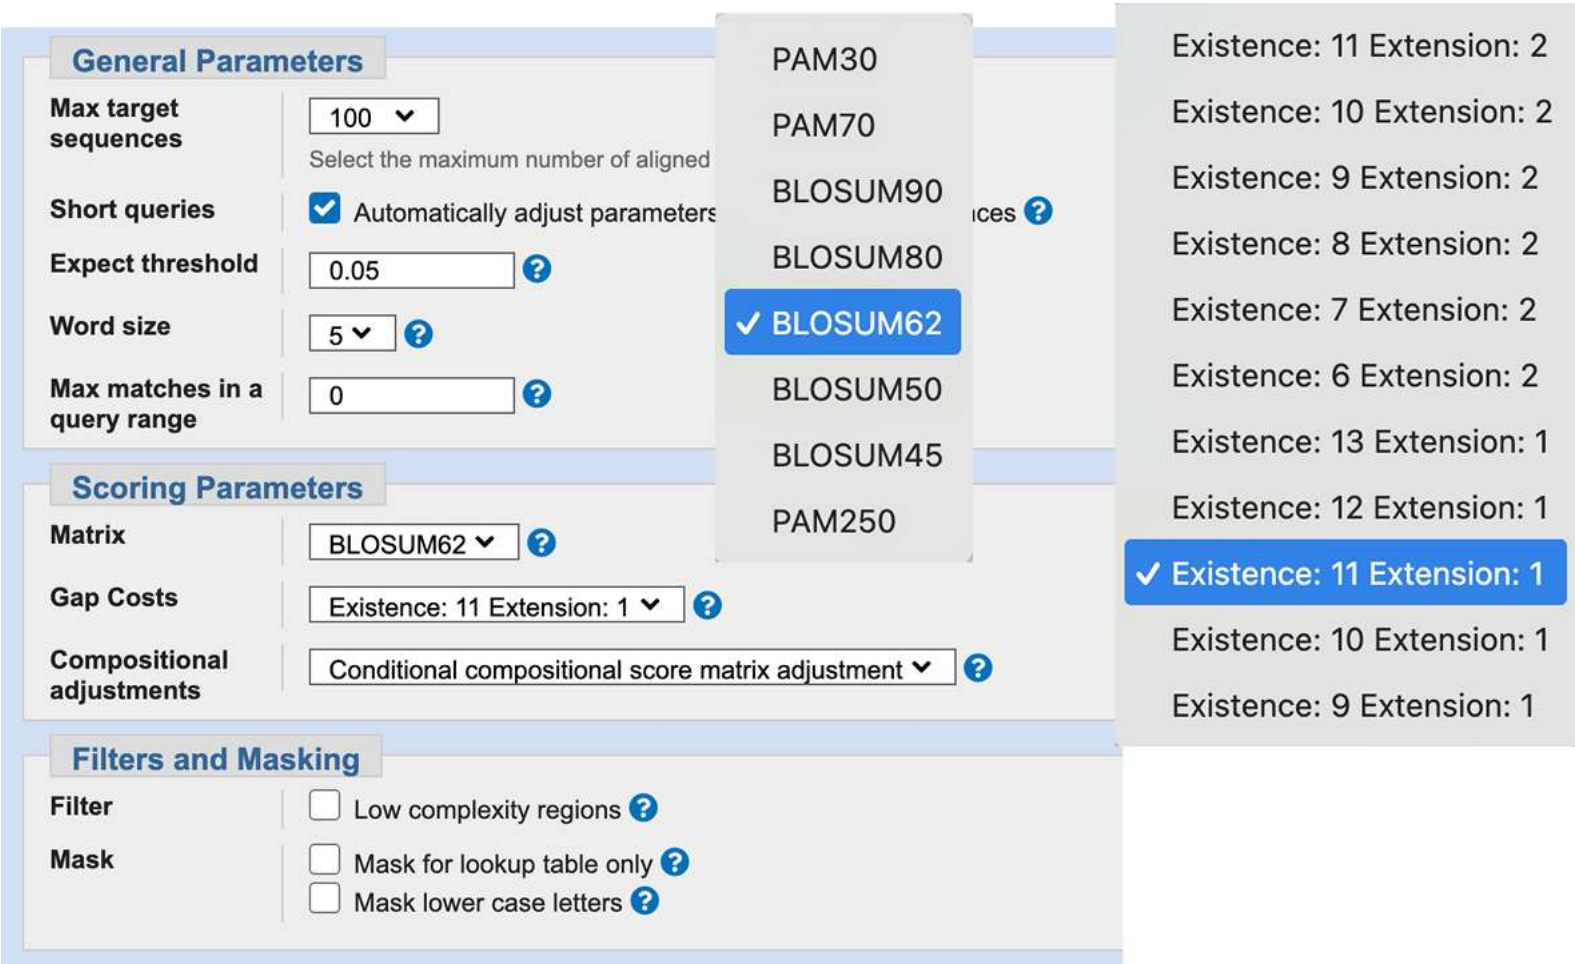

Le format FASTA

- Format de fichier texte pour le stockage des séquences biologiques

- Suite de lettres codant pour des acides nucléiques ou des acides aminés selon la nomenclature IUPAC

- Extensions:
    - .fasta, .fas, .fa, (.seq, .fsa)
    - .faa (acide aminés), .fna (acide nucléiques)
    - .ffn (séquence génomique codante), .frn (séquence ARN non codant)

- La simplicité du format facilite la manipulation et la lecture des séquences par des langages de script tels que Python, R, Ruby, Perl, etc…

- Développé par William R. Pearson pour son programme FASTA
    - Dérive de FASTP (1985) et FASTN
    - « FAST-All » -> FAST-A -> FASTA

- Un fichier FASTA ne contient que deux lignes par séquence
    - Une ligne d'identification / commentaires **qui débute par le caractère >**
    - Une ligne de séquence

Le format FASTA

```
>gi|4504349|ref|NP_000509.1| beta globin [Homo sapiens]
MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGKKVLG
AFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVAN
ALAHKYH
```

```
>(gi|28380636:70595-70686, 70817-71039, 71890-72018) Homo sapiens beta
globin region (HBB@) on chromosome 11
ATGGTGCATCTGACTCCTGAGGAGAAGTCTGCCGTTACTGCCCTGTGGGGCAAGGTGAACGTGGATGAAG
TTGGTGGTGAGGCCCTGGGCAGGCTGCTGGTGGTCTACCCTTGGACCCAGAGGTTCTTTGAGTCCTTTGG
GGATCTGTCCACTCCTGATGCTGTTATGGGCAACCCTAAGGTGAAGGCTCATGGCAAGAAAGTGCTCGGT
GCCTTTAGTGATGGCCTGGCTCACCTGGACAACCTCAAGGGCACCTTTGCCACACTGAGTGAGCTGCACT
GTGACAAGCTGCACGTGGATCCTGAGAACTTCAGGCTCCTGGGCAACGTGCTGGTCTGTGTGCTGGCCCA
TCACTTTGGCAAAGAATTCACCCCACCAGTGCAGGCTGCCTATCAGAAAGTGGTGGCTGGTGTGGCTAAT
GCCCTGGCCCACAAGTATCACTAA
```

Le format FASTA

```
>HBB
MVHLTPEEKSAVTALWGKVNVDEVGGEALGRLLVVYPWTQRFFESFGDLSTPDAVMGNPKVKAHGKKVLG
AFSDGLAHLDNLKGTFATLSELHCDKLHVDPENFRLLGNVLVCVLAHHFGKEFTPPVQAAYQKVVAGVAN
ALAHKYH
>HBD
MVHLTPEEKTAVNALWGKVNVDAVGGEALGRLLVVYPWTQRFFESFGDLSSPDAVMGNPKVKAHGKKVLG
AFSDGLAHLDNLKGTFSQLSELHCDKLHVDPENFRLLGNVLVCVLARNFGKEFTPQMQAAYQKVVAGVAN
ALAHKYH
>HBE1
MVHFTAEEKAAVTSLWSKMNVEEAGGEALGRLLVVYPWTQRFFDSFGNLSSPSAILGNPKVKAHGKKVLT
SFGDAIKNMDNLKPAFAKLSELHCDKLHVDPENFKLLGNVMVIILATHFGKEFTPEVQAAWQKLVSAVAI
ALAHKYH
>HBG1
MGHFTEEDKATITSLWGKVNVEDAGGETLGRLLVVYPWTQRFFDSFGNLSSASAIMGNPKVKAHGKKVLT
SLGDATKHLDDLKGTFAQLSELHCDKLHVDPENFKLLGNVLVTVLAIHFGKEFTPEVQASWQKMVTAVAS
ALSSRYH
>HBG2
MGHFTEEDKATITSLWGKVNVEDAGGETLGRLLVVYPWTQRFFDSFGNLSSASAIMGNPKVKAHGKKVLT
SLGDAIKHLDDLKGTFAQLSELHCDKLHVDPENFKLLGNVLVTVLAIHFGKEFTPEVQASWQKMVTGVAS
ALSSRYH
```

Le format FASTA

Base de données	Format de la ligne d'identification
GenBank	gi|*numéro gi*|gb|*numéro d'accession*|*locus*
Laboratoire européen de biologie moléculaire	gi|*numéro gi*|emb|*numéro d'accession*|*locus*
DNA Data Bank of Japan	gi|*numéro gi*|dbj|*numéro d'accession*|*locus*
NBRF PIR	pir||*entrée*
Protein Research Foundation	prf||*nom*
Swiss-Prot	sp|*numéro d'accession*|*nom*
Brookhaven Protein Data Bank (1)	pdb|*entrée*|*chaîne*
Brookhaven Protein Data Bank(2)	*entrée:chaîne*|PDBID|CHAÎNE|SÉQUENCE
Brevets	pat|brevet|numéro
GenInfo Backbone Id	bbs|numéro
General database identifier	gnl|base de données|identifiant
NCBI Reference Sequence	ref|numéro d'accession|locus
Local Sequence identifier	lcl|identifiant

>gi|4504349|ref|NP_000509.1| beta globin [Homo sapiens]

Les solutions logiciels : BLAST

Basic Local Alignment Search Tool
(*Stephen Altschul, Warren Gish et David Lipman*, *1990, NCBI*)

Le plus utilisé des programmes d'alignement local
-> rapide
-> estime la valeur statistique des scores

Fonctionnement de BLAST

Phase préparatoire :

Indexation de la base de données

>Seq1
KAGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNA

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Indexation de la base de données

>Seq1
KAGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNAQRAGL

Création de l'index
Seq1-1 : KAGKD

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Indexation de la base de données

>Seq1
KAGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNAQRAGL

Création de l'index
Seq1-1 : KAGKD
Seq1-2 : AGKDS

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Indexation de la base de données

>Seq1
KAGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNAQRAGL

Création de l'index
Seq1-1 : KAGKD
Seq1-2 : AGKDS
Seq1-3 : GKDSG

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Indexation de la base de données

>Seq1
KGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNAQRAGL

Création de l'index
Seq1-1 : KAGKD
Seq1-2 : AGKDS
Seq1-3 : KDSGK
…
Seq1-18 : QRAGL

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Indexation de la base de données

>Seq1
KGKDSGKAKTKAVSRSQRAGLQFPV
>Seq2
GRIHRHLKSRTTSHGRVGATAAVYS
>Seq3
YSAAILEYLTAEVLELAGNAQRAGL

Création de l'index
Seq1-1 : KAGKD
Seq1-2 : AGKDS
Seq1-3 : KDSGK
…
Seq1-18 : QRAGL
…
Seq3-21 : QRAGL

Fonctionnement de BLAST

Phase préparatoire : Taille du mot k = 5

Tri de l'index de la base de données

Création de l'index
Seq1-1 : KAGKD
Seq1-2 : AGKDS
Seq1-3 : KDSGK
…
Seq1-18 : QRAGL
…
Seq3-21 : QRAGL

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

GRIHR => 0

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

GRIHR => 0
RIHRH => 0

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

GRIHR => 0
RIHRH => 0
…
QRAGL => Seq1-18 : Seq3-21

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

```
Query :        GRIHRHLKSRTTQRAGLSHGRVGAT
                           |||||
Subject1: KGKDSGKAKTKAVSRSQRAGLQFPV
```

Fonctionnement de BLAST

Étape 1 de la recherche :
Recherche des mots de la séquence « Query » dans l'index trié

K = 5
Query :

>ProtX
GRIHRHLKSRTTQRAGLSHGRVGATAAVYSA
AILEYLTAEVLELAGNA

Index trié
KAGKD -> Seq1-1
AGKDS -> Seq1-2
KDSGK -> Seq1-2
…
QRAGL -> Seq1-18 : Seq3-21
…
Etc

```
Query :            GRIHRHLKSRTTQRAGLSHGRVGAT
                                |||||
Subject3: YSAAILEYLTAEVLELAGNAQRAGL
```

Fonctionnement de BLAST

Étape 2 de la recherche :
Extension de l'alignement sans indel
Création des HSP (High Scoring Pairs)

```
Query :        GRIHRHLKSRTTQRAGLSHGRVGAT
                           |||||
Subject1: KGKDSGKAKTKAVSRSQRAGLQFPV

Query :            GRIHRHLKSRTTQRAGLSHGRVGAT
                              |||||
Subject3: YSAAILEYLTAEVLELAGNAQRAGL
```

Fonctionnement de BLAST

Étape 2 de la recherche :
Extension de l'alignement sans indel
Création des HSP (High Scoring Pair)

```
Query :        GRIHRHLKSRTTQRAGLSHGRVGAT
                         |||||
Subject1: KGKDSGKAKTKAVSRSQRAGLQFPV

Query :            GRIHRHLKSRTTQRAGLSHGRVGAT
                          |||||
Subject2: YSAAILEYLTAEVLELAGNAQRAGL
```

Extension du segment jusqu'à un seuil S ≥ seuil limite

Fonctionnement de BLAST

Accélération des calculs en considérant des mots « approximatifs »
Sur la base du calcul de score de « dérive »

Il prépare tous les mots dérivés de chaque index et calcul le score de l'alignement avec la matrice définie
Il compare ce score à une limite et prend la décision d'exclure le mot ou pas de la recherche

K = 5 et Score min S_{min}= 13

QRAGL S = 5+5+0+6+2 = 18 > S_{min} **-> Accepté**
QRQGI

QRAGL
PRGRL S = -1+5-1-2+2 = 3 < S_{min} **-> Rejeté**

Fonctionnement de BLAST

Dans la base, tous les scores des mots de *k* lettres sont dérivés à l'avance
La construction de la base est très lente et le document produit très long
Mais après indexation, la recherche est plus rapide lorsque *k* est petit

K = 5 et Score min S_{min}= 13

QRAGL S = 5+5+0+6+2 = 18 > S_{min}-> Accepté
QRQGI

QRAGL
PRGRL S = -1+5-1-2+2 = 3 < S_{min}-> Rejeté

Une fois la liste de tous les mots obtenue de la séquence alignés sur les index de la base, il tente de trouver 2 HSP espacés par la même distance dans les 2 séquences

Fonctionnement de BLAST

Ensuite, il applique une contrainte de trouver 2 HSP espacés par la même distance dans les 2 séquences

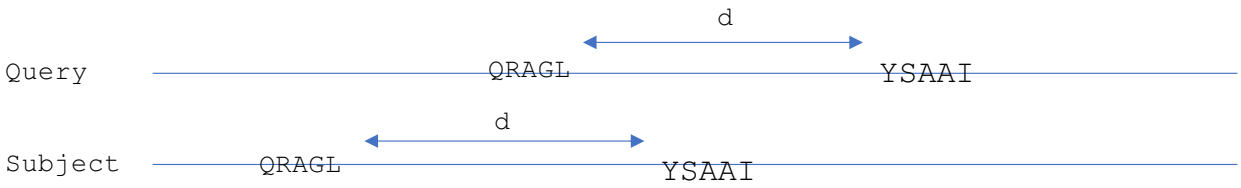

Fonctionnement de BLAST

Ensuite on applique la contrainte de trouver 2 HSP espacés par la même distance dans les 2 séquences

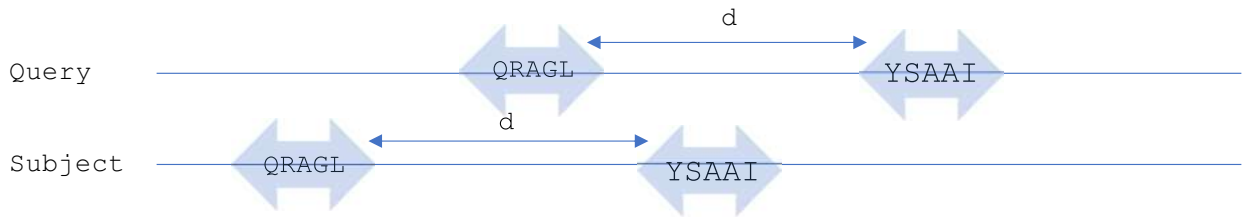

Vérification que les séquences peuvent être étendues entre les HSP

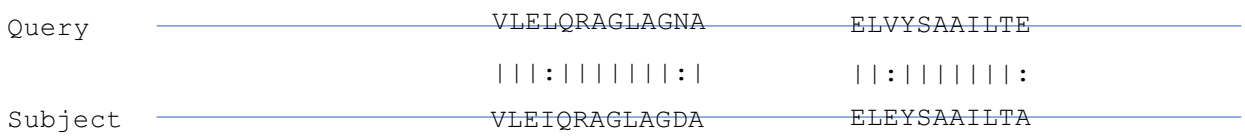

Alignement local SW avec calcul de scores $S > S_{min}$

Fonctionnement de BLAST

Étape 3 : Estimation de la statistique du résultat

Quelle est la probabilité *p* d'obtenir par hasard des HSP respectant les valeurs de S_{min} définies ?

D'après la distribution de valeurs extrêmes de Gumbel (*Gumbel EVD*)

$$p_{(S \geq x)} = 1 - e^{(-e^{-\lambda(x-\mu)})}$$

$$\mu = \frac{\log(K * m' * n')}{\lambda}$$

$\lambda = 0.318$ (BLOSUM62)

$m \; et \; n \; longueur \; des \; séquences \; comparées$

K = coefficient

Fonctionnement de BLAST

Étape 3 : Estimation de la statistique du résultat

Le score attendu *E* (*E-score – Expected score*) d'un match dans la base de données est le nombre de fois qu'un tel match sera trouvé par chance dans une base de données aléatoire avec un score $S \geq x$

$$E \approx 1 - e^{-p(S>xD)}$$

D : nombre de séquences dans la base

Si $p < 0{,}1$ on peut approximer *E* par une distribution de poisson à :

$$\boldsymbol{E \approx pD}$$

E : Expect value, Expectation value noté *E-Score*, *E-value*, *e-value* indique ainsi la signification d'un score de HSP pour un alignement local sans gap

Fonctionnement de BLAST

Étape 3 : Estimation de la statistique du résultat

E-value = 5 signifie donc :

« Si je compare ma séquence à une base de données aléatoire de même taille et de même composition que la base de données de recherche, je m'attends à trouver 5 alignements de score = *S* »

⇒ Forte probabilité, HSP non significatif

Plus la *E-value* est petite, plus la similarité est pertinente
(indépendante du hasard)

Cette *E-value* dépend :
- De la matrice de substitution (qui impose les valeurs de S et de la taille des HSP)
- De la taille et de la composition de la base de données

Fonctionnement de BLAST

Fourchette de la *E-value*

$1e^{-200} < E\text{-}value < 1e^{-100}$	Les alignements sont biologiquement pertinents
$1e^{-100} < E\text{-}value < 1e^{-50}$	Séquences pratiquement identiques (allèles, mutations ponctuelles, espèces voisines)
$1e^{-50} < E\text{-}value < 1e^{-10}$	Lien probable entre la séquence X et celles trouvées dans la base de données
$1e^{-1} > E\text{-}value > 0{,}1$	Séquences de l'alignement à rejeter car n'ont aucun rapport avec la séquence X recherchée

Les différentes versions de BLAST

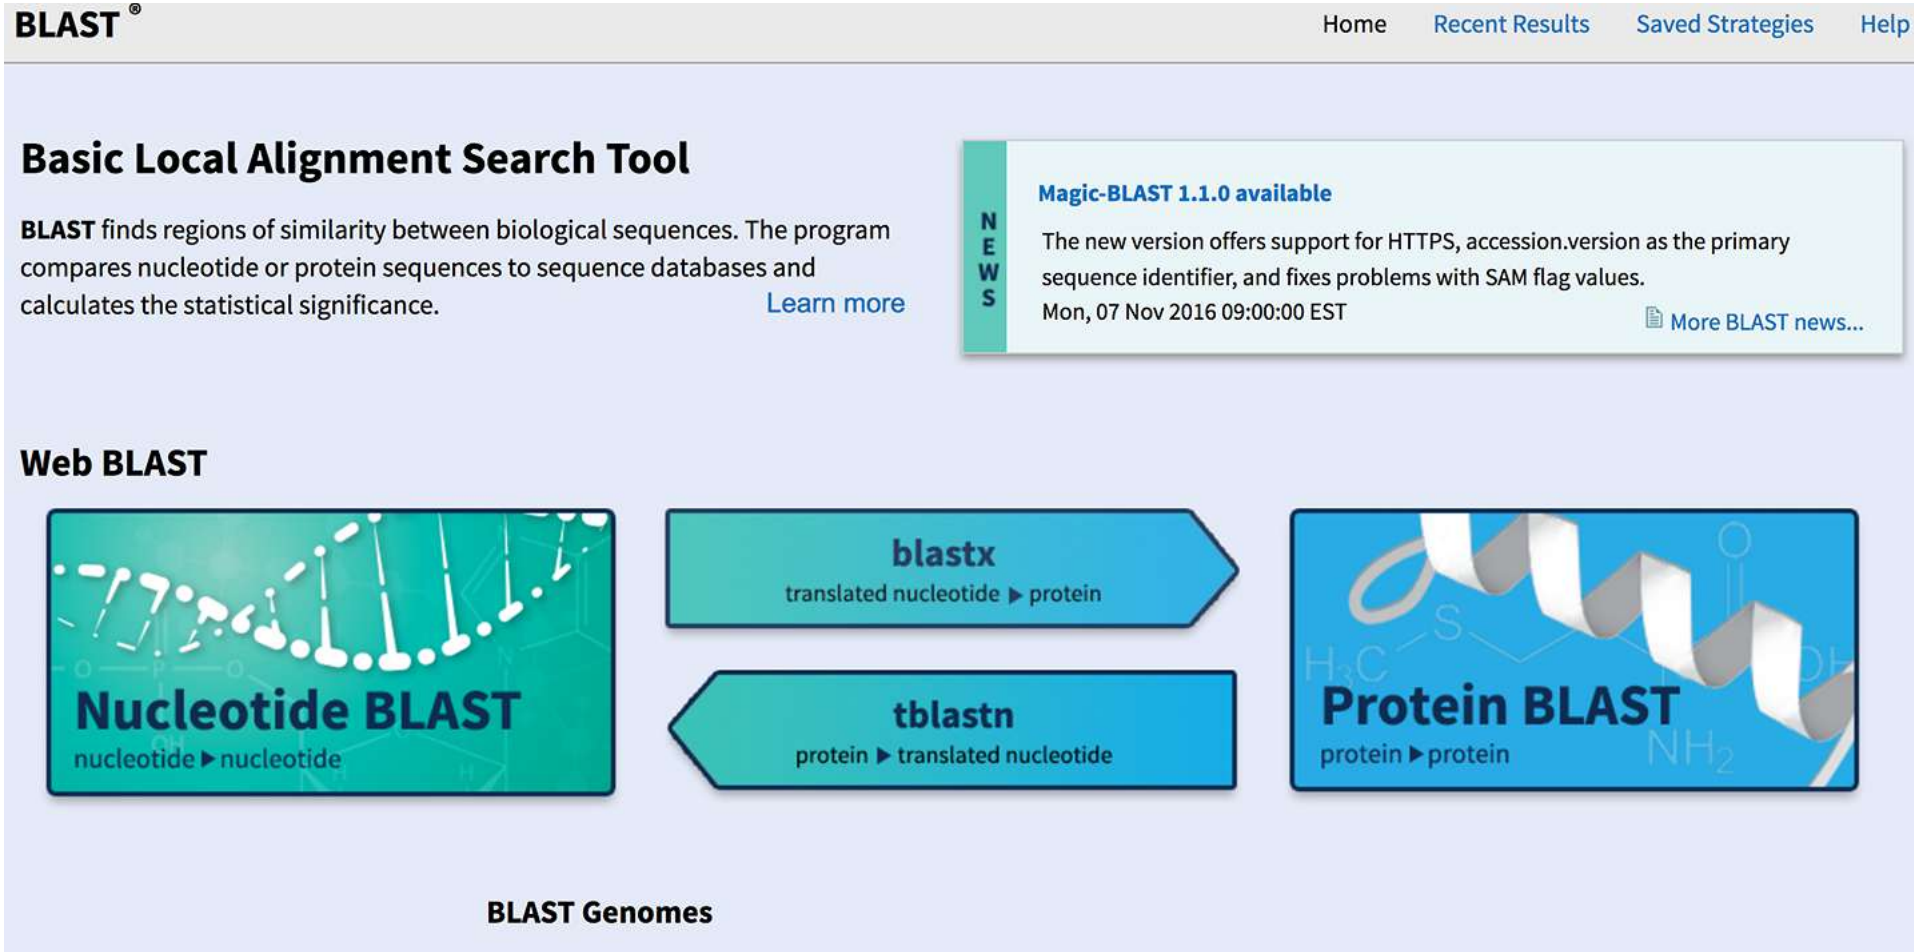
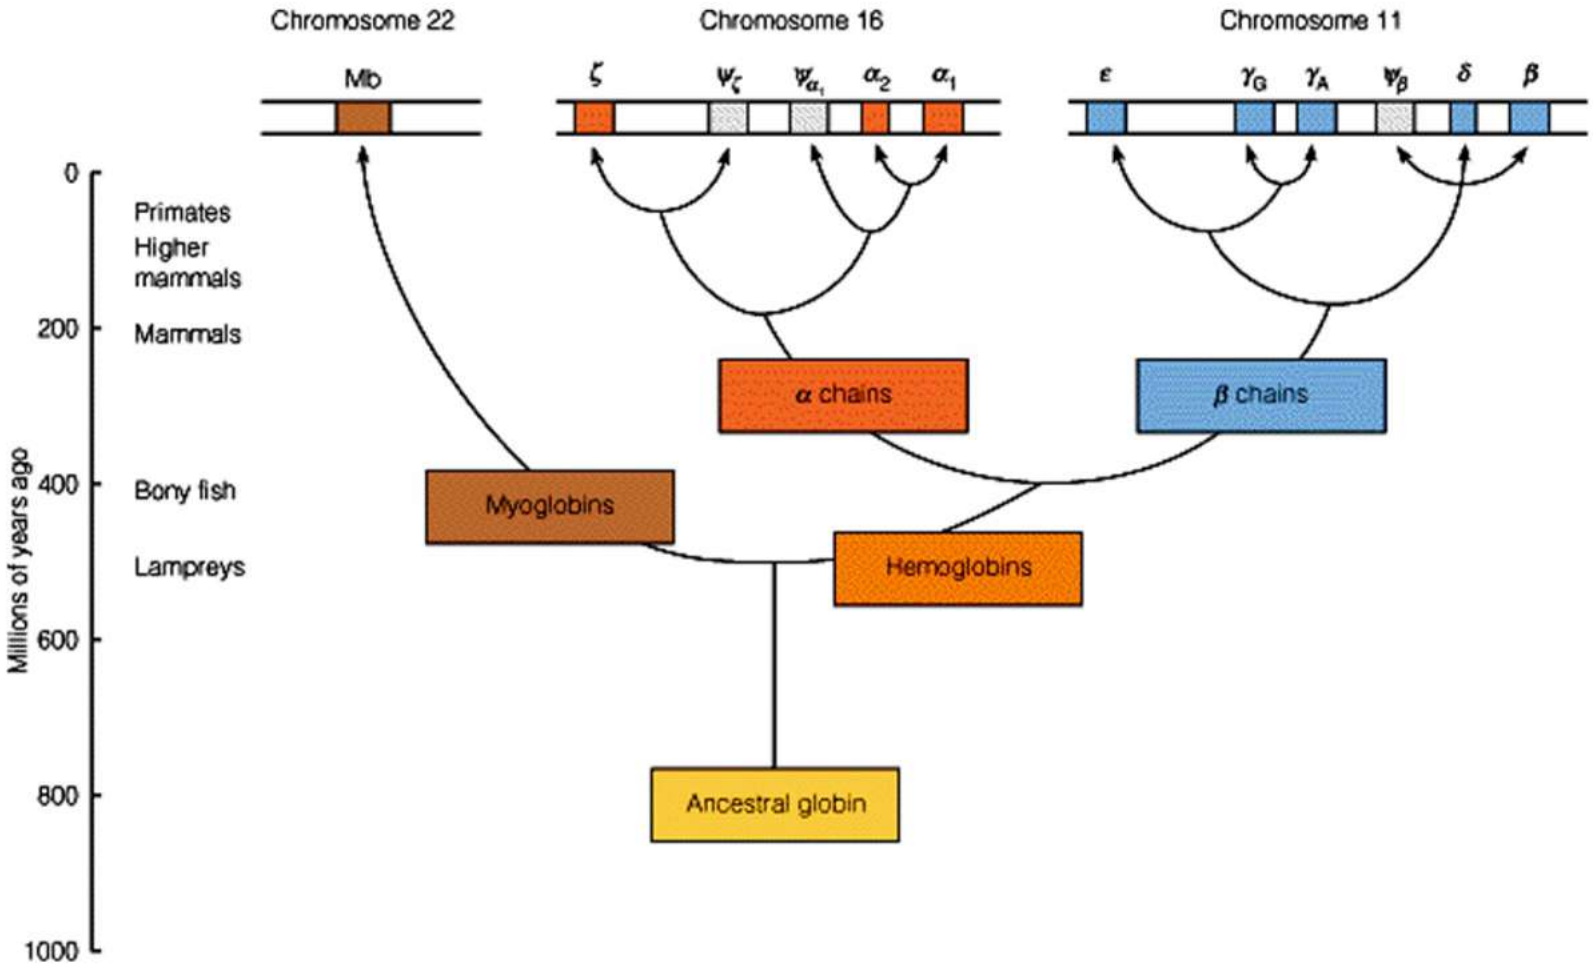
Les globines dans leur ensemble